

Quant-WM-Guru

Ein probabilistisches Prognose- und Entscheidungssystem für die FIFA-Weltmeisterschaft
2026

Konzeptdokumentation

M. Dantschenko

Juni 2026

Zusammenfassung

Dieses Dokument spezifiziert Konzept, Mathematik, Datenarchitektur und Validierungsmethodik eines quantitativen Prognosesystems für Fußball-Länderspiele, mit der FIFA-WM 2026 als Anwendungsfall. Das System trennt strikt zwischen *Inferenz* (Schätzung einer vollständigen Wahrscheinlichkeitsverteilung über Spielausgänge) und *Entscheidung* (Ableitung optimaler Handlungen aus dieser Verteilung). Auf demselben stochastischen Kern operieren zwei entscheidungstheoretisch fundamental verschiedene Modi: (1) ein *Capital Allocator*, der Wetten als risikobehaftete Assets behandelt und Einsätze über das fraktionale Kelly-Kriterium mit Risiko-Nebenbedingungen dimensioniert, wobei Nicht-Wetten eine zulässige und häufig optimale Aktion ist; und (2) ein *Kicktipp-Optimierer*, der unter Tippzwang den erwarteten Punktertrag einer turnierspezifischen Punktefunktion maximiert. Die Validierung erfolgt über strikt zeitkausale Walk-Forward-Backtests auf historischen Turnieren (Validierung: WM 2014, EM 2016, WM 2018; eingefrorenes Test-Set: EM 2021, WM 2022, EM 2024, Copa América 2024) mit Proper Scoring Rules (Ranked Probability Score, Log-Loss, Brier Score), Kalibrierungsanalyse sowie ökonomischen Metriken (ROI, Maximum Drawdown, Closing Line Value) gegen explizit definierte Baselines, insbesondere den entvigten Buchmachermarkt.

Inhaltsverzeichnis

1	Einleitung und Zielsetzung	3
1.1	Motivation	3
1.2	Leitprinzip: Trennung von Inferenz und Entscheidung	3
1.3	Capabilities: Was das System leisten muss	3
1.4	Explizite Nicht-Ziele (Scope-Abgrenzung)	4
2	Mathematische Grundlagen	4
2.1	Lernen unter vollständiger Information	5
3	Problemformulierung	5
3.1	Notation	5
3.2	Die Entscheidungsprobleme	6
4	Datenarchitektur	9
4.1	Kanonisches Datenmodell	9
4.2	Datenquellen und Priorisierung	9
4.3	Datenqualität und bekannte Probleme	11
4.4	Abgeleitete Merkmalsdatensätze	12

5	Schicht 1: Das stochastische Modell	12
5.1	Basismodell: unabhängige Poisson-Zählprozesse	12
5.2	Dixon-Coles-Korrektur und Zeitgewichtung	13
5.3	Alternative Kopplung und Überdispersion	14
5.4	Dynamische Teamstärken: Zustandsraum-Formulierung	14
5.5	Bayesianische Hierarchie: das Sparse-Data-Problem der Nationalteams	15
5.6	Regimewechsel und turnierspezifische Strukturbrüche	15
5.7	Elo-basiertes Referenzmodell	16
5.8	Feature-basiertes ML-Modell und dynamisches Ensemble (Online Learning) . . .	16
5.9	K.o.-Phase: Verlängerung und Elfmeterschießen	17
6	Schicht 2: Pricing Engine — von Intensitäten zur Ergebnismatrix	18
6.1	Analytische Auswertung als Standardpfad	18
6.2	Monte Carlo, wo es tatsächlich gebraucht wird	18
7	Marktdaten: implizite Wahrscheinlichkeiten und Entvigung	18
8	Schicht 3, Modus A: Der Capital Allocator	19
8.1	Value-Identifikation	19
8.2	Kelly-Kriterium: Herleitung	19
8.3	Fraktionales Kelly und Unsicherheits-Shrinkage	19
8.4	Grenzen der Asymptotik und Finite-Horizon-Effekte	19
8.5	Mehrere gleichzeitige Spiele: Portfolio-Sicht	20
8.6	Betriebsregeln Modus A	21
9	Schicht 3, Modus B: Der Kicktipp-Optimierer	21
9.1	Punktefunktion der Zielrunde	21
9.2	Optimaler Tipp als Erwartungsnutzen-Maximierung	22
9.3	Sensitivität und Diagnostik	22
9.4	Erweiterung: Rang- statt Punktemaximierung	22
10	Validierung und Backtesting	23
10.1	Designprinzipien und Leakage-Kontrolle	23
10.2	Evaluationsdatensätze	24
10.3	Probabilistische Güte: Proper Scoring Rules	24
10.4	Baselines (Mindesthürden)	24
10.5	Ökonomische Validierung Modus A	25
10.6	Validierung Modus B	25
10.7	Statistische Signifikanz	25
11	Software-Architektur	26
11.1	Schichtenmodell	26
11.2	Zentrale Abstraktionen	26
12	Roadmap mit Verifikationskriterien	26
13	Future Work	27

1 Einleitung und Zielsetzung

1.1 Motivation

Fußballspiele sind niedrig-skorende, stark verrauschte stochastische Ereignisse: Das bessere Team verliert regelmäßig, und einzelne Tore (Erwartungswert pro Spiel $\approx 2,5$ – $2,7$) dominieren das Ergebnis. Genau diese Eigenschaften machen Fußball zu einem idealen Testfall für quantitative Methoden, wie sie im Asset Management eingesetzt werden: probabilistische Modellierung statt Punktprognosen, Bewertung gegen einen effizienten Markt (Wettquoten), Positionsgrößenbestimmung unter Unsicherheit und rigorose Out-of-Sample-Validierung.

Das Projekt verfolgt zwei Ziele:

1. **Wissenschaftlich:** Ein methodisch sauberes, reproduzierbares Prognosesystem auf dem Stand der sportstatistischen Literatur [1, 2, 3, 4, 5].
2. **Praktisch:** Einsatz während der WM 2026 in zwei realen Entscheidungssituationen (frei wählbare Wetten; verpflichtende Kicktipp-Abgabe).

1.2 Leitprinzip: Trennung von Inferenz und Entscheidung

Das zentrale Designprinzip des Systems ist die strikte Trennung zweier Fragen, wobei die diskreten Zufallsvariablen $X \in \mathbb{N}_0$ und $Y \in \mathbb{N}_0$ die Anzahl der erzielten Tore des erstgenannten (Heim-) bzw. zweitgenannten (Gast-)Teams beschreiben:

1. *Was wird passieren?* Die Inferenz umfasst die Schätzung der gemeinsamen Verteilung $\mathbb{P}(X = x, Y = y)$ der Tore beider Teams (Schichten 1 und 2, Abschnitte 5–6).
2. *Was soll ich tun?* Die Entscheidung bezeichnet die Abbildung dieser Verteilung auf eine Handlung unter einer modusabhängigen Zielfunktion (Schicht 3, Abschnitte 8–9).

Beide Modi konsumieren *dieselbe* Wahrscheinlichkeitsmatrix. Unterschiede im Verhalten entstehen ausschließlich aus den Zielfunktionen, nicht aus unterschiedlichen Modellen. Ein zentraler methodischer Vorteil des Systemdesigns besteht darin, dass derselbe stochastische Kern auf zwei ökonomisch völlig verschiedene Probleme (diskretionäres Portfoliomanagement vs. Entscheidung unter Zwangsbedingungen) angewandt wird.

1.3 Capabilities: Was das System leisten muss

- C1. Für jedes Spiel eine vollständige, kalibrierte Torverteilung $\mathbb{P}(X = x, Y = y)$ der diskreten Zufallsvariablen für die Tore des Heimteams $X \in \mathbb{N}_0$ und des Gastteams $Y \in \mathbb{N}_0$ liefern. Daraus sind die Tendenzwahrscheinlichkeiten (Sieg, Remis, Niederlage), exakte Ergebnisse, Tordifferenzen sowie Over/Under-Märkte (Totals) abzuleiten.
- C2. Die Parameterunsicherheit aller Modellparameter quantifizieren und explizit über *Bayesian posterior distributions* abbilden. Das System gibt somit vollständige Wahrscheinlichkeitsverteilungen der Stärkeparameter aus, anstatt sich auf singuläre Punktschätzer (*Point Estimates*) zu beschränken.
- C3. Marktquoten einlesen, von der impliziten Gewinnmarge bereinigen und als wahre Wahrscheinlichkeiten sowohl als *Benchmark* als auch als *Feature* nutzen.
- C4. Modus A: Value-Wetten identifizieren. Unter Verwendung der vom Modell geschätzten Wahrscheinlichkeit des Spielausganges (p_{Modell}), der dezimalen Marktquote (o) und einer definierten Sicherheitsmarge ($\delta > 0$) geschieht dies über die Bedingung $p_{\text{Modell}} \cdot o > 1 + \delta$. Anschließend werden die Einsätze via fraktionalem Kelly-Kriterium bestimmt, Risiko-Nebenbedingungen eingehalten und explizit „keine Wette“ als gültige Handlung ermöglicht.

- C5. Modus [B1](#) und Modus [B2](#). Im Einzelspielerfall (Modus [B1](#)) wählt das System für jedes Spiel nicht zwingend das wahrscheinlichste Ergebnis, sondern berechnet exakt den Tipp, der nach den Regeln der Tipprunde (dem konfigurierbaren Punkteschema) im Durchschnitt die höchste Punktzahl liefert. Im Mehrspielerfall (Modus [B2](#)) maximiert es stattdessen die Platzierungswahrscheinlichkeit am Turnierende und wählt den Tipp risikoadjustiert in Abhängigkeit vom Punktrückstand und vom beobachteten Tippverhalten der Mitspieler.
- C6. Backtests über historische Turniere ohne Look-Ahead-Bias durchführen und alle Metriken aus Abschnitt [10](#) reproduzierbar berichten.
- C7. Spielphasen korrekt behandeln: In der *Gruppenphase* zählt das Ergebnis nach 90 Minuten, sodass ein Remis ein regulärer Ausgang ist. In der *K.o.-Phase* tippt die Zielrunde im Modus „nach Elfmeterschießen“. Wenn es nach 90 Minuten und Verlängerung unentschieden steht, entscheidet das Elfmeterschießen. Das System benötigt an dieser Stelle die Endergebnis-Verteilung aus Abschnitt [5.9](#) sowie die Weiterkommens-Wahrscheinlichkeiten für die Turniersimulation, die Bonusfragen und Outright-Wetten.

1.4 Explizite Nicht-Ziele (Scope-Abgrenzung)

Die folgenden, teils in frühen Brainstormings (u. a. extern vorgeschlagenen) Komponenten sind *bewusst* nicht Teil des Kernsystems, sondern dokumentiertes Future Work (Abschnitt [13](#)):

- **Hochfrequente Tick-by-Tick-Quotenhistorie (Betfair/Pinnacle):** Historische Tick-Daten sind kostenpflichtig bzw. für vergangene Turniere nicht mehr frei beschaffbar. Der Kern arbeitet mit Eröffnungs- und Schlussquoten (Open/Close), was für die CLV-Analyse (Abschnitt [10.5](#)) ausreicht.
- **Spieler-Belastungsdaten (Minuten in Vereinen):** als aggregiertes Feature in Phase 2 vorgesehen, nicht im Kern — die Beschaffung (Scraping) ist aufwendig und der dokumentierte Zusatznutzen in der Literatur gering gegenüber Marktwert-Proxies.
- **In-Play-/Live-Wetten:** Das System prognostiziert ausschließlich pre-match.

2 Mathematische Grundlagen

Die beiden Entscheidungsmodi greifen auf Resultate der Informationstheorie und der Entscheidungstheorie zurück, die hier kompakt bereitgestellt werden, bevor sie in der Problemformulierung verwendet werden. Im Zentrum von Modus [A](#) steht das Kellykriterium, das die Einsatzgröße über die Maximierung der erwarteten logarithmischen Wachstumsrate des Kapitals bestimmt.

Proposition 2.1 (Kellyoptimum im Binärfall). *Sei $o > 1$ eine dezimale Quote, $b = o - 1 > 0$ die zugehörige Nettoquote, $p \in (0, 1)$ die Gewinnwahrscheinlichkeit und $q = 1 - p$. Für einen Einsatzanteil $f \in [0, 1)$ bezeichne*

$$g(f) = p \ln(1 + bf) + q \ln(1 - f)$$

die erwartete logarithmische Wachstumsrate des Kapitals pro Wette. Dann ist g auf $[0, 1)$ strikt konkav und besitzt das eindeutige Maximum

$$f^* = \frac{bp - q}{b} = \frac{po - 1}{o - 1} \quad \text{falls } po > 1,$$

und $f^ = 0$ andernfalls.*

Beweis. Die erste Ableitung lautet $g'(f) = \frac{pb}{1+bf} - \frac{q}{1-f}$ und die zweite $g''(f) = -\frac{pb^2}{(1+bf)^2} - \frac{q}{(1-f)^2}$. Wegen $p, q > 0$ und $b > 0$ gilt $g''(f) < 0$ für alle $f \in [0, 1)$, womit g strikt konkav ist. Die Bedingung $g'(f) = 0$ ist äquivalent zu $pb(1 - f) = q(1 + bf)$. Umstellen unter Verwendung von

$p + q = 1$ liefert $f^* = (bp - q)/b$, und mit $o = b + 1$ folgt $bp - q = po - 1$. Im Fall $po \leq 1$ ist $g'(0) = pb - q \leq 0$, sodass g wegen der Konkavität auf $[0, 1)$ monoton fällt und das Maximum am Rand bei $f^* = 0$ angenommen wird. $\square$

Der Zähler $po - 1$ ist genau dann positiv, wenn die Wette einen positiven Erwartungswert besitzt. Dies motiviert die Valuebedingung aus Abschnitt 1.3 in der Form $p_{\text{Modell}} \cdot o > 1 + \delta$ als geschärfte Variante mit Sicherheitsmarge $\delta > 0$. Das Kellykriterium maximiert die fast sicher erreichte asymptotische Wachstumsrate des Vermögens über eine Folge unabhängiger Wetten [10, 11]. Die in Modus A verwendete Mehrausgangsformel aus Abschnitt 8 verallgemeinert dieses Resultat auf einen Markt mit mehreren sich gegenseitig ausschließenden Ausgängen und einem nicht investierten Restanteil. Sie entspricht dem logarithmisch optimalen Portfolio für ein Pferderennen im Sinne von Cover und Thomas [19]. Da die Zielfunktion eine Summe konkaver Logarithmen über einem konvexen Polytop bildet, bleibt das zugehörige Optimierungsproblem konvex und mit Standardverfahren eindeutig lösbar.

Bemerkung 2.1. *Volles Kelly ist berüchtigt volatil und reagiert überproportional empfindlich auf eine Überschätzung von p . Das System verwendet daher durchgängig fraktionales Kelly mit einer zusätzlichen Schrumpfung auf das untere Ende des bayesianischen Kreditibilitätsintervalls, was in Abschnitt 8 ausgeführt wird.*

2.1 Lernen unter vollständiger Information

Modus B2 schätzt das Tippverhalten der Mitspieler fortlaufend aus Beobachtungen. Nach jedem Spieltag werden das tatsächliche Ergebnis sowie die Tipps sämtlicher Mitspieler sichtbar, und da die Punktefunktion bekannt ist, lässt sich der Ertrag jeder möglichen eigenen Tippabgabe kontrafaktisch bestimmen. Dieses Szenario ist die Prädiktion mit Expertenrat im Sinne von Cesa-Bianchi und Lugosi [21], also Onlinelernen mit vollständiger Rückmeldung. Es unterscheidet sich grundlegend vom stochastischen Banditenproblem, in dem ausschließlich der Ertrag des gewählten Arms beobachtbar ist und Exploration deshalb unvermeidlich wird.

Die Abgrenzung ist quantitativ bedeutsam. Für K Aktionen und einen Horizont von n Runden besitzt der stochastische Bandit eine Minimaxschranke der Ordnung $\Omega(\sqrt{Kn})$ [20], deren Herleitung gerade die Kosten der Exploration bei unvollständiger Rückmeldung abbildet. Unter vollständiger Information sinkt die erreichbare Schranke auf die Ordnung $\Theta(\sqrt{n \log K})$. Bei $K = (X_{\max} + 1)^2$ Ergebniszellen ist dies eine exponentiell günstigere Abhängigkeit von der Aktionszahl, deren Ursache exakt der Wegfall der Explorationskosten ist. Aus diesem Grund modelliert das System die Gegnerschätzung als Verfahren der Regretminimierung unter vollständiger Information und nicht als Banditenalgorithmus. Der zeitlichen Instationarität des Tippverhaltens begegnet es durch Diskontierung älterer Beobachtungen, etwa über eine exponentielle Gewichtung oder ein gleitendes Fenster.

3 Problemformulierung

3.1 Notation

Sei $\mathcal{I}$ die endliche Menge aller betrachteten Teams und $\mathcal{M}$ die Menge aller Spiele. Für jedes Spiel $m \in \mathcal{M}$ bezeichne $i(m) \in \mathcal{I}$ das erstgenannte Team (Heimteam), $j(m) \in \mathcal{I}$ das zweitgenannte Team (Gastteam) und $t_m \in \mathbb{R}$ den Anpfiff-Zeitpunkt. Der Ausgang eines Spiels $m \in \mathcal{M}$ nach regulärer Spielzeit wird durch die diskreten Zufallsvariablen X_m und Y_m modelliert, wobei das Tupel (X_m, Y_m) Werte in $\mathbb{N}_0 \times \mathbb{N}_0$ annimmt. Dabei bezeichnen X_m und Y_m die Anzahl der erzielten Tore von Team $i(m)$ bzw. $j(m)$.

Wir verwenden im Folgenden die folgenden Notationen und Definitionen:

- $\mathcal{P}_m: \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow [0, 1]$ bezeichne die vom Modell geschätzte Wahrscheinlichkeitsfunktion für das Spiel m , definiert durch $\mathcal{P}_m(x, y) = \mathbb{P}(X_m = x, Y_m = y)$ für alle $x, y \in \mathbb{N}_0$. In der praktischen Implementierung wird die Wahrscheinlichkeitsfunktion bei einem endlichen Schwellenwert $X_{\max} \in \mathbb{N}$ rechnerisch zensiert, wobei die verbleibende Restmasse beider Ränder auf die zugehörigen Randzellen des Gitters $\{0, \dots, X_{\max}\}^2$ kumuliert wird, sodass etwa die Eckzelle $(X_{\max}, X_{\max})$ die gemeinsame Wahrscheinlichkeit $\mathbb{P}(X_m \geq X_{\max}, Y_m \geq X_{\max})$ trägt. Der Parameter $X_{\max}$ wird empirisch oder über ein Optimierungsverfahren so gewählt, dass der numerische Fehler für die Erwartungswertberechnung $\mathbb{E}[S]$ vernachlässigbar klein bleibt. Gleichzeitig garantiert der endliche Träger $\{0, \dots, X_{\max}\}^2$ eine effiziente algorithmische Auswertung unter exakter Erhaltung des Wahrscheinlichkeitsmaßes ($\sum_{x,y} \mathcal{P}_m(x, y) = 1$).
- $\pi_m = (\pi_m^{i(m)}, \pi_m^R, \pi_m^{j(m)})^T \in [0, 1]^3$ bezeichne den Vektor der drei Tendenzwahrscheinlichkeiten (Sieg von Team $i(m)$, Remis, Sieg von Team $j(m)$) für ein Spiel $m \in \mathcal{M}$. Da zwingend genau einer dieser drei Ausgänge eintreffen muss, summieren sich ihre Wahrscheinlichkeiten auf 1. Dieser Vektor wird abgeleitet, indem die Wahrscheinlichkeiten aller relevanten Einzelergebnisse (z. B. 1:0, 2:0, 2:1 für einen Sieg von Team $i(m)$) aus der Ergebnismatrix $\mathcal{P}_m$ aufaddiert werden.
- $o_m = (o_m^{i(m)}, o_m^R, o_m^{j(m)})^T \in [1, \infty)^3$ bezeichne den Vektor der dezimalen Marktquoten der Buchmacher für das Spiel m , aufgeteilt nach den Ausgängen Sieg von Team $i(m)$, Remis und Sieg von Team $j(m)$. Sei $q_m = (q_m^{i(m)}, q_m^R, q_m^{j(m)})^T \in [0, 1]^3$ der zugehörige Vektor der von der Buchmachermarge bereinigten Marktwahrscheinlichkeiten, deren Komponenten sich auf 1 summieren (Details siehe Abschnitt 7).
- $f_m = (f_m^{i(m)}, f_m^R, f_m^{j(m)})^T \in [0, f_{\max}]^3 \subset [0, 1]^3$ bezeichne den Einsatzvektor für das Spiel m , dessen Komponenten die relativen Anteile der aktuellen Bankroll $B_t \in \mathbb{R}_{>0}$ zum Zeitpunkt $t \in \mathbb{N}_0$ definieren, die auf die jeweiligen Tendenzen (Sieg von Team $i(m)$, Remis, Sieg von Team $j(m)$) gesetzt werden. Mit der Zustandsmenge der Tendenzen $\Omega_m = \{i(m), R, j(m)\}$ unterliegt der Vektor der Budgetrestriktion $\sum_{\omega \in \Omega_m} f_m^\omega \leq f_{\max}$, wobei $f_{\max} \in [0, 1]$ den maximal zulässigen Anteil der Bankroll für ein Einzelspiel limitiert.
- Sei $(\Omega, \mathcal{F}, \mathbb{P})$ der zugrundeliegende Wahrscheinlichkeitsraum, der alle möglichen Turnierverläufe abbildet, und $(\mathcal{F}_t)_{t \geq 0}$ eine darauf definierte Filtration, die den exakten Informationsstand zum Zeitpunkt t repräsentiert. Sämtliche Prognosen für ein Spiel $m \in \mathcal{M}$ müssen ausschließlich $\mathcal{F}_{t_m}$ -messbar sein (Zeitkausalität).

3.2 Die Entscheidungsprobleme

Modus A (Capital Allocator). Sei $\mathcal{M}$ die Menge aller Spiele. Sei $f_{\max} \in [0, 1]$ der maximal zulässige Anteil der Bankroll $B_t \in \mathbb{R}_{>0}$ für ein Spiel $m \in \mathcal{M}$. Gegeben seien der Quotenvektor $o_m = (o_m^{i(m)}, o_m^R, o_m^{j(m)})^T \in [1, \infty)^3$ und die Prognoseverteilung $\pi_m = (\pi_m^{i(m)}, \pi_m^R, \pi_m^{j(m)})^T \in [0, 1]^3$ mit $\|\pi_m\|_1 = 1$. Sei $\Omega_m = \{i(m), R, j(m)\}$ die Menge der drei möglichen Tendenzen und $Z_m \in \Omega_m$ die diskrete Zufallsvariable des tatsächlichen Spielausgangs mit $\mathbb{P}(Z_m = \omega) = \pi_m^\omega$. Der zulässige Aktionsraum der Einsatzvektoren ist definiert als

$$\mathcal{A}_m = \left\{ f = \left(f^{i(m)}, f^R, f^{j(m)} \right)^T \in [0, f_{\max}]^3 \subseteq [0, 1]^3 \left| \sum_{\omega \in \Omega_m} f^\omega \leq f_{\max} \right. \right\}.$$

Die Aufgabe besteht darin, den optimalen Vektor $f_m^* \in \mathcal{A}_m$ zu wählen, der das erwartete logarithmische Bankroll-Wachstum

$$f_m^* = \arg \max_{f_m \in \mathcal{A}_m} \mathbb{E} \left[\ln \left(1 + f_m^{Z_m} \cdot o_m^{Z_m} - \sum_{\omega \in \Omega_m} f_m^\omega \right) \right] = \arg \max_{f_m \in \mathcal{A}_m} \sum_{\omega \in \Omega_m} \pi_m^\omega \ln \left(1 + f_m^\omega \cdot o_m^\omega - \sum_{\nu \in \Omega_m} f_m^\nu \right)$$

maximiert (Abschnitt 8). Aufgrund der logarithmischen Nutzenfunktion ist die Optimierung skaleninvariant bezüglich des absoluten Kapitals B_t . Im Gegensatz zu positionsbezogenen Risiken

bei Turnieren (vgl. Modus B2) ist das Risiko hier strikt monetär. Die Aktionsmenge $\mathcal{A}_m$ schließt die Nullaktion $f_m = (0, 0, 0)$ explizit ein, welche das Kapital bei fehlendem positiven stochastischen Erwartungswert vor Erosion schützt und im Allgemeinfall die optimale Lösung darstellt.

Modus B1 (Kicktipp: Einzelspieler-Baseline). Sei $\mathcal{K} \subset \mathbb{N}_0$ die diskrete Menge der möglichen Punkterträge (hier $\mathcal{K} = \{0, 2, 3, 4\}$). Gegeben sei die auf den Träger $\{0, \dots, X_{\max}\}^2$ zensierte Wahrscheinlichkeitsfunktion $\mathcal{P}_m: \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow [0, 1]$ mit $\mathcal{P}_m(x, y) = \mathbb{P}(X_m = x, Y_m = y)$ sowie eine Punktfunktion $S: \mathbb{N}_0^2 \times \mathbb{N}_0^2 \rightarrow \mathcal{K}$. Die Punktfunktion S definiert für jedes tatsächliche Ergebnis $(x, y) \in \mathbb{N}_0^2$ und jeden gewählten Tipp $(x^*, y^*) \in \mathbb{N}_0^2$ den Punktertrag. Die Aufgabe besteht darin, exakt einen Tipp $(x^*, y^*) \in \{0, \dots, X_{\max}\}^2$ *verpflichtend* zu wählen, der den erwarteten Punktertrag

$$\mathbb{E}[S((X_m, Y_m), (x^*, y^*))] = \sum_{x=0}^{X_{\max}} \sum_{y=0}^{X_{\max}} \mathcal{P}_m(x, y) \cdot S((x, y), (x^*, y^*))$$

maximiert (Abschnitt 9). Es existiert weder eine Nullaktion noch zu allozierendes Kapital. Das Risiko ist nicht monetär, sondern positionsbezogen bezüglich des Ranges in der Tipprunde.

Modus B2 (Kicktipp: Mehrspieler-Dynamik). Sei $N \in \mathbb{N}$ die Anzahl der Teilnehmer. Dann gilt $R_t \in \mathbb{N}^N$. Der Vektor $R_t = (r_1, \dots, r_N)^T$ bildet den aktuellen Punktestand aller Teilnehmer zum Zeitpunkt $t \in \mathbb{N}_0$ ab. Sei $K = (X_{\max} + 1)^2$ die Anzahl der diskreten Ergebniszellen des Score-Gitters. Das *Gegnermodell* (Opponent Model) $C_m \in [0, 1]^K$ ist ein Wahrscheinlichkeitsvektor, dessen Komponenten die geschätzten Auftretenswahrscheinlichkeiten jedes möglichen Ergebnisses $(x, y) \in \{0, \dots, X_{\max}\}^2$ abbilden, normiert durch $\|C_m\|_1 = 1$.

In der kompetitiven Realität transformiert sich das Modell zu einem dynamischen, spieltheoretischen Optimierungsproblem. Die globale Zielfunktion verschiebt sich von der isolierten Punktemaximierung zur Maximierung der Sieg- bzw. Platzierungswahrscheinlichkeit am Turnierende $T \in \mathbb{N}_0$. Das Ziel ist die Maximierung des Erwartungswertes der Indikatorfunktion für den Turniersieg

$$\max \mathbb{E}[\mathbb{I}_{\{\text{Rang}_T=1\}}].$$

Im Gegensatz zur isolierten Einzelspieler-Baseline ist die optimale Entscheidungsfindung in Modus B2 kein statischer Prozess, sondern skaliert substanziell mit dem aktuellen Zustandsraum, namentlich dem Punkterückstand und dem verbleibenden Turnierhorizont $(T - t)$ (vgl. [17, 18]). Spieltheoretische Herleitungen mittels Rückwärtsinduktion zeigen, dass die auf Erwartungswertmaximierung basierende Strategie von Modus B1 in kompetitiven Umgebungen bei Abweichungen vom Idealverlauf nicht mehr das globale Optimum darstellt. Sobald der Punkterückstand das durch Modus B1 inhärent aufholbare Varianzpotential übersteigt, transformiert das System seine Strategie dynamisch. Zur Maximierung der Siegbedingung erfolgt bei Rückstand eine bewusste Reduktion der Korrelation zu C_m (*Contrarian Play*), während bei eigener Führung die Korrelation zu C_m maximiert wird (*Hedging*), um den relativen Vorsprung durch Konsenswahrung gegen stochastische Ausreißer zu immunisieren.

Die explizite Trennung zwischen der Einzelspieler-Baseline (Modus B1) und der Mehrspieler-Dynamik (Modus B2) ist auch dann mathematisch zwingend erforderlich, wenn das Teilnehmerfeld ausschließlich aus unstrategischen Gelegenheitsspielern besteht, die rein heuristisch oder intuitiv agieren. Die fundamentale Notwendigkeit dieser spieltheoretischen Erweiterung lässt sich durch drei stochastische Kernargumente formal begründen:

1. *Das Extremwert-Problem:* Das globale Optimierungsziel eines Turniers besteht nicht darin, den durchschnittlichen Mitspieler zu schlagen, sondern das Maximum der gegnerischen

Punkteverteilung zu übertreffen. Bei kurzen Turnierhorizonten (z. B. $|\mathcal{M}| = 51$ bei einer Europameisterschaft) und einer moderaten Teilnehmeranzahl führt die inhärente stochastische Varianz des Fußballs dazu, dass mit hoher Wahrscheinlichkeit mindestens ein Gelegenheitsspieler durch rein zufällige Kumulation von Extremereignissen eine exzeptionell hohe Punktzahl erreicht. Modus B1 agiert aufgrund der reinen Erwartungswertmaximierung inhärent konservativ und stark favoritenlastig. Liegt das System im späten Turnierverlauf im Rückstand, reicht die verbleibende Varianz von Modus B1 mathematisch nicht aus, um diesen statistischen Ausreißer zu kompensieren.

2. *Die Verwässerung des Grenzertrags (Payoff Dilution):* Unstrategische Spieler verhalten sich keineswegs stochastisch unkorreliert, sondern unterliegen systematischen kognitiven Verzerrungen (z. B. Favoriten- oder Heimat-Bias). Diese systemischen Verzerrungen manifestieren sich in einer Konzentration der Tipp-Dichte C_m auf bestimmte Ergebnisse. Deklariert Modus B1 beispielsweise ein 2 : 1 als das Ergebnis mit dem höchsten Erwartungswert, so wird dieses Ergebnis aufgrund der identischen Heuristiken im Teilnehmerfeld in der Verteilung C_m eine hohe Dichte aufweisen. Tritt dieses Ergebnis tatsächlich ein, so wird eine große Anzahl an Mitspielern denselben Punktertrag erzielen; der erwartete Punkterückstand zur Spitze bleibt somit konstant. Dies reduziert die Möglichkeit, die Lücke zu schließen, auf seltene stochastische Zufallstreffer statt auf strategische Überlegenheit. Modus B2 löst dieses Defizit, indem er gezielt suboptimale Ergebnisse mit niedrigerem isolierten Erwartungswert, aber signifikant höherer strategischer Divergenz relativ zur Tipp-Dichte C_m wählt.
3. *Adaptives Lernen des Gegnermodells.* Das Gegnermodell C_m operiert losgelöst von der Annahme rationaler Agenten und schätzt die systematischen Verzerrungen des Teilnehmerfeldes wie Favoritenneigung, Heimatneigung und die mit wachsendem Rückstand zunehmende Varianzsuche fortlaufend aus den nach jedem Spieltag vollständig beobachtbaren Tipps. Formal ist dies eine Regretminimierung unter vollständiger Information und kein stochastisches Banditenproblem, wie in Abschnitt 2.1 ausgeführt wird. Die mathematische Überlegenheit von Modus B2 resultiert somit nicht aus der Vorhersage einer fixen Rationalität, sondern aus der laufenden Monetarisierung informationeller Ineffizienzen, indem das System systematische Fehlallokationen des Kollektivs identifiziert und in einem dynamischen Optimierungsprozess zur Maximierung der Siegwahrscheinlichkeit ausnutzt. Da die Schätzung der Tippdichte C_m über ein kurzes Turnier teils hohem Schätzrauschen unterliegt, wird der tatsächliche Edge von Modus B2 im Backtest explizit gegen Modus B1 evaluiert und mit statistischen Konfidenzbändern ausgewiesen.

Strategische Adaption des Risiko-Ertrag-Verhältnisses. Die Divergenz von der Baseline-Strategie B1 hin zu einer spieltheoretischen Strategie in Modus B2 erfolgt nicht unkontrolliert. Es handelt sich um ein stetiges Optimierungsproblem, das den Erwartungswert $\mathbb{E}[S]$ als *Constraint* (Nebenbedingung) behandelt. Sei $s \in \{1, \dots, N\}$ der Index des eigenen Systems und bezeichne $r_{k,t}$ für einen Teilnehmer $k \in \{1, \dots, N\}$ dessen aktuellen Punktstand, also den Eintrag k des Vektors der Punktstände $R_t \in \mathbb{N}^N$. Der Rückstand des eigenen Systems zur Führung zum Zeitpunkt t ist dann

$$\Delta_t = \max_{k \in \{1, \dots, N\}} r_{k,t} - r_{s,t}.$$

Das System maximiert die Gewinnwahrscheinlichkeit $\mathbb{P}(\text{Rang}_T = 1)$ unter der Nebenbedingung, dass der erwartete Punktertrag $\mathbb{E}[S]$ nicht unter ein kritisches Niveau $\tau \in \mathbb{R}$ fällt, das vom aktuellen Punktrückstand Δ_t und der verbleibenden Turnierlänge $T - t$ abhängt.

$$(x^*, y^*)_{B2} = \arg \max_{(x^*, y^*) \in \{0, \dots, X_{\max}\}^2} \mathbb{P}(\text{Rang}_T = 1 \mid x^*, y^*, \Delta_t, C_m) \quad \text{u.d.N.} \quad \mathbb{E}[S] \geq \tau(\Delta_t, T - t)$$

Die bedingte Wahrscheinlichkeit $\mathbb{P}(\text{Rang}_T = 1 \mid \cdot)$ ist dabei kein myopischer Ausdruck über lediglich das aktuelle Spiel. Sie wird über die vollständige Monte Carlo Turniersimulation aus

Abschnitt 6 ausgewertet, welche alle verbleibenden Spiele unter dem Gegnermodell C_m ausrollt und die eigenen künftigen Tipps gemäß derselben Politik wählt. Auf diese Weise geht der Fortsetzungswert der Rückwärtsinduktion in die Bewertung des aktuellen Tipps ein. Diese Formulierung stellt sicher, dass das System niemals äußerst unwahrscheinliche oder punktemäßig ineffiziente Ergebnisse wählt, sondern ausschließlich solche, die eine mathematisch begründete Wahrscheinlichkeit für eine erfolgreiche Aufholjagd bei gleichzeitig vertretbarem punktetechnischen Erwartungswert bieten. Das System wählt somit einen *risikoadjustierten* Tipp, der das Risiko des Punktverlustes gegen die Opportunität des Turniergewinns abwägt.

Bemerkung 3.1 (Warum die Modi nicht ineinander überführbar sind). *Modus A optimiert die absolute Wachstumsrate des Kapitals gegenüber einem Marktmechanismus. Diese Zielsetzung ist disjunkt zu Modus B1, da dieser ausschließlich den Erwartungswert der Punkte maximiert und dabei weder Wettquoten noch Kapitalallokation adressiert. Eine Überführbarkeit scheitert hier an der fundamentalen Differenz zwischen der Maximierung von Prognosegüte (B1) und der Ausnutzung von Marktineffizienzen (A). Eine Äquivalenz zu Modus B2 ist ebenfalls ausgeschlossen, da dieser den relativen Rang in einem kompetitiven Umfeld maximiert. Strategien aus Modus A sind in Modus B2 suboptimal, da sie die strategische Interaktion mit Mitspielern sowie die Dynamik des Turnierverlaufs ignorieren, während B2 hingegen die individuellen Marktquoten aus A ignoriert. Zusammenfassend adressiert Modus A Kapitalmärkte, Modus B1 reine Statistik und Modus B2 spieltheoretischen Wettbewerb.*

4 Datenarchitektur

4.1 Kanonisches Datenmodell

Alle Quellen werden in ein kanonisches Match-Schema überführt (ein Datensatz pro Spiel):

Feld	Typ	Beschreibung
match_id	str	deterministischer Hash aus Datum + Teams
date	date	Spieltag (Kalenderdatum)
team_home/away	str	kanonisch normalisierte Teamnamen (Mapping <code>former_names.csv</code>)
goals_home/away	int	Tore nach 90 Min.
goals_home/away_aet	int?	Tore nach Verlängerung (falls K.o.)
penalty_winner	str?	Sieger Elfmeterschießen (falls)
tournament	enum	WM, EM, Quali, Freundschaftsspiel, ...
stage	enum	Gruppe, Achtelfinale, ... (gejoint, nur Turniere)
neutral	bool	neutraler Spielort
host_home/away	bool	Team ist Gastgeber des Turniers
city, country	str	Spielort (für Reise-/Höhenfeatures)
elo_home/away	float	Elo-Rating <i>zum Stichtag vor</i> dem Spiel
odds_open/close	float ³	Marktquoten 1X2 (sofern verfügbar)

Annahme 4.1 (Zeitstempel-Disziplin). *Jedes abgeleitete Feature (Elo, Form, Marktwert) trägt einen Gültigkeits-Zeitstempel und wird ausschließlich mit Informationsstand vor Anpfiff berechnet. Dies wird technisch erzwungen, nicht nur konventionell vereinbart (Abschnitt 10.1).*

4.2 Datenquellen und Priorisierung

Daten	Quelle	Kosten	Prio	Verwendung
Ergebnisse und Ratings				

Daten	Quelle	Kosten	Prio	Verwendung
Länderspiele seit 1872 (Ergebnis, Ort, Turnier)	Kaggle „International football results“ (martj42)	frei	P0	Modelltraining
Elo Nationalteams, zeitkausal pro Spiel	eigene Engine aus Ergebnissen nach eloratings.net Methodik	frei	P0	Feature, Baseline
Elo Live Snapshot	eloratings.net	frei	P1	Quervalidierung
FIFA Ranking 1992 bis 2024	Kaggle Archive	frei	P1	Feature
SPI Ratings und Matchprognosen 2016 bis 2023	FiveThirtyEight (spi_matches_intl.csv)	frei	P2	Benchmark und Feature
Club Elo tagesgenau 2000 bis 2026	clubelo.com	frei	P2	Vereinsmodell
Quoten				
Turnierquoten 1X2 Nationalteams 2005 bis 2016 (Closing, EM 2016 Open und Close)	Beat The Bookie	frei	P0 ^(A)	Backtest Modus A, Benchmark
Turnierquoten 1X2 WM, EM, Copa 2018 bis 2024	FootyStats (c-dl.php)	frei	P0 ^(A)	Backtest Modus A (Test Set)
Vereinsliga Quoten 1X2, Open ab 2002, Close ab 2012/13, Historie ab 1993/94	football-data.co.uk	frei	P0 ^(A)	Modus A Proof of Concept
UEFA Klubquoten 2005 bis 2016 (Closing, Open und Close)	Beat The Bookie	frei	P2	Eurocup Backtest
Quoten live WM 2026	The Odds API (Free Tier)	frei	P0 ^(A)	Betrieb Modus A
Eurocup und Bundesliga				
UEFA Klubwettbewerbe Ergebnisse 1955 bis 2026 (rund 28000)	Kaggle (rtx666x3)	frei	P2	Klubstärke Kontext
Club Football Engineered 2000 bis 2025 (230000 Spiele mit Elo, Form, Quoten)	Kaggle (adamgbor)	frei	P2	Referenz und Klubmodell
OpenLigaDB BL1 und BL2 2010 bis 2025 mit Tor Timelines	OpenLigaDB	frei	P2	minutengenaue Features
European Soccer Database 2008 bis 2016 (Aufstellungen, FIFA Attribute)	Kaggle	frei	P2	schliesst xG Luecke EM 2016
Spieler und Kader				
Kader Marktwerte Nationalteams	Transfermarkt Mirror	frei (ToS)	P1	Stärke Prior (log Skala)
Spielerbelastung (Verweinsminuten je Spiel)	Kaggle player-scores (appearances)	frei	P2	Phase 2
Verletzungshistorie und Verfügbarkeit	Transfermarkt via worldfootballR, Kaggle Mirror	frei (ToS)	P3	Verfügbarkeit von Schlüsselspielern

Daten	Quelle	Kosten	Prio	Verwendung
Spieler Athletik FIFA 15 bis FC 26, alle Jahrgänge	Kaggle EA FC und so-fifa	frei	P2	Phase 2
Football Manager Datenbanken (FM17, FM20, FM21, FM23)	Community Mirrors	frei	P2	Attribut Tiefe
xG Turnierspiele 2018 bis 2024	StatsBomb Open Data	frei	P2	Phase 2
Aufstellungen Turnierspiele	StatsBomb Open Data	frei	P2	HHI, Legionäre
Kaderlisten und Spieler-ratings je Turnier	FootyStats (type=players)	frei	P2	HHI, Legionäre
Internationale xG ab 2018	FBref (Opta) via soccerdata	frei (ToS)	P3	xG vor StatsBomb Abdeckung
Wyscout Event Daten (Pappalardo, rund 520 MB)	Figshare	frei	P3	eigenes xG Modell (Future Work)
Kontext und alternative Signale				
Trainerhistorie National-teams	Wikidata SPARQL	frei	P2	Trainerwechsel Indikator
WM 2026 Base Camps	Wikipedia	frei	P2	Reise und Akklimatisierung
Anstoss Wetter je Turnierspiel	Open-Meteo Archiv	frei	P2	Klima Features
Höhenlage der Spielorte	Open-Meteo Elevation	frei	P2	Altitude Kovariate
Geokoordinaten und Zeitzonen	Open-Meteo Geocoding	frei	P2	Reisedistanz, Jetlag
Schiedsrichterprofile (Karten und Elfmeterdaten)	abgeleitet aus Match Daten	frei	P2	Tiebreaker Heuristik, Bias
Wikipedia Pageviews	Wikimedia REST API	frei	P3	Aufmerksamkeits Proxy
Prediction Markets (Polymarket, Manifold)	oeffentliche APIs	frei	P3	Markt Quervalidierung
News Tonalität	GDELT DOC API	frei	P3	Stimmungs Proxy (Lauf ausstehend)
Suchinteresse Google Trends	pytrends bzw. offizielle Alpha API	frei	P3	Aufmerksamkeit, Beschaffung fragil
Strukturierte Ergebnisse und Kaderlisten	openfootball, foot-ball.db (CC0)	frei	P3	Quervalidierung

P0 ist Pflicht für den Kern. Das Kuerzel ^(A) markiert eine Pflicht nur für Modus A. P1 ist stark erwünscht. P2 ist optional bzw. Phase 2. P3 ist explorativ bzw. Future Work.

4.3 Datenqualität und bekannte Probleme

- **Teamnamen-Normalisierung:** historische Umbenennungen und Rechtsnachfolgen (UdSSR→Russland, Jugoslawien→Serbien, Tschechoslowakei) werden über eine explizite Mapping-Tabelle mit Gültigkeitszeiträumen behandelt.
- **Verlängerungstore:** Quelldatensätze mischen teils 90-Minuten- und 120-Minuten-Ergebnisse. Für K.o.-Spiele werden *beide* Ergebnisse rekonstruiert (90 Minuten und Endstand inkl. Verlängerung samt Elfmeter-Sieger): Die Zielrunde wertet nach Elfmeterschießen (Abschnitt 9.1), Backtests anderer Schemata und das Modelltraining benötigen die 90-Minuten-Basis.
- **Quoten-Survivorship (Turniere):** Für ältere Turniere existieren Quoten nur von wenigen Buchmachern; wir dokumentieren pro Turnier die Abdeckung und rechnen ROI-Backtests

nur auf Spielen mit belegten Quoten.

- **Zusammengesetzte Turnierquoten-Basis:** Da keine einzelne freie Quelle alle Zielturniere abdeckt, wird die Turnierquoten-Basis aus drei Quellen zusammengesetzt: (i) der Beat-The-Bookie-Datensatz liefert Closing-Quoten für Senior-Nationalmannschaftsspiele 2005–2015 (u. a. WM 2006/2010/2014, EM 2008/2012) sowie — aus den Quoten-Zeitreihen der Serie B — Opening- und Closing-Quoten für 2016 inkl. der kompletten EM 2016; (ii) FootyStats liefert pre-match 1X2-Quoten für die jüngeren Turniere (WM 2018/2022, EM 2021/2024, Copa 2019/2021/2024); (iii) das WorldCup-Workbook von football-data.co.uk dient als Quervervalidierung für WM 2014–2022 und liefert die 2026er-Qualifikation. Die Quellen unterscheiden sich in Quotentyp (Closing vs. pre-match) und Buchmacher-Aggregation; die Heterogenität wird im Backtest-Bericht je Turnier ausgewiesen, und CLV-Analysen sind nur auf der Open/Close-belegten Teilmenge zulässig.
- **Quoten-Abdeckung football-data.co.uk:** Diese Quelle deckt ausschließlich nationale *Vereinsligen* ab, *keine* WM-/EM-Turnierspiele. Open-Quoten (1X2) liegen für die Topligen ab ~2002/03 vor, Closing-Quoten (inkl. Pinnacle, nötig für CLV) erst ab 2012/13 (schottische Unterligen ab 2016/17). Modus A wird daher zunächst auf Vereinsligen 2012/13–heute als Proof-of-Concept validiert (exzellente, reichhaltige Quoten-Coverage, Heimat des Dixon-Coles-Modells); die Turnier-Backtests laufen separat auf der dünneren, aber zielrelevanten Turnierquoten-Basis.
- **Freundschaftsspiele:** systematisch geringere Intensität (Rotation); sie erhalten im Modell ein eigenes Wettbewerbsgewicht (Abschnitt 5.2).

4.4 Abgeleitete Merkmalsdatensätze

Aus den vorhandenen Rohdaten werden mehrere Datensätze *generiert*, die latentes Signal sichtbar machen, das in keiner Einzelquelle direkt steht. Jeder entsteht durch ein reproduzierbares Skript der Standardbibliothek und liegt unter `Data/Custom_Data`. Wo sie als Merkmal dienen, sind sie strikt zeitkausal berechnet. Sie gelten als Hypothesen und gehen erst dann in den Kern ein, wenn sie im zeitkausalen Backtest out of sample einen Mehrwert belegen (Abschnitt 10).

- **Konföderationskalibrierung.** Aus den interkontinentalen Spielen wird je Konföderation ein Elo Offset geschätzt, der die schwach identifizierte Niveaurelation zwischen den Konföderationen korrigiert. Der Befund ist deutlich, denn das Elo überschätzt sämtliche Konföderationen außer UEFA und CONMEBOL (`confederation_elo_offsets.csv`).
- **Form und Finishing Residuen.** Tatsächliche Punktausbeute minus Elo Erwartung sowie Tore minus Expected Goals, jeweils als vor dem Spiel bekannter gleitender Mittelwert (`elo_form_residuals.csv`, `xg_finishing_residuals.csv`).
- **Reise und Höhenlast der WM 2026.** Je Team die kumulierten Reisekilometer, Zeitzonensprünge und Höhenmeter über den Gruppenspielplan (`wc2026_team_burden_summary.csv`).
- **Linienbewegung und Closing Line Value.** Drift der entvigten Wahrscheinlichkeiten von der Eröffnung zur Schlussquote als Proxy für informierten Geldfluss. In allen geprüften Ligen ist die Schlusslinie schärfer als die Eröffnung (`line_movement_clv.csv`).
- **Crowd Tip Prior.** Eine nach Favoritenstärke bedingte Verteilung über Ergebnistipps als Startwert für das Gegnermodell C_m in Modus B2, bevor Live Tipps vorliegen (`crowd_tip_prior_by_band.csv`).

5 Schicht 1: Das stochastische Modell

5.1 Basismodell: unabhängige Poisson-Zählprozesse

Als Ausgangspunkt für die stochastische Modellierung dient der Ansatz von Maher [1]. Für ein fixiertes Spiel $m \in \mathcal{M}$ zwischen dem Heimteam $i = i(m)$ und dem Gastteam $j = j(m)$ nehmen wir an, dass die Zufallsvariablen X_m und Y_m bedingt unabhängig und Poisson-verteilt sind. Das heißt, es existieren deterministische Intensitätsparameter $\lambda_m > 0$ und $\mu_m > 0$, sodass für alle

$x, y \in \mathbb{N}_0$ gilt:

$$\mathbb{P}(X_m = x, Y_m = y) = \frac{\lambda_m^x e^{-\lambda_m}}{x!} \cdot \frac{\mu_m^y e^{-\mu_m}}{y!}. \quad (1)$$

Die erwarteten Tor-Intensitäten λ_m und μ_m werden als log-lineare Funktionen der latenten Teamstärken modelliert. Für jedes Team $k \in \mathcal{I}$ seien $\alpha_k \in \mathbb{R}$ die Angriffsstärke und $\beta_k \in \mathbb{R}$ die Verteidigungsstärke. Es gilt

$$\log \lambda_m = \gamma + \alpha_i - \beta_j + \eta \cdot h_m, \quad \log \mu_m = \gamma + \alpha_j - \beta_i, \quad (2)$$

wobei $\gamma \in \mathbb{R}$ einen globalen Niveau-Parameter (die Basis-Torfrequenz) darstellt und $h_m \in \{0, 1\}$ ein Indikator für einen eventuellen Heimvorteil des Teams i im Spiel m ist. Um die formale Identifizierbarkeit des Parametervektors sicherzustellen, werden zusätzlich die linearen Nebenbedingungen $\sum_{k \in \mathcal{I}} \alpha_k = 0$ und $\sum_{k \in \mathcal{I}} \beta_k = 0$ gefordert.

Spielstätten-Effekte und geografische Belastung. Die erwartete Tor-Intensität wird durch spezifische Kovariaten modifiziert:

- **Regulärer Heimvorteil (h):** In Qualifikationsspielen existiert ein starker Heimvorteil.
- **Host-Effekt (η_{host}):** Bei Turnieren gibt es keinen regulären Heimvorteil (neutraler Boden), aber der Gastgeber profitiert von Fanunterstützung und vertrautem Klima. Dieser Effekt ist historisch stark, aber schwächer als der reguläre Vereinsheimvorteil [25, 26]. Bei Turnieren mit mehreren Gastgebern wird der Effekt granular vergeben.
- **Höhenlage (Altitude):** Ein massiver Faktor bei mittelamerikanischen Spielen. Teams aus dem Flachland verzeichnen hier einen signifikanten Leistungsabfall durch messbare physiologische Ermüdung [27].
- **Reisedistanz & Zeitzonen:** Extreme Distanzen führen zu Jetlag und verlorenen Trainingstagen [28], was als dämpfende Kovariate in die Intensitätsgleichung einfließt. Um eine Parameterinflation und ein Überanpassungsrisiko auf den relativ dünnen Länderspieldaten zu vermeiden, wird für all diese Kovariaten eine sparsame Grundspezifikation erzwungen. Jeder Zusatzterm muss seinen Mehrwert zwingend in einer Ablationsstudie außerhalb der Stichprobe belegen, andernfalls entfällt er.

5.2 Dixon-Coles-Korrektur und Zeitgewichtung

Empirisch weichen niedrige Ergebnisse (0:0, 1:1, 1:0, 0:1) von der Unabhängigkeitsannahme ab. Dixon und Coles [2] korrigieren mit dem Faktor τ :

$$\mathbb{P}(X = x, Y = y) = \tau_{\lambda, \mu}(x, y) \frac{\lambda^x e^{-\lambda}}{x!} \frac{\mu^y e^{-\mu}}{y!}, \quad \tau_{\lambda, \mu}(x, y) = \begin{cases} 1 - \lambda\mu\rho & (x, y) = (0, 0) \\ 1 + \lambda\rho & (x, y) = (0, 1) \\ 1 + \mu\rho & (x, y) = (1, 0) \\ 1 - \rho & (x, y) = (1, 1) \\ 1 & \text{sonst,} \end{cases} \quad (3)$$

mit Abhängigkeitsparameter ρ (typisch leicht negativ). Damit alle Zellwahrscheinlichkeiten nichtnegativ bleiben, ist ρ auf den Bereich $\max(-1/\lambda, -1/\mu) \leq \rho \leq \min(1/(\lambda\mu), 1)$ beschränkt. Die Parameterschätzung maximiert die zeitgewichtete Log-Likelihood

$$\ell(\theta; t) = \sum_{m: t_m < t} \omega(t - t_m) \cdot w_{c(m)} \cdot \log \mathbb{P}_{\theta}(X_m = x_m, Y_m = y_m), \quad \omega(\Delta t) = e^{-\xi \Delta t}, \quad (4)$$

wobei $\xi > 0$ die Zerfallsrate der Zeitgewichtung festlegt (je weiter das Spiel in der Vergangenheit liegt, desto näher rückt das Gewicht an 0). Der Parameter $w_{c(m)}$ bestimmt als *Wettbewerbsgewichtung* die sportliche Aussagekraft des Ergebnisses:

- **Tier 1 (Faktor 1,0):** WM- und EM-Endrundenspiele, Copa América (beste A-Kader, 100 % Einsatz).
- **Tier 2 (Faktor $\sim 0,7-0,8$):** Kontinentale Qualifikationsspiele (WM-Quali, EM-Quali).
- **Tier 3 (Faktor $\sim 0,5-0,6$):** UEFA Nations League (oft kompetitiv, aber experimenteller).
- **Tier 4 (Faktor $\sim 0,2-0,3$):** Offizielle Freundschaftsspiele (extreme Rotation, Taktiktests).

Diese Likelihood-Gewichte (ξ und $w_{c(m)}$) skalieren direkt den Einfluss eines historischen Spiels im Training und werden *nicht* in-sample gefittet, sondern per zeitkausaler Kreuzvalidierung optimiert.

5.3 Alternative Kopplung und Überdispersion

Als erste Robustheits-Variante implementieren wir Karlis/Ntzoufras [3]: $X = Z_1 + Z_3$, $Y = Z_2 + Z_3$ mit unabhängigen $Z_k \sim \text{Poisson}(\lambda_k)$, sodass $\text{Cov}(X, Y) = \lambda_3 > 0$.

Behandlung der Überdispersion via diskreter Copula. Die Poisson-Verteilung erzwingt $\text{Var}(X) = \mathbb{E}[X] = \lambda$. Um die bei extremen Leistungsunterschieden auftretende empirische Überdispersion ($\text{Var}(X) > \mathbb{E}[X]$) abzufangen, dürfen die Randverteilungen nicht naiv mit der Dixon-Coles-Korrektur τ multipliziert werden, da diese exakt für Poisson-Ränder hergeleitet ist und sonst die Wahrscheinlichkeitsmasse verfälscht.

Wir formulieren die Bivariatät stattdessen über das Theorem von Sklar [23] für diskrete Verteilungen, unter bewusster Beachtung des Eindeutigkeitsproblems der Copula bei Zähldaten [24]. Seien $F_X(x)$ und $F_Y(y)$ die kumulativen Verteilungsfunktionen der marginalen Negativbinomialmodelle (inklusive Dispersionsparameter α_{disp}). Die finale Modellauswahl zwischen dieser Copulavariante, der Korrektur von Dixon und Coles und der geteilten Komponente nach Karlis und Ntzoufras erfolgt strikt außerhalb der Stichprobe. Die gemeinsame Verteilung wird über eine Copula C_θ (z. B. die Frank-Copula, die sowohl positive als auch negative Abhängigkeit zulässt) gekoppelt:

$$\mathbb{P}(X \leq x, Y \leq y) = C_\theta(F_X(x), F_Y(y)). \quad (5)$$

Die exakten Zellwahrscheinlichkeiten der Ergebnismatrix ergeben sich durch endliche Differenzierung auf dem diskreten Gitter:

$$\mathbb{P}(X = x, Y = y) = C_\theta(u_x, v_y) - C_\theta(u_{x-1}, v_y) - C_\theta(u_x, v_{y-1}) + C_\theta(u_{x-1}, v_{y-1}), \quad (6)$$

mit $u_x = F_X(x)$ und $v_y = F_Y(y)$. Dies garantiert $\sum_{x,y} \mathcal{P}_m(x, y) = 1$ bei exaktem Erhalt der überdispersen Randmomente. Der formale Modellvergleich gegen das klassische Dixon-Coles-Modell erfolgt out-of-sample primär über den Log-Loss auf der vollen Ergebnismatrix.

5.4 Dynamische Teamstärken: Zustandsraum-Formulierung

Statische α, β sind für ein Turnier-Setting unzureichend (Generationenwechsel, Trainereffekte). Wir modellieren die Stärken als latente Random-Walk-Prozesse [4, 5]:

$$\alpha_{k,t+1} = \alpha_{k,t} + \varepsilon_{k,t}^\alpha, \quad \varepsilon_{k,t}^\alpha \sim \mathcal{N}(0, \sigma_\alpha^2), \quad \beta_{k,t+1} = \beta_{k,t} + \varepsilon_{k,t}^\beta, \quad \varepsilon_{k,t}^\beta \sim \mathcal{N}(0, \sigma_\beta^2), \quad (7)$$

mit Beobachtungsgleichung (2).

Heteroskedastische Innovationsvarianz. Empirisch ist der Stärkedrift nicht homoskedastisch. Teams im Umbruch (neuer Trainer, hoher Anteil an Debütanten) weisen eine höhere kurzfristige Volatilität auf. Das System erweitert den Random Walk daher um einen parametrisierten, zeitvariablen Varianzprozess:

$$\log \sigma_{\alpha,k,t}^2 = w_0 + w_1 \cdot V_{k,t}^{\text{Alter}} + w_2 \cdot I_{k,t}^{\text{Trainer}}, \quad (8)$$

wobei V^{Alter} die Altersvarianz des Kaders und $I^{\text{Trainer}} \in \{0, 1\}$ ein Indikator für einen kürzlichen Trainerwechsel ist. Im bayesianischen Netz (Stufe 2) führt eine situativ erhöhte Innovationsvarianz

automatisch zu einem breiteren Posterior für Team k , was später in Schicht 3 (Abschnitt 8.3) durch das Unsicherheits-Shrinkage völlig autonom zu reduzierten Wetteinsätzen führt.

Die Innovationsvarianzen $\sigma_\alpha^2, \sigma_\beta^2$ kontrollieren, wie schnell Stärken driften dürfen.

Implementierungsentscheidung. Die exakte Filterung (Partikelfilter) ist möglich, aber für den Kern wählen wir die pragmatische Hierarchie:

1. **Stufe 1 (Kern):** Dixon-Coles mit exponentieller Zeitgewichtung (4) — approximiert die Dynamik und ist in Minuten schätzbar.
2. **Stufe 2 (Kern):** Bayesianisches hierarchisches Modell (Abschnitt 5.5) mit Random-Walk-Prior auf Turnier-Zyklus-Ebene (Stützstellen alle 2 Jahre statt pro Spiel) — voller Posterior in PyMC/NumPyro in vertretbarer Rechenzeit.
3. **Stufe 3 (Future Work):** kontinuierlicher Partikelfilter.

5.5 Bayesianische Hierarchie: das Sparse-Data-Problem der Nationalteams

Nationalteams spielen ~ 10 Spiele pro Jahr, oft gegen Gegner derselben Konföderation. Daraus folgen zwei Kernprobleme: (a) große Parameterunsicherheit pro Team, (b) schwache Identifikation der *interkonföderalen* Stärkerelationen (UEFA vs. CONMEBOL vs. AFC vs. CAF vs. CONCACAF vs. OFC) — ausgerechnet die Relation, die bei einer WM entscheidend ist.

Wir adressieren beides mit partieller Pooling-Struktur:

$$\alpha_k \sim \mathcal{N}(\mu_{\text{conf}(k)}^\alpha + \psi \cdot \log \widetilde{MV}_k, \sigma_{\text{team}}^2), \quad \mu_c^\alpha \sim \mathcal{N}(0, \sigma_{\text{conf}}^2), \quad (9)$$

analog für β_k . Hier ist $\widetilde{MV}_k$ der (zeitgestempelte, normierte) Kader-Marktwert als Stärke-Prior und ψ der zugehörige Gewichtungskoeffizient (das Symbol δ ist der Value-Marge in Abschnitt 8 vorbehalten): Teams mit wenigen Beobachtungen werden zum Konföderations-Mittel plus Marktwert-Signal geschrumpft statt zu Null. Interkonföderale Spiele (WM-Endrunden, Freundschaftsspiele, Confed-/Continental-Playoffs) identifizieren die μ_c^α -Ebene.

Inferenz. Hamiltonian Monte Carlo (NUTS) via PyMC oder NumPyro; Konvergenzdiagnostik über $\hat{R} < 1,01$ und effektive Stichproben; Posterior Predictive Checks gegen empirische Tor-Histogramme.

Nutzen des Posteriors. Die Parameterunsicherheit wird *durchgereicht*: Die Ergebnismatrix $\mathcal{P}_m$ entsteht als Posterior-Mittel über die prädiktive Verteilung, und für Modus A steht zusätzlich die Verteilung von p_{Modell} selbst zur Verfügung — ein Edge, der nur unter günstigen Parameterausprägungen existiert, rechtfertigt kleinere Einsätze (Abschnitt 8.3).

5.6 Regimewechsel und turnierspezifische Strukturbrüche

Die in Abschnitt 5.4 definierte Zustandsraum-Modellierung fängt graduellen Formdrift ab. Turnier-Settings weisen jedoch abrupte, diskrete Strukturbrüche auf, die das System wie folgt berücksichtigt:

- a) **Das WM-2026-Format als struktureller Bruch und Tie-Breaker-Stochastik (Punkt 3):** Die Erweiterung auf 48 Teams (12 Vierergruppen, Einzug der acht besten Gruppendritten, K.o.-Baum mit 32 Teams) verändert Anreizstruktur und Weiterkommens-Wahrscheinlichkeiten gegenüber allen Turnieren des Validierungszeitraums (2014–2024). Behandlung: Die Monte-Carlo-Turniersimulation (Abschnitt 6) implementiert das 2026er-Reglement exakt (Gruppen-Tiebreaker, Ranking der Gruppendritten, neuer K.o.-Baum); die Prognose einzelner Spiele ist davon unberührt, da formatunabhängig. Zudem führt der teamübergreifende Vergleich der Gruppendritten bei Punkt- und Torgleichstand zu stochastischen Grenzfällen (Fair-Play-Wertung nach Karten bzw. Losentscheid). Da das Poisson-Tormodell keine Karten simuliert,

implementiert die Monte-Carlo-Engine für diese Patt-Situationen eine statistische Heuristik (historische Karten-Basisraten je Konföderation) kombiniert mit einem gesäten Zufallsentscheid (Pseudozufall), um einen reproduzierbaren Ablauf ohne Absturz des simulierten Turnierbaums zu garantieren. Dass format-sensitive Größen auf historischen 32-Team-Turnieren nur eingeschränkt validierbar sind, wird als bekannte Limitation im Validierungsbericht ausgewiesen.

- b) **Dead Rubbers (zustandsabhängige Intensitäten):** Steht das Weiterkommen oder Ausscheiden eines Teams vor dem dritten Gruppenspiel bereits fest, verschiebt sich die Torverteilung (Kader-Rotation, Motivationseffekte). Das System erweitert hierfür die Intensitätsgleichung (2) um einen additiven Term $\zeta \cdot I_{\text{dead}}$, wobei die Indikatorvariable $I_{\text{dead}} \in \{0, 1\}$ ex ante aus dem Tabellenstand vor Anpfiff berechenbar ist (zeitkausal) und ζ auf historischen dritten Gruppenspielen geschätzt wird.
- c) **Exogene Strukturbrüche (COVID-Epoche):** Spiele der Geisterspiel-Epoche (ca. 2020–2021) zeigen einen stark dokumentierten Einbruch des Heimvorteils [29, 30]. Da bei Turnierspielen ohnehin $h = 0$ gilt, wäre eine Skalierung von h dort wirkungslos; korrigiert werden stattdessen (i) der Heimvorteil h in den betroffenen *Trainingsspielen* (Qualifikation, Nations League, Freundschaftsspiele) über eine zeitlich begrenzte Skalierung und (ii) der Host-Effekt η_{host} der EM 2021, die als Multi-Host-Turnier gesondert kodiert wird (England trug sechs von sieben Spielen in Wembley aus).

5.7 Elo-basiertes Referenzmodell

Als einfaches, robustes Zweitmodell (und Pflicht-Baseline) dient ein Elo-Ansatz [6]: Das World-Football-Elo-Rating [16] liefert R_i, R_j ; eine geordnete logistische Regression bzw. Poisson-Regression bildet die Differenz $d = R_i - R_j$ (plus Host-Indikator) auf Tendenzwahrscheinlichkeiten bzw. Torintensitäten ab:

$$\log \lambda = c_0 + c_1 d + c_2 \cdot \text{host}, \quad \log \mu = c_0 - c_1 d. \quad (10)$$

Dieses Modell hat ~ 3 Parameter, ist nahezu un-overfitbar und erstaunlich schwer zu schlagen — genau deshalb ist es die Messlatte für jede komplexere Komponente.

5.8 Feature-basiertes ML-Modell und dynamisches Ensemble (Online Learning)

Drittens ein Gradient-Boosting-Modell (LightGBM/XGBoost) auf zeitpunktkorrekten Features: Elo-Differenz, Marktwert-Verhältnis (log-Skala), Form (gewichtete Tordifferenz letzter n Spiele), Ruhetage, Reisedistanz, Wettbewerbstyp, Turnierphase — und optional die entvigten Marktquoten als Feature (nur für Modus B; in Modus A wäre der Markt sonst zugleich Input und Benchmark, was den Alpha-Nachweis zirkulär machte; vgl. Bemerkung 5.1).

Dynamische Modellgewichtung via Hedge-Algorithmus. Die Vorhersagen der Basismodelle (Elo, Dixon-Coles, ML-Modell) werden *nicht* starr kombiniert, sondern sequenziell über die Theorie der *Prediction with Expert Advice* (Lernen unter vollständiger Information, vgl. Abschnitt 2.1) aggregiert. Die Prämisse ist, dass Modelle während eines Turniers Phasen unterschiedlicher Kalibrierung durchlaufen. Sei $\mathcal{P}_{i,t}$ die prädiktive Ergebnismatrix des Modells i für das Spiel t . Das Ensemble bildet die finale Vorhersage als konvexe Kombination

$$\mathcal{P}_{\text{Ens},t} = \sum_i w_{i,t} \mathcal{P}_{i,t}. \quad (11)$$

Nach Offenlegung des tatsächlichen Spielausgangs (x_t, y_t) erleidet jedes Modell den Log-Loss $L_{i,t} = -\log(\max(\epsilon, \mathcal{P}_{i,t}(x_t, y_t)))$, wobei $\epsilon = 10^{-4}$ als Wahrscheinlichkeitsuntergrenze (Clipping)

dient, um die für die Regretgarantien des Algorithmus zwingend notwendige Beschränkung der Verlustfunktion sicherzustellen. Die Gewichte werden für das nächste Spiel $t + 1$ über den *Exponential Weights Algorithm* (Hedge) aktualisiert:

$$w_{i,t+1} = \frac{w_{i,t} \exp(-\eta \cdot L_{i,t})}{\sum_j w_{j,t} \exp(-\eta \cdot L_{j,t})}, \quad (12)$$

wobei $\eta > 0$ die Lernrate bezeichnet, die die Reaktivität des Ensembles auf kurzfristige Strukturbrüche (z. B. eine unerwartete Überdispersion im aktuellen Turnierverlauf) steuert. Schlecht kalibrierte Modelle verlieren so mathematisch optimal an Einfluss, während performante Modelle „on the fly“ höher gewichtet werden.

Bemerkung 5.1 (Markt als Feature — Behandlung der Zirkularität). *Für Modus B (kein Markt-Gegner) ist die Marktquote ein legitimes, starkes Feature. Für Modus A berichten wir beide Varianten getrennt: (i) Modell ohne Marktinput — nur dies kann echtes, unabhängiges Alpha belegen; (ii) Modell mit Marktinput — relevant für die praktisch beste Prognose. Diese Trennung wird im Backtest-Bericht durchgehalten.*

5.9 K.o.-Phase: Verlängerung und Elfmeterschießen

Ein Elfmeterschießen findet ausschließlich in der K.o.-Phase statt, und auch dort nur, wenn nach 90 Minuten *und* Verlängerung (2×15 Minuten) kein Sieger feststeht. In der Gruppenphase endet ein Spiel ggf. als Remis. Für K.o.-Spiele wird die Endergebnis-Verteilung dreistufig aufgebaut:

1. **K.o.-Phasen-Dämpfung:** Ab dem Achtelfinale sinkt die erwartete Toranzahl systematisch, da die Risikoaversion der Teams extrem steigt (niemand will den entscheidenden Fehler machen). Die 90-Minuten-Matrix $\mathcal{P}_m$ wird wie in der Gruppenphase geschätzt, jedoch werden die Basis-Intensitäten λ und μ um diesen dämpfenden Faktor korrigiert.
2. Bedingt auf Remis nach 90 Minuten wird die Verlängerung als Poisson-Prozess mit Intensitäten $\lambda^{ET} = \kappa \cdot \frac{1}{3} \lambda$, $\mu^{ET} = \kappa \cdot \frac{1}{3} \mu$ modelliert ($\frac{1}{3}$: Zeitanteil; κ : empirischer Intensitätsfaktor, erwartbar < 1 wegen vorsichtigerer Spielweise in der Verlängerung — wird auf historischen K.o.-Spielen geschätzt).
3. Bedingt auf Remis auch nach Verlängerung wird das Elfmeterschießen als annähernd faire Münze mit schwachem Stärke-Effekt modelliert: $\mathbb{P}(i \text{ gewinnt ES}) = \text{logit}^{-1}(c \cdot d_{ij})$ mit kleinem c . Ein potenzieller Reihenfolgeeffekt oder Erstschützeneffekt [31] wird aufgrund der widersprüchlichen empirischen Replikationslage [32] in dieser Basisformulierung bewusst ausgeklammert.

Bezeichnet D_{90} das Ereignis „Remis nach 90 Minuten“ und D_{120} das Ereignis „Remis auch nach Verlängerung“, so ergibt sich die Weiterkommens-Wahrscheinlichkeit als

$$\mathbb{P}(i \text{ kommt weiter}) = \pi_m^H + \pi_m^D \cdot [\mathbb{P}(i \text{ gewinnt ET} \mid D_{90}) + \mathbb{P}(D_{120} \mid D_{90}) \cdot \mathbb{P}(i \text{ gewinnt ES} \mid D_{120})]. \quad (13)$$

Endergebnis-Verteilung für den Tippmodus „nach Elfmeterschießen“. Die Zielrunde (Abschnitt 9.1) wertet K.o.-Spiele nach dem Endstand inklusive Verlängerung und Elfmeterschießen. Die dafür maßgebliche Verteilung $\mathcal{P}_m^{\text{final}}$ entsteht durch Faltung der drei Stufen:

$$\mathcal{P}_m^{\text{final}}(x, y) = \underbrace{\mathcal{P}_m(x, y) \mathbf{1}\{x \neq y\}}_{\text{Entscheidung in 90 Min.}} + \sum_{z \geq 0} \mathcal{P}_m(z, z) \cdot \mathbb{P}(\text{ET/ES führt von } (z, z) \text{ zu } (x, y)), \quad (14)$$

wobei der Übergangskern als Komposition der drei Stufen definiert ist: Verlängerungstore gemäß der Intensitäten (λ^{ET}, μ^{ET}) aus Stufe 2, bei erneutem Remis der ES-Sieger gemäß Stufe 3. Beim Elfmeterschießen gilt die Kicktipp-Konvention, dass dem Sieger des Elfmeterschießens ein Tor zum Stand nach Verlängerung hinzugezählt wird (Beispiel WM-Finale 2022: 3:3 n. V.,

Argentinien gewinnt das Elfmeterschießen $\Rightarrow$ gewertet als 4:3).¹ Unmittelbare Konsequenzen für den Optimierer: In K.o.-Spielen hat $\mathcal{P}_m^{\text{final}}$ keine Masse auf der Diagonalen — Remis-Tipps sind dort strikt dominiert und das Gitter der Kandidaten-Tipps wird auf $i \neq j$ eingeschränkt; zugleich verschiebt die +1-Tor-Konvention Masse auf knappe Siege (1:0, 2:1), was deren $\mathbb{E}[R]$ systematisch erhöht.

6 Schicht 2: Pricing Engine — von Intensitäten zur Ergebnismatrix

6.1 Analytische Auswertung als Standardpfad

Da Schicht 1 parametrische Verteilungen liefert, ist die Ergebnismatrix *analytisch* berechenbar: $\mathcal{P}_m$ folgt direkt aus (λ, μ, ρ) durch Auswertung auf dem Gitter $\{0, \dots, X_{\max}\}^2$. Monte Carlo ist hierfür unnötig und würde nur Simulationsrauschen addieren.

6.2 Monte Carlo, wo es tatsächlich gebraucht wird

Simulation (typisch $N = 100.000$ Pfade) kommt an drei Stellen zum Einsatz, an denen analytische Lösungen unpraktikabel sind:

1. **Parameterunsicherheit:** Ziehung $\theta^{(s)} \sim \text{Posterior}$, Auswertung $\mathcal{P}_m^{(s)}$, Aggregation zur prädiktiven Matrix und zur Verteilung der Tendenzwahrscheinlichkeiten (für Kelly-Shrinkage, Abschnitt 8.3).
2. **Turniersimulation:** vollständige WM-Simulation (Gruppenausgänge inkl. Tiebreaker-Regeln, K.o.-Baum mit Abschnitt 5.9) für Weiterkommens-, Halbfinal- und Titelnwahrscheinlichkeiten; nötig für Outright-Märkte und Kicktipp-Bonusfragen.
3. **Strategie-Backtests:** Verteilung von Bankroll-Pfaden in Modus A (Drawdown-Quantile statt nur Erwartungswerte).

Bemerkung 6.1. Die Trennung „analytisch wo möglich, Simulation wo nötig“ ist eine bewusste Designentscheidung: Sie hält den Prognosepfad deterministisch, testbar und schnell; Stochastik wird nur dort eingeführt, wo sie einen Informationsgewinn liefert.

7 Marktdaten: implizite Wahrscheinlichkeiten und Entvigung

Buchmacherquoten enthalten eine Marge (Vig). Aus Dezimalquoten $o = (o^H, o^D, o^A)$ folgt der Buchungsüberschuss $\Sigma = \sum_k 1/o^k > 1$. Wir implementieren zwei Entvigungsverfahren:

(a) **Proportionale Normierung (Baseline):** $q^k = \frac{1/o^k}{\Sigma}$.

(b) **Shin-Modell [8] (Standard):** modelliert die Marge als Schutz des Buchmachers vor Insider-Wetten; der Insider-Anteil z wird je Quotensatz aus

$$q_{\text{Shin}}^k = \frac{\sqrt{z^2 + 4(1-z) \frac{(1/o^k)^2}{\Sigma}} - z}{2(1-z)}, \quad \sum_k q_{\text{Shin}}^k = 1 \quad (15)$$

numerisch gelöst. Shin korrigiert das bekannte Favorite-Longshot-Bias-Muster besser als proportionale Normierung; die empirische Überlegenheit wird im Backtest verifiziert (Kalibrierung der q gegen realisierte Frequenzen).

¹Diese Konvention wird vor Implementierung gegen die Kicktipp-Hilfe und historische Rundendaten verifiziert (Testfall in der Daten-Pipeline).

Die entvigten q_m dienen (i) als Benchmark-Prognose, (ii) als Feature (Modus B), (iii) als Gegenseite der Value-Bedingung in Modus A.

8 Schicht 3, Modus A: Der Capital Allocator

8.1 Value-Identifikation

Eine Wette auf Ausgang k mit Quote o^k hat den erwarteten Bruttoertrag pro Einheit

$$\mathbb{E}[\text{Ertrag}] = p^k o^k - 1, \quad (16)$$

mit Modellwahrscheinlichkeit p^k . Die Wettbedingung lautet

$$p^k o^k > 1 + \delta, \quad (17)$$

mit Sicherheitsmarge $\delta > 0$ (kalibriert im Backtest, Größenordnung 2–5 %). Die Marge δ kompensiert Parameterunsicherheit und verbleibende Modellfehler; ohne Marge würde das System systematisch genau dann wetten, wenn das Modell irrt (Winner’s Curse der Modell-Markt-Differenz).

8.2 Kelly-Kriterium: Herleitung

Sei $f \in [0, 1)$ der Bankroll-Anteil auf eine Binärwette mit Nettoquote $b = o - 1 > 0$ und Gewinnwahrscheinlichkeit $p \in (0, 1)$, $q = 1 - p$. Das logarithmische Wachstum pro Wette ist

$$g(f) = p \log(1 + bf) + q \log(1 - f). \quad (18)$$

Da g auf $[0, 1)$ strikt konkav ist, liefert die Bedingung $g'(f) = 0$ das eindeutige innere Maximum, das Kelly-Optimum [10]

$$f^* = \frac{bp - q}{b} = \frac{po - 1}{o - 1}; \quad (19)$$

auf der zulässigen Menge $[0, f_{\max}]$ lautet die Lösung entsprechend $\min\{\max\{0, f^*\}, f_{\max}\}$. Es gilt $f^* > 0$ genau dann, wenn die Value-Bedingung (17) mit $\delta = 0$ erfüllt ist; die Nullaktion ist also natürlicher Bestandteil der Lösung. Kelly maximiert asymptotisch fast sicher die Wachstumsrate des Vermögens [11] und macht den Ruin (bei $f < 1$ und korrektem p) unmöglich — aber es ist berüchtigt volatil und vor allem *extrem empfindlich gegen Überschätzung von p* .

8.3 Fraktionales Kelly und Unsicherheits-Shrinkage

Wir setzen niemals volles Kelly, aus zwei formalisierten Gründen:

1. **Schätzfehler:** Bei überschätztem p ist Voll-Kelly überproportional schädlich (asymmetrische Verlustfunktion in f). Standard-Praxis: *fraktionales Kelly* $f = \phi f^*$ mit $\phi \in [0, 1, 0, 25]$.
2. **Bayesianisches Shrinkage:** Da das Modell die Posteriorverteilung von p liefert, setzen wir $f = \phi \cdot \min_{p' \in [\underline{p}, \bar{p}]} f^*(p')$ mit $[\underline{p}, \bar{p}]$ als z. B. 80 %-Kredibilitätsintervall — d. h. der Einsatz wird auf das untere Ende des plausiblen Edge-Bereichs dimensioniert. Ist $f^*(\underline{p}) \leq 0$, wird nicht gewettet, selbst wenn der Punktschätzer Value anzeigt.

Zusätzlich gilt eine harte Obergrenze $f \leq f_{\max}$ (z. B. 2 % der Bankroll pro Spiel).

8.4 Grenzen der Asymptotik und Finite-Horizon-Effekte

Die asymptotische Optimalität des Kelly-Kriteriums — Maximierung der fast sicheren Wachstumsrate — beruht auf dem Starken Gesetz der großen Zahlen für $N_{\text{Wetten}} \rightarrow \infty$ [10, 11]. Im Kontext einer WM liegt die reale Stichprobengröße bei lediglich $N_{\text{Wetten}} \approx 15$ bis 35.

In diesem endlichen *Non-Asymptotic Regime* ist das klassische Kelly-Kriterium unvollständig. Statt das fraktionale Kelly heuristisch zu setzen, formulieren wir das Einsatzproblem als stochastische dynamische Programmierung für einen endlichen Horizont N . Wir maximieren den Erwartungswert einer isoelastischen Nutzenfunktion (CRRA) des Endkapitals W_N mit Risikoaversionsparameter $\gamma > 1$:

$$\max_{f_t} \mathbb{E} \left[\frac{W_N^{1-\gamma}}{1-\gamma} \right]. \quad (20)$$

Die Lösung dieser Bellman-Gleichung führt zur expliziten Berücksichtigung des endlichen Horizonts (dem optimalen Merton-Anteil). Für eine Binärwette im zeitstetigen lognormalen Grenzfall nach Merton [22] ergibt sich der Optimaleinsatz

$$f_{\text{Merton}}^* = \frac{1}{\gamma} \cdot \frac{p \cdot o - 1}{o - 1}. \quad (21)$$

Für diskrete Wetten über einen endlichen Horizont ist diese Gleichheit zwar nicht exakt, da die Lösung der Bellmangleichung zustandsabhängig und zeitabhängig wird. Dennoch dient der Skalierungsfaktor ϕ aus Abschnitt 8.3 hier als fundierte Approximation und entspricht in diesem Grenzfall dem Kehrwert der Risikoaversion ($\phi \approx 1/\gamma$), welche aus der maximal tolerierbaren Drawdownwahrscheinlichkeit für die verbleibende Anzahl der Turnierspiele abgeleitet wird.

8.5 Mehrere gleichzeitige Spiele: Portfolio-Sicht

In der Gruppenphase finden bis zu vier Spiele pro Tag statt. Gleichzeitige Wetten interagieren über die gemeinsame Bankroll. Da die zugrundeliegenden Modellwahrscheinlichkeiten p_m zudem über den gemeinsamen bayesianischen Posterior (insb. den Konföderations-Prior μ_c^α) stochastisch abhängig sind, wäre eine Optimierung über das Produkt der Randverteilungen fehlspezifiziert. Da Turnierspiele am selben Tag häufig sequenziell stattfinden (z. B. 15:00 Uhr, 18:00 Uhr, 21:00 Uhr), greift eine rein simultane Tages-Optimierung zu kurz: Sie blockiert Kapital, das bei einem Gewinn des frühen Spiels bereits für das spätere Spiel reinvestiert werden könnte (Intraday-Zinseszinsseffekt).

Die Portfolio-Optimierung wird daher als bedingte Politik $\pi(f_{t_2} | Y_{t_1})$ formuliert. Wir mitteln über die Posterior-Draws $\theta^{(s)}$ und lösen per Rückwärtsinduktion über die Startzeiten des Tages:

$$\max_{\pi(\cdot)} \frac{1}{S} \sum_{s=1}^S \mathbb{E}_{Y \sim \pi(\theta^{(s)})} \left[\log \left(B_{\text{Start}} + \sum_{m=1}^M R_m(f_m(Y_{<m}), Y_m) \right) \right], \quad (22)$$

wobei $Y_{<m}$ die Ausgänge aller chronologisch vor Spiel m beendeten Spiele des Tages bezeichnen. Bei echten Simultan-Spielen (z. B. dritter Gruppenspieltag) zerfällt die Politik automatisch in die Standard-Portfolio-Optimierung über die gemeinsamen Ausgänge.

Risiko-Overlay (CVaR). Ergänzend zur Kelly-Zielfunktion wird eine Conditional-Value-at-Risk-Nebenbedingung auf den Tagesverlust L gelegt:

$$\text{CVaR}_\alpha(L) = \mathbb{E} [L | L \geq \text{VaR}_\alpha(L)] \leq c \cdot B_t, \quad (23)$$

z. B. $\alpha = 0,95$, $c = 5\%$: Der erwartete Verlust in den schlechtesten 5% der Tage darf 5% der Bankroll nicht übersteigen. Unter Hinzunahme dieser CVaR Nebenbedingung bleibt das statische, simultane Problem nach der Formulierung von Rockafellar und Uryasev [9] konvex und ist mit Standardsolvern (cvxpy) lösbar. Der in Gleichung (22) beschriebene sequentielle Fall wird stattdessen als Rückwärtsinduktion über konvexe Teilprobleme charakterisiert.

Bemerkung 8.1 (Einordnung). *Für die praktisch relevanten Einsatzgrößen ($\phi f^* \leq 2\%$) bindet die CVaR-Nebenbedingung selten; sie ist primär ein Sicherheitsnetz gegen Tage mit ungewöhnlich vielen simultanen Value-Signalen — genau das Szenario, in dem korrelierte Modellfehler (ein systematisch falscher Konföderations-Prior!) am gefährlichsten sind.*

8.6 Betriebsregeln Modus A

- Quoten-Snapshot zu definiertem Zeitpunkt (z. B. 2h vor Anpfiff); Entscheidung und Begründung (Modell- p , Markt- q , Edge, f) werden revisionssicher geloggt — vor Anpfiff.
- Es wird höchstens *ein* Ausgang pro Spiel bewettet (der mit maximalem f^* ; simultane Gegenwetten auf dasselbe Spiel sind durch (22) ohnehin nicht optimal).
- Erwartung an die Selektivität: Bei effizienten WM-Märkten ist in 70–85 % der Spiele kein Edge zu erwarten; eine deutlich höhere Wettfrequenz ist ein *Warnsignal* (Modell zu selbstsicher), kein Erfolg.
- Paper-Trading ist der Default-Betriebsmodus; Echtgeld ist eine rein persönliche Entscheidung außerhalb des Systems.
- **Marktfriktionen und Einsatz-Limitierungen (Punkt 1):** In-sample berechnete Equity-Curves ignorieren oft die Praxis von Account-Sperren und individuellen Limits (Soft Bookies). Zur Vermeidung dieses Bias limitiert das System den maximalen absoluten Einsatz im Backtest künstlich auf realistische Marktliquiditäts-Grenzwerte oder weicht operativ auf asiatische Broker/Exchanges aus.
- **API-Latenzen und Geister-Value (Punkt 4):** Da zeitkritische Quotenbewegungen kurz vor Anpfiff stattfinden, führen Caching-Verzögerungen (insb. im Free Tier von *The Odds API*) zu Scheinerfolgen im Protokoll (Wetten auf veraltete Quoten). Die Betriebsregel erzwingt ein engmaschiges Polling (High-Frequency-Snapshot) exakt in den 60 Minuten vor Anpfiff; Quoten, die im Platzierungsfenster real nicht mehr verfügbar sind, werden als ungültig markiert.

9 Schicht 3, Modus B: Der Kicktipp-Optimierer

9.1 Punktefunktion der Zielrunde

Die Zielrunde ist die Kicktipp-Runde „Yanuwantaka“ mit folgenden, den offiziellen Spielregeln entnommenen Parametern:

	Tendenz	Tordifferenz	Ergebnis
Sieg	2	3	4
Unentschieden	2	—	4

Da die Runde Turnierspiele auf neutralem Platz wertet, sind Heim- und Auswärtssieg punktgleich. Formal, für Tipp (i, j) und gewertetes Ergebnis (x, y) :

$$S(i, j \mid x, y) = \begin{cases} 4 & (i, j) = (x, y) \\ 3 & i - j = x - y \wedge (i, j) \neq (x, y) \wedge i \neq j \\ 2 & \text{sgn}(i - j) = \text{sgn}(x - y) \wedge (i - j \neq x - y \vee i = j) \wedge (i, j) \neq (x, y) \\ 0 & \text{sonst.} \end{cases} \quad (24)$$

Bemerkung 9.1 (Remis-Abwertung in dieser Runde). *In vielen Tipprunden erhält ein in der Tendenz richtiger Remis-Tipp die Tordifferenz-Punktzahl (hier wären das 3 Punkte), da bei Remis Tordifferenz und Tendenz zusammenfallen. Die Zielrunde vergibt dafür jedoch nur die Tendenz-Punktzahl 2 (Beispiel: Tipp 1:1, Ergebnis 2:2 $\Rightarrow$ 2 Punkte). Remis-Tipps sind hier also strukturell schwächer als im verbreiteten 4/3/2-Schema: Ein Sieg-Tipp kann drei Punkteklassen treffen (4/3/2), ein Remis-Tipp nur zwei (4/2). Der Optimierer berücksichtigt das automatisch über (25); erwartbare Konsequenz ist eine gegenüber dem Standardschema reduzierte Häufigkeit optimaler Remis-Tipps.*

Weitere Regelparameter der Zielrunde.

- **Tippmodus:** genaues Ergebnis, gewertet „nach Elfmeterschießen“ — relevant nur für die K.o.-Phase (Abschnitt 5.9); Gruppenspiele werden nach 90 Minuten gewertet, Remis ist dort ein regulärer Ausgang.
- **Bonusfragen:** 4 Punkte pro richtiger Antwort, Reihenfolge ohne Bedeutung. Antworten werden aus der Monte-Carlo-Turniersimulation (Abschnitt 6) abgeleitet: Maximierung der Trefferwahrscheinlichkeit je Frage.
- **Tippabgabe bis Anpfiff** (0 Minuten Vorlaufzeit): operativ wertvoll, da Tipps mit dem spätesten verfügbaren Quoten- und Aufstellungsstand abgegeben werden können.
- **Punktegleichstand:** Platzierung per Anzahl der Spieltagssiege — relevant für die Rang-Optimierung (Abschnitt 9.4): Spieltagssiege erhöhen den Wert varianzreicher Tipps an Spieltagen, an denen man ohnehin nicht führt.

Konfigurierbarkeit. Das Punkteschema bleibt ein injizierter Parameter (Konstruktor-Argument) — die obigen Werte sind die Default-Konfiguration der Zielrunde, Backtests gegen andere Schemata (z. B. Standard 4/3/2 mit Remis-Tordifferenz) bleiben möglich.

9.2 Optimaler Tipp als Erwartungsnutzen-Maximierung

Der Optimierer berechnet für jeden Kandidaten-Tipp (i, j) auf dem Gitter $\{0, \dots, 5\}^2$ (höhere Tipps sind nie optimal bei realistischen λ, μ ; das Gitter ist konfigurierbar):

$$\mathbb{E}[R_{i,j}] = \sum_{x=0}^{X_{\max}} \sum_{y=0}^{X_{\max}} \mathbb{P}(X = x, Y = y) \cdot S(i, j \mid x, y), \quad (i^*, j^*) = \arg \max_{(i,j)} \mathbb{E}[R_{i,j}]. \quad (25)$$

Das ist eine exakte, geschlossene Berechnung (36×121 Auswertungen pro Spiel) — kein Schätzproblem, sobald $\mathcal{P}$ vorliegt.

Proposition 9.1 (Tipp $\neq$ Modus der Verteilung). *Es existieren Intensitäten (λ, μ) , für die der punktoptimale Tipp (i^*, j^*) aus (25) nicht mit dem wahrscheinlichsten Ergebnis (dem Modus von $\mathcal{P}$) übereinstimmt.*

Beweis. Direkte Auswertung von (25) für unabhängige Poisson-Margen mit $\lambda = 1,8$ und $\mu = 1,2$ (moderater Favorit): Der Modus der Ergebnismatrix ist das Remis 1:1 mit $\mathbb{P}(1:1) = 0,108$, aber $\mathbb{E}[R_{1,1}] = 0,678$. Der optimale Tipp ist 2:1 mit $\mathbb{E}[R_{2,1}] = 1,354$ (knapp vor 1:0 mit $\mathbb{E}[R_{1,0}] = 1,347$) — fast der doppelte erwartete Punktertrag des Modus-Tipps, da der Remis-Tipp die Tordifferenz-Punkteklasse verliert (Bemerkung 9.1) und nur zwei statt drei Punkteklassen abdeckt. $\square$

Diese Rechnung dient zugleich als handverifizierter Testfall für Meilenstein M4; der Optimierer macht die Abwägung zwischen Trefferwahrscheinlichkeit und Nachbarschafts-Abdeckung exakt statt intuitiv.

9.3 Sensitivität und Diagnostik

Pro Spiel werden ausgegeben: die Top-5-Tipps nach $\mathbb{E}[R]$, deren Erwartungswerte und die Differenz zum naiven Modus-Tipp. Da $\mathbb{E}[R_{i,j}]$ -Landschaften oft flach sind (Differenzen $< 0,05$ Punkte), dokumentieren wir die Robustheit des optimalen Tipps gegen Posterior-Unsicherheit in $\mathcal{P}$ (Anteil der Posterior-Draws, in denen (i^*, j^*) optimal bleibt).

9.4 Erweiterung: Rang- statt Punktemaximierung

Punktemaximierung (Gleichung 25) ist optimal für die *erwartete* Punktzahl, aber das eigentliche Ziel in einer Tipprunde ist die Maximierung der Sieg- bzw. Platzierungswahrscheinlichkeit. Da

das Verhalten der Mitspieler stark korreliert (Herdenverhalten auf Favoriten), ist Modus B im Kern ein nicht-kooperatives Nullsummenspiel.

Sei $\mathbf{T}_m$ der unbekannte Vektor der Tipps aller K Mitspieler für Spiel m . Wir führen ein empirisches Crowd-Modell $Q(t \mid \pi_m)$ ein, das die Wahrscheinlichkeit angibt, dass ein zufälliger Mitspieler bedingt auf die Markt-Tendenzen π_m den Tipp t wählt. Die korrekte Zielfunktion maximiert nicht $\mathbb{E}[R]$, sondern die Wahrscheinlichkeit, die Mitspieler zu übertreffen:

$$\max_{(i,j)} \sum_{x,y} \mathcal{P}_m(x,y) \sum_{\mathbf{T}_m} \mathbb{P}(\mathbf{T}_m \mid Q) \cdot \mathbf{1} \left\{ R((i,j), x, y) > \max_k R(T_{m,k}, x, y) \right\}. \quad (26)$$

Da der Zustandsraum für $K > 10$ kombinatorisch explodiert, verwendet das System eine *Mean-Field-Approximation*: Anstatt individuelle Mitspieler zu simulieren, berechnen wir die erwartete Punkteverteilung der Population. Das Problem transformiert sich in eine Mean-Variance-Optimierung auf Tipp-Erträgen: Wir suchen den Tipp (i, j) , der die Kovarianz $\text{Cov}(R_{\text{eigen}}, R_{\text{crowd}})$ minimiert, während der isolierte Erwartungswert $\mathbb{E}[R_{i,j}]$ hoch bleibt. Dies operationalisiert die Tournament-Theory-Resultate aus dem Fondsmanagement [12] mathematisch exakt für das Tipster-Problem.

Das Absicherungs-Paradoxon (Hedging in der Endphase - Punkt 5). Während die Mean-Field-Approximation das globale Herdenverhalten abbildet, mutiert die Anreizstruktur an den letzten Spieltagen für Spitzenreiter der Tipprunde fundamental. Liegt der Nutzer in Führung, maximiert die reine Punkte-Optimierung nach (25) nicht mehr zwingend die Siegwahrscheinlichkeit des Turniers. Das System implementiert für die Finalphase eine dynamische Absicherungs-Logik (Hedging): Wenn die Führung statistisch signifikant ist, schrumpfen die abgegebenen Tipps in Richtung der erwarteten Tipps der direkten Verfolger (Varianz-Minimierung durch Spiegelung), anstatt risikoreiche Außenseiter-Tipps mit hohem solitären $\mathbb{E}[R]$ zu wählen.

10 Validierung und Backtesting

10.1 Designprinzipien und Leakage-Kontrolle

1. **Walk-Forward, keine zufälligen Splits:** Training ausschließlich auf $\mathcal{F}_{t_m}$. Für Turnier-Backtests: Parameterschätzung mit Datenstand *vor Turnierbeginn*, optional tägliche Re-Schätzung während des Turniers (nur mit bereits gespielten Turnierspielen).
2. **Feature-Zeitkausalität technisch erzwungen:** Jede Feature-Berechnung erhält den Prognose-Zeitpunkt als Pflicht-Parameter; Tests stellen sicher, dass kein Feature auf Daten mit späterem Zeitstempel zugreift (Look-Ahead-Bias als Testfall, nicht als Konvention).
3. **Hyperparameter-Disziplin und Bayesian Optimization:** Die Likelihood-Gewichte (ξ, w_c) sowie δ, ϕ und die Ensemble-Lernrate η spannen einen hochdimensionalen Parameterraum auf. Da eine erschöpfende Raster-Suche (Grid Search) hierfür rechenineffizient ist, erfolgt die Kalibrierung über **Bayesian Optimization**. Ein *Gaussian Process* modelliert die Performance (RPS oder CLV) über dem Parameterraum. Eine Acquisition Function (z. B. *Upper Confidence Bound* oder *Thompson Sampling*) wählt iterativ diejenige Parameterkombination für den nächsten Backtest-Lauf, die das Explore-Exploit-Dilemma der Parametersuche mathematisch optimal löst. Die auf dem *Validierungsfenster* (WM 2014, EM 2016, WM 2018) gefundenen Optima werden anschließend eingefroren und auf dem vorregistrierten Test-Set unverändert angewendet.
4. **Vorregistrierung:** Vor der WM 2026 wird die finale Konfiguration (Modelle, Hyperparameter, δ, ϕ , Punkteschema) in einem getaggten Commit eingefroren; alle WM-Prognosen sind dadurch nachweislich ex-ante.

10.2 Evaluationsdatensätze

Fenster	Turniere	Rolle
Training (rollierend)	alle Länderspiele bis t	Parameterschätzung
Validierung	WM 2014, EM 2016, WM 2018	Hyperparameter, Modellwahl
Test (eingefroren)	EM 2021, WM 2022, EM 2024, Copa 2024	finale Bewertung
Live	WM 2026	vorregistrierter Ernstfall

Das ergibt ~ 190 Validierungs- und ~ 190 Testspiele — genug für probabilistische Metriken, knapp für ökonomische (daher Bootstrap, Abschnitt 10.7).

10.3 Probabilistische Güte: Proper Scoring Rules

Accuracy ist für probabilistische Prognosen ungeeignet. Wir verwenden ausschließlich *proper* Scoring Rules (Anreizverträglichkeit: ehrliche Wahrscheinlichkeiten minimieren den erwarteten Score):

Ranked Probability Score (primär). Für die geordneten Ausgänge (Heimsieg $\succ$ Remis $\succ$ Auswärtssieg) mit Prognose $p = (p_1, p_2, p_3)$ und Ergebnisindikator $e \in \{0, 1\}^3$ (One-Hot-Kodierung des realisierten Ausganges):

$$\text{RPS} = \frac{1}{2} \sum_{k=1}^2 \left(\sum_{l=1}^k (p_l - e_l) \right)^2. \quad (27)$$

RPS respektiert die Ordnung der Ausgänge („knapp daneben“ ist besser als „völlig daneben“) und ist Standard der Fußballprognose-Literatur [7]. Erwartete Größenordnung guter Modelle auf Turnierdaten: $\text{RPS} \approx 0,19\text{--}0,21$.

Log-Loss / Ignorance Score. $-\log p_{\text{Ergebnis}}$; bestraft Überkonfidenz drastisch. Zusätzlich auf der *Ergebnismatrix* ausgewertet ($-\log \mathbb{P}(x, y)$), was die volle Verteilung statt nur der Tendenz testet — relevant für Modus B.

Brier Score. Quadratischer Multikategorie-Score als Robustheits-Check.

Kalibrierung. Reliability-Diagramme und Kalibrierungs-Regression (prognostizierte vs. realisierte Frequenz in Wahrscheinlichkeits-Bins) für Tendenzen und für ausgewählte Ergebnis-Wahrscheinlichkeiten. Ein unkalibriertes Modell ist für Modus A disqualifiziert, selbst bei gutem RPS.

Stratifizierung nach Quotenbändern. Die Kalibrierungsanalyse wird ergänzend explizit nach Quotenbändern (starke Favoriten vs. extreme Außenseiter) geschnitten. Dies dient als spezifisches Prüfkriterium, um nachzuweisen, ob das eigene Modell gegen das marktweit dokumentierte *Favorite-Longshot-Bias* [15] kalibriert ist oder dieses systematisch repliziert.

10.4 Baselines (Mindesthürden)

- B1. **Klimatologie:** historische Basisraten (z. B. Heim/Remis/Auswärts $\approx 45/27/28\%$ in Turnieren, neutral korrigiert).
- B2. **Nur-Elo** (Abschnitt 5.7).
- B3. **Entvigter Markt** (q_m): die harte Benchmark. Modelle ohne Marktinput, die B3 im RPS schlagen, belegen echtes Alpha; Gleichstand ist bereits ein starkes Resultat.
- B4. **Kicktipp-Heuristiken** (nur Modus B): „immer 2:1 für den Favoriten“, „immer 1:0 für den Quoten-Favoriten“, „Modus der Markt-impliziten Ergebnisverteilung“.

10.5 Ökonomische Validierung Modus A

Auf historischen Quoten (Abdeckung dokumentiert) wird die volle Strategie simuliert (Value-Filter, Shrinkage-Kelly, CVaR-Overlay, Transaktionsannahmen):

- **Equity Curve** und Endkapital-Verteilung (über Bootstrap-Resamples der Spielmenge);
- **ROI** pro Wette und p. a.; **Profit Factor**;
- **Maximum Drawdown** und Drawdown-Dauer;
- **Sharpe Ratio** der Wettrendite-Reihe (mit der gebotenen Vorsicht: nicht-normale, schiefe Erträge — ergänzt um Sortino);
- **Closing Line Value (CLV)**: mittlere relative Bewegung der Quote zwischen Wettzeitpunkt und Schlussquote auf den bewetteten Ausgängen. CLV ist der stärkste verfügbare Indikator für echten Edge, da er nicht vom Ergebnisrauschen abhängt. Da die Validität des CLV jedoch zwingend eine scharfe Schlusslinie (typischerweise Pinnacle) voraussetzt, weist der Backtestbericht explizit aus, gegen welche Schlussquelle der CLV für Turniere vs. Vereinsligen gemessen wird;
- **Wettfrequenz** und Edge-Verteilung (Plausibilitäts-Check gegen Überkonfidenz).

Data-Snooping und Backtest-Overfitting. Da bei der iterativen Modell- und Hyperparameterwahl auf dem Validierungsfenster implizit eine Vielzahl an Konfigurationen (ξ, w_c, δ) verglichen wird, unterliegt der resultierende Backtest einem Selektionsbias (Data-Snooping). Um die Gefahr von Scheinerfolgen statistisch zu bereinigen, unterziehen wir die Sharpe-Ratio der Equity Curve einem Korrekturverfahren analog zu *White's Reality Check* [13] bzw. berechnen die *Deflated Sharpe Ratio* (DSR) nach Bailey und López de Prado [14].

10.6 Validierung Modus B

Pro Test-Turnier: erzielte Kicktipp-Punkte des Optimierers vs. alle B4-Heuristiken und vs. dem Optimierer auf Basis der entvigten Markt-Ergebnismatrix (Markt-implizite $\mathcal{P}$ via Poisson-Kalibrierung auf q_m). Zusätzlich: erwartete vs. realisierte Punkte (Kalibrierung der Punkteprognose) und Verteilung der Punktzahl über simulierte Turnierverläufe (wo hätte der Optimierer in einer typischen Tipprunde gelegen?).

10.7 Statistische Signifikanz

Bei ~ 190 Testspielen sind Konfidenzintervalle breit; wir berichten sie immer mit:

- **Bootstrap-Konfidenzintervalle** (Spiel-Level-Resampling) für RPS-Differenzen, ROI und Punktdifferenzen;
- **Paarweise Tests** für Scoring-Rule-Differenzen (Diebold-Mariano-artig auf Spiel-Level-Scoredifferenzen);
- **Ehrlichkeitsklausel:** Ergebnisse, deren Konfidenzintervall die Null überdeckt, werden als „nicht unterscheidbar“ berichtet — insbesondere ist ein positiver Backtest-ROI auf ~ 50 – 80 Wetten *kein* Beleg für profitables Wetten, und das Dokument sagt das auch so.

11 Software-Architektur

11.1 Schichtenmodell

Schicht	Paket	Verantwortung (SRP)
Ingestion	src/data/	Quellen laden, validieren, kanonisches Schema bauen
Features	src/features/	zeitpunktkorrekte Feature-Berechnung
Modelle	src/models/	$\mathcal{F}_t \rightarrow \mathcal{P}_m$ (Schicht 1+2)
Markt	src/market/	Quoten laden, entvigen (Shin)
Entscheidung	src/decision/	$\mathcal{P}_m \rightarrow$ Aktion (Modus A/B)
Backtest	src/backtest/	Walk-Forward-Engine, Metriken, Berichte
Helpers	src/helpers/	constants.py, dtos.py, enums.py
Einstieg	main.py	CLI: predict / tip / bet / backtest

11.2 Zentrale Abstraktionen

- **ScorelineDistribution** (DTO): die Ergebnismatrix samt Ableitungen (Tendenz, Tordifferenz-Verteilung) — die *einzig*e Schnittstelle zwischen Modellen und Entscheidungen.
- **MatchPredictionModel** (ABC): `fit(matches, as_of)` und `predict(fixture) → ScorelineDistribution`. Subklassen: `EloPoissonModel`, `DixonColesModel`, `BayesianHierarchicalModel`, `EnsembleModel` (Open/Closed: neue Modelle als neue Subklassen).
- **DecisionStrategy** (ABC): `decide(distribution, context) → Aktion`. Subklassen: `KellyBettingStrategy` (Kontext: Quoten, Bankroll), `KicktippStrategy` (Kontext: Punkteschema). Liskov: beide sind drop-in-austauschbar gegen die ABC.
- **ScoringScheme** (Wertobjekt, injiziert): kapselt $S(i, j | x, y)$ inklusive Sonderregeln.
- **WalkForwardEngine**: orchestriert Re-Fitting und Vorhersage entlang der Zeitachse; Modelle und Strategien werden per Dependency Injection übergeben (testbar mit Stub-Modellen).

Alle übrigen Konventionen (PEP 8, Black, Type Hints, uv, Funktionslängen, Konstanten-Klassen, Branch-/PR-Workflow) folgen den projektweiten Coding-Standards und werden hier nicht dupliziert.

12 Roadmap mit Verifikationskriterien

- M1. **Daten-Pipeline**: kanonischer Datensatz (Kaggle + Elo gemerzt, Namens-Mapping, K.o.-Rekonstruktion).
Verifiziert durch: Validierungs-Suite grün (Zeilenzahlen, Null-Quoten, Stichproben gegen Originalquellen).
- M2. **Baseline-Modelle**: Elo-Poisson und Dixon-Coles mit Zeitgewichtung.
Verifiziert durch: RPS auf Validierungsturnieren im Literaturbereich (0,19–0,21); Kalibrierungsplots ohne systematische Verzerrung.
- M3. **Backtest-Engine + Metriken**: Walk-Forward, alle Scores, Baselines B1–B3.
Verifiziert durch: Leakage-Tests grün; Baseline-Resultate reproduzierbar (Seed-fixiert).
- M4. **Modus B**: `KicktippStrategy` + Punkteschema.
Verifiziert durch: Unit-Tests gegen handgerechnete $\mathbb{E}[R]$ -Beispiele; Backtest-Punkte $\geq$ beste B4-Heuristik auf Validierungsturnieren.
- M5. **Markt + Modus A**: Quoten-Pipeline, Shin-Entvigung, Shrinkage-Kelly, CVaR-Overlay.
Verifiziert durch: Unit-Tests Kelly/Shin gegen Handrechnung; Backtest-Bericht mit CLV, ROI inkl. Bootstrap-Intervallen.

- M6. **Bayesianisches Modell + Ensemble:**
Verifiziert durch: $\hat{R}$ -Diagnostik; RPS-Verbesserung (oder dokumentierte Nicht-Verbesserung) gegenüber M2 out-of-sample.
- M7. **Finalisierung Test-Set + Vorregistrierung:** eingefrorene Konfiguration, Bericht auf EM 2021–Copa 2024, getaggtter Commit.
Verifiziert durch: vollständiger, reproduzierbarer Ergebnisbericht (README mit Charts).
- M8. **WM-2026-Betrieb:** CLI-Workflow pro Spieltag (Quoten ziehen, Tipps/Wetten ausgeben, Logs).
Verifiziert durch: Trockenlauf auf den WM-Eröffnungsspieltagen mit vollständigem Log.

13 Future Work

In Reihenfolge des erwarteten Nutzen-Aufwand-Verhältnisses:

1. **Rang-Optimierung in Tipprunden** (Abschnitt 9.4) — spieltheoretisch reizvoll, benötigt nur vorhandene Bausteine plus Mitspieler-Verhaltensmodell.
2. **Spielerbasierte Features** (Belastung, Verfügbarkeit von Schlüsselspielern, xG-Aggregate wo verfügbar).
3. **Partikelfilter** für kontinuierliche Stärke-Dynamik (Abschnitt 5.4, Stufe 3).
4. **Quotenbewegungs-Features** (Open-zu-Close-Drift als Smart-Money-Proxy), sofern historische Open/Close-Paare in ausreichender Abdeckung beschaffbar sind.
5. **GNN auf Interaktionsdaten** — nur falls Event-Daten-Abdeckung für Länderspiele substanziell besser wird; aktuell nicht reproduzierbar umsetzbar (Abschnitt 1.4).

Literatur

- [1] M. J. Maher, *Modelling association football scores*, Statistica Neerlandica 36 (1982), 109–118.
- [2] M. J. Dixon, S. G. Coles, *Modelling association football scores and inefficiencies in the football betting market*, Journal of the Royal Statistical Society C 46 (1997), 265–280.
- [3] D. Karlis, I. Ntzoufras, *Analysis of sports data by using bivariate Poisson models*, Journal of the Royal Statistical Society D 52 (2003), 381–393.
- [4] H. Rue, Ø. Salvesen, *Prediction and retrospective analysis of soccer matches in a league*, Journal of the Royal Statistical Society D 49 (2000), 399–418.
- [5] S. J. Koopman, R. Lit, *A dynamic bivariate Poisson model for analysing and forecasting match results in the English Premier League*, Journal of the Royal Statistical Society A 178 (2015), 167–186.
- [6] L. M. Hvattum, H. Arntzen, *Using ELO ratings for match result prediction in association football*, International Journal of Forecasting 26 (2010), 460–470.
- [7] A. C. Constantinou, N. E. Fenton, *Solving the problem of inadequate scoring rules for assessing probabilistic football forecast models*, Journal of Quantitative Analysis in Sports 8 (2012).
- [8] H. S. Shin, *Measuring the incidence of insider trading in a market for state-contingent claims*, The Economic Journal 103 (1993), 1141–1153.
- [9] R. T. Rockafellar, S. Uryasev, *Optimization of conditional value-at-risk*, Journal of Risk 2 (2000), 21–41.

- [10] J. L. Kelly, Jr., *A new interpretation of information rate*, Bell System Technical Journal 35 (1956), 917–926.
- [11] L. Breiman, *Optimal gambling systems for favorable games*, Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability 1 (1961), 65–78.
- [12] K. C. Brown, W. V. Harlow, L. T. Starks, *Of tournaments and temptations: An analysis of managerial incentives in the mutual fund industry*, The Journal of Finance 51 (1996), 85–110.
- [13] H. White, *A reality check for data snooping*, Econometrica 68 (2000), 1097–1126.
- [14] D. H. Bailey, M. López de Prado, *The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality*, The Journal of Portfolio Management 40 (2014), 94–107.
- [15] M. Cain, D. Law, D. Peel, *The favourite-longshot bias and market efficiency in UK football betting*, Scottish Journal of Political Economy 47 (2000), 25–36.
- [16] World Football Elo Ratings, <https://eloratings.net>.
- [17] K. C. Lichtendahl, R. L. Winkler, *Probability elicitation, scoring rules, and competition among forecasters*, Management Science 53 (2007), 1745–1755.
- [18] L. M. B. Cabral, *R&D competition when firms choose variance*, Journal of Economics & Management Strategy 12 (2003), 139–150.
- [19] T. M. Cover, J. A. Thomas, *Elements of Information Theory*, John Wiley & Sons, New York, 1991.
- [20] T. Lattimore, C. Szepesvári, *Bandit Algorithms*, Cambridge University Press, 2020.
- [21] N. Cesa-Bianchi, G. Lugosi, *Prediction, Learning, and Games*, Cambridge University Press, 2006.
- [22] R. C. Merton, *Lifetime portfolio selection under uncertainty: The continuous-time case*, Review of Economics and Statistics 51 (1969), 247–257.
- [23] A. Sklar, *Fonctions de répartition à n dimensions et leurs marges*, Publications de l’Institut de Statistique de l’Université de Paris 8 (1959), 229–231.
- [24] C. Genest, J. Nešlehová, *A primer on copulas for count data*, ASTIN Bulletin 37 (2007), 475–515.
- [25] A. M. Nevill, R. L. Holder, *Home advantage in sport: An overview of studies on the advantage of playing at home*, Sports Medicine 28 (1999), 221–236.
- [26] R. Pollard, *Home advantage in football: A current review of an unsolved puzzle*, Journal of Human Sport and Exercise 3 (2008), 12–14.
- [27] P. E. McSharry, *Effect of altitude on physiological performance: a statistical analysis using results of international football games*, BMJ 335 (2007), 1278–1281.
- [28] L. D. Recht, R. A. Lew, W. J. Schwartz, *Baseball teams beaten by jet lag*, Nature 377 (1995), 583.
- [29] K. Fischer, J. Haucap, *Does crowd support drive the home advantage in professional football? Evidence from German ghost games during the COVID-19 pandemic*, Journal of Sports Economics 22 (2021), 982–1008.

- [30] F. Wunderlich, M. Weigelt, R. Rein, D. Memmert, *How does spectator presence affect football? Home advantage remains in European top-class football matches played without spectators during the COVID-19 pandemic*, PLoS ONE 16 (2021), e0248590.
- [31] J. Apesteguia, I. Palacios-Huerta, *Psychological pressure in competitive environments: Evidence from a randomized natural experiment*, American Economic Review 100 (2010), 2548–2564.
- [32] M. G. Kocher, M. V. Lenz, M. Sutter, *Psychological pressure in competitive environments: New evidence from randomized natural experiments*, Management Science 58 (2012), 1585–1591.