

Ein probabilistisches Prognose- und Entscheidungssystem für die FIFA-Weltmeisterschaft 2026

Projekt Quant-WM-Guru
Konzeptdokumentation

M. Dantschenko

4. Juli 2026

Zusammenfassung

Dieses Dokument spezifiziert Konzept, Mathematik, Datenarchitektur und Validierungsmethodik eines quantitativen Prognosesystems für Fußball-Länderspiele, mit der FIFA-WM 2026 als Anwendungsfall. Das System trennt strikt zwischen *Inferenz* (Schätzung einer vollständigen Wahrscheinlichkeitsverteilung über Spielausgänge) und *Entscheidung* (Ableitung optimaler Handlungen aus dieser Verteilung). Auf demselben stochastischen Kern operieren zwei entscheidungstheoretisch fundamental verschiedene Modus-Familien: (1) ein *Capital Allocator* (Modus A), der Wetten als risikobehaftete Assets behandelt und Einsätze über das fraktionale Kelly-Kriterium mit Risiko-Nebenbedingungen dimensioniert, wobei Nicht-Wetten eine zulässige und häufig optimale Aktion ist, und (2) ein *Kicktipp-Optimierer* (Modus B mit den Varianten B1 und B2), der unter Tippzwang den erwarteten Punktertrag einer turnierspezifischen Punktefunktion maximiert. Die Validierung erfolgt über strikt zeitkausale Walk-Forward-Backtests auf historischen Turnieren (Validierung: WM 2014, EM 2016, WM 2018; eingefrorenes Test-Set: EM 2021, WM 2022, EM 2024, Copa América 2024) mit Proper Scoring Rules (Ranked Probability Score, Log-Loss, Brier Score), Kalibrierungsanalyse sowie ökonomischen Metriken (ROI, Maximum Drawdown, Closing Line Value) gegen explizit definierte Baselines, insbesondere den entvigten Buchmachermarkt.

Inhaltsverzeichnis

1	Einleitung und Zielsetzung	3
1.1	Motivation	3
1.2	Trennung von Inferenz und Entscheidung als Leitprinzip	3
1.3	Anforderungen an das System	3
1.4	Explizite Nicht-Ziele (Scope-Abgrenzung)	4
1.5	Aufbau des Dokuments	4
2	Mathematische Grundlagen	4
2.1	Lernen unter vollständiger Information	5
3	Problemformulierung	6
3.1	Notation	6
3.2	Die Entscheidungsprobleme	7
4	Datenarchitektur	10
4.1	Kanonisches Datenmodell	10
4.2	Datenquellen und Priorisierung	11

4.3	Datenqualität und bekannte Probleme	12
4.4	Abgeleitete Merkmalsdatensätze	13
5	Das stochastische Modell (Schicht 1)	14
5.1	Unabhängige Poisson-Zählprozesse als Basismodell	14
5.2	Dixon-Coles-Korrektur und Zeitgewichtung	15
5.3	Alternative Kopplung und Überdispersion	16
5.4	Dynamische Teamstärken in einer Zustandsraum-Formulierung	18
5.5	Bayesianische Hierarchie und das Sparse-Data-Problem der Nationalteams	20
5.6	Regimewechsel und turnierspezifische Strukturbrüche	21
5.7	Referenzmodell basierend auf dem Elo-System	22
5.8	Feature-basiertes Machine-Learning-Modell und dynamisches Ensemble	23
5.9	Knockout-Phase sowie Verlängerung und Elfmeterschießen	24
6	Von Intensitäten zur Ergebnismatrix (Schicht 2)	26
6.1	Analytische Auswertung als Standardpfad	26
6.2	Monte-Carlo, wo es tatsächlich gebraucht wird	26
7	Implizite Wahrscheinlichkeiten und Entvigung der Marktdaten	26
8	Der Capital Allocator (Schicht 3, Modus A)	27
8.1	Value-Identifikation	27
8.2	Einsatzdimensionierung nach Kelly	27
8.3	Fraktionales Kelly und Unsicherheits-Shrinkage	28
8.4	Grenzen der Asymptotik und Finite-Horizon-Effekte	28
8.5	Portfolio-Sicht bei gleichzeitigen Spielen	29
8.6	Betriebsregeln Modus A	30
9	Der Kicktipp-Optimierer (Schicht 3, Modus B)	31
9.1	Punktefunktion der Zielrunde	31
9.2	Optimaler Tipp als Erwartungsnutzen-Maximierung	32
9.3	Sensitivität und Diagnostik	33
9.4	Rangmaximierung statt Punktemaximierung als Erweiterung	33
10	Validierung und Backtesting	34
10.1	Designprinzipien und Leakage-Kontrolle	34
10.2	Evaluationsdatensätze	34
10.3	Proper Scoring Rules zur probabilistischen Güte	34
10.4	Baselines (Mindesthürden)	35
10.5	Ökonomische Validierung Modus A	35
10.6	Validierung Modus B	36
10.7	Statistische Signifikanz	36
11	Software-Architektur	36
11.1	Schichtenmodell	36
11.2	Zentrale Abstraktionen	36
12	Roadmap mit Verifikationskriterien	37
13	Future Work	37

1 Einleitung und Zielsetzung

1.1 Motivation

Fußballspiele sind niedrig-skorende, stark verrauschte stochastische Ereignisse: Das bessere Team verliert regelmäßig, und einzelne Tore (Erwartungswert pro Spiel $\approx 2,5$ – $2,7$) dominieren das Ergebnis. Genau diese Eigenschaften machen Fußball zu einem idealen Testfall für quantitative Methoden, wie sie im Asset Management eingesetzt werden: probabilistische Modellierung statt Punktprognosen, Bewertung gegen einen effizienten Markt (Wettquoten), Positionsgrößenbestimmung unter Unsicherheit und rigorose Out-of-Sample-Validierung.

Das Projekt verfolgt zwei Ziele:

1. **Wissenschaftlich:** Ein methodisch sauberes, reproduzierbares Prognosesystem auf dem Stand der sportstatistischen Literatur [23, 11, 17, 31, 20].
2. **Praktisch:** Einsatz während der WM 2026 in zwei realen Entscheidungssituationen (frei wählbare Wetten; verpflichtende Kicktipp-Abgabe).

1.2 Trennung von Inferenz und Entscheidung als Leitprinzip

Das zentrale Designprinzip des Systems ist die strikte Trennung zweier Fragen, wobei die diskreten Zufallsvariablen X und Y mit Werten in $\mathbb{N}_0$ (formal Abbildungen auf dem in Abschnitt 3.1 eingeführten Wahrscheinlichkeitsraum) die Anzahl der erzielten Tore des erstgenannten (Heim-) bzw. zweitgenannten (Gast-)Teams beschreiben:

1. *Was wird passieren?* Die Inferenz umfasst die Schätzung der gemeinsamen Verteilung $\mathbb{P}(X = x, Y = y)$ der Tore beider Teams (Schichten 1 und 2, Abschnitte 5–6).
2. *Was soll ich tun?* Die Entscheidung bezeichnet die Abbildung dieser Verteilung auf eine Handlung unter einer modusabhängigen Zielfunktion (Schicht 3, Abschnitte 8–9).

Beide Modi konsumieren *dieselbe* Wahrscheinlichkeitsmatrix. Unterschiede im Verhalten entstehen ausschließlich aus den Zielfunktionen, nicht aus unterschiedlichen Modellen, sodass derselbe stochastische Kern auf zwei ökonomisch völlig verschiedene Probleme (diskretionäres Portfoliomanagement gegenüber Entscheidung unter Zwangsbedingungen) angewandt wird.

1.3 Anforderungen an das System

- C1. Für jedes Spiel eine vollständige, kalibrierte Torverteilung $\mathbb{P}(X = x, Y = y)$ der diskreten Zufallsvariablen für die Tore des Heimteams $X \in \mathbb{N}_0$ und des Gastteams $Y \in \mathbb{N}_0$ liefern. Daraus sind die Tendenzwahrscheinlichkeiten (Sieg, Remis, Niederlage), exakte Ergebnisse, Tordifferenzen sowie Over/Under-Märkte (Totals) abzuleiten.
- C2. Die Parameterunsicherheit aller Modellparameter quantifizieren und explizit über *Bayesian posterior distributions* abbilden. Das System gibt somit vollständige Wahrscheinlichkeitsverteilungen der Stärkeparameter aus, anstatt sich auf singuläre Punktschätzer (*Point Estimates*) zu beschränken.
- C3. Marktquoten einlesen, von der impliziten Gewinnmarge bereinigen und als wahre Wahrscheinlichkeiten sowohl als *Benchmark* als auch als *Feature* nutzen.
- C4. Modus A: Value-Wetten identifizieren. Unter Verwendung der vom Modell geschätzten Wahrscheinlichkeit des Spielausganges (π_{Modell}), der dezimalen Marktquote (o) und einer definierten Sicherheitsmarge ($\delta > 0$) geschieht dies über die Bedingung $\pi_{\text{Modell}} \cdot o > 1 + \delta$. Anschließend werden die Einsätze via fraktionalem Kelly-Kriterium bestimmt, Risiko-Nebenbedingungen eingehalten und explizit „keine Wette“ als gültige Handlung ermöglicht.
- C5. Modus B1 und Modus B2. Im Einzelspielerfall (Modus B1) wählt das System für jedes Spiel nicht zwingend das wahrscheinlichste Ergebnis, sondern berechnet exakt den Tipp,

der nach den Regeln der Tipprunde (dem konfigurierbaren Punkteschema) im Durchschnitt die höchste Punktzahl liefert. Im Mehrspielerfall (Modus B2) maximiert es stattdessen die Platzierungswahrscheinlichkeit am Turnierende und wählt den Tipp risikoadjustiert in Abhängigkeit vom Punktrückstand und vom beobachteten Tippverhalten der Mitspieler.

- C6. Backtests über historische Turniere ohne Look-Ahead-Bias durchführen und alle Metriken aus Abschnitt 10 reproduzierbar berichten.
- C7. Spielphasen korrekt behandeln: In der *Gruppenphase* zählt das Ergebnis nach 90 Minuten, sodass ein Remis ein regulärer Ausgang ist. In der *K.o.-Phase* erzeugt das System die Tipps für die Zielrunde (die konkrete Kicktipp-Runde des Anwendungsfalls, Abschnitt 9.1) im Modus „nach Elfmeterschießen“. Wenn es nach 90 Minuten und Verlängerung unentschieden steht, entscheidet das Elfmeterschießen. Das System benötigt an dieser Stelle die Endergebnis-Verteilung aus Abschnitt 5.9 sowie die Weiterkommens-Wahrscheinlichkeiten für die Turniersimulation und die Bonusfragen. Die Bepreisung von Outright-Wetten nutzt dieselben Weiterkommens-Wahrscheinlichkeiten, ihre Einsatzsteuerung ist jedoch Ausblick.

1.4 Explizite Nicht-Ziele (Scope-Abgrenzung)

Die folgenden, teils in frühen Brainstormings (u. a. extern vorgeschlagenen) Komponenten sind *bewusst* nicht Teil des Kernsystems, sondern dokumentiertes Future Work (Abschnitt 13):

- **Hochfrequente Tick-by-Tick-Quotenhistorie (Betfair/Pinnacle):** Historische Tick-Daten sind kostenpflichtig bzw. für vergangene Turniere nicht mehr frei beschaffbar. Der Kern arbeitet mit Eröffnungs- und Schlussquoten (Open/Close), was für die CLV-Analyse (Abschnitt 10.5) ausreicht.
- **Spieler-Belastungsdaten (Minuten in Vereinen):** als aggregiertes Feature in Phase 2 vorgesehen, nicht im Kern. Die Beschaffung (Scraping) ist aufwendig und der dokumentierte Zusatznutzen in der Literatur gering gegenüber Marktwert-Proxies.
- **In-Play-/Live-Wetten:** Das System prognostiziert ausschließlich pre-match.

1.5 Aufbau des Dokuments

Abschnitt 2 stellt die entscheidungstheoretischen Grundlagen bereit, und Abschnitt 4 beschreibt die Datenarchitektur. Die Abschnitte 5 und 6 entwickeln das stochastische Modell sowie die Pricing-Engine, die Entvigung der Marktdaten behandelt Abschnitt 7. Die beiden Entscheidungsmodi folgen in den Abschnitten 8 und 9. Abschnitt 10 beschreibt die zeitkausale Validierung, die übrigen Abschnitte die Softwarearchitektur, die Roadmap und die zukünftige Arbeit. Als eigene Leistung dieser Arbeit gelten die Integration der genannten Bausteine, die Formalisierung der Modi B1 und B2 sowie das zeitkausale Validierungsdesign, während die einzelnen stochastischen Bausteine (Dixon-Coles, Shin, Kelly, Hedge) der zitierten Literatur folgen.

2 Mathematische Grundlagen

Die beiden Entscheidungsmodi greifen auf Resultate der Informationstheorie und der Entscheidungstheorie zurück, die hier kompakt bereitgestellt werden, bevor sie in der Problemformulierung Verwendung finden. Im Zentrum von Modus A steht das Kelly-Kriterium, welches die optimale Einsatzgröße über die Maximierung der erwarteten logarithmischen Wachstumsrate des Kapitals bestimmt.

Proposition 2.1 (Kellyoptimum im Binärfall). *Wir betrachten eine dezimale Marktquote $o \in (1, \infty)$ und definieren die zugehörige Nettoquote $b \in \mathbb{R}_{>0}$ durch die Beziehung $b = o - 1$. Die Gewinnwahrscheinlichkeit wird durch den Parameter $p \in (0, 1)$ beschrieben, die Verlustwahrscheinlichkeit beträgt entsprechend $1 - p$. Für einen wählbaren Einsatzanteil $f \in [0, 1)$ bezeichne die*

Funktion $g_K : [0, 1) \rightarrow \mathbb{R}$ mit der Form

$$g_K(f) = p \ln(1 + bf) + (1 - p) \ln(1 - f)$$

die erwartete logarithmische Wachstumsrate des Kapitals pro Wette. Dann ist die Funktion g_K auf dem Intervall $[0, 1)$ strikt konkav und besitzt das eindeutige Maximum $f^* \in [0, 1)$, welches durch die Gleichheit

$$f^* = \frac{bp - (1 - p)}{b} = \frac{po - 1}{o - 1}$$

gegeben ist, falls die Bedingung $po > 1$ erfüllt ist, und andernfalls den Wert $f^* = 0$ annimmt.

Beweis. Für die Funktion g_K lautet die erste Ableitung $g'_K(f) = \frac{pb}{1+bf} - \frac{1-p}{1-f}$ und die zweite Ableitung $g''_K(f) = -\frac{pb^2}{(1+bf)^2} - \frac{1-p}{(1-f)^2}$. Wegen der Bedingung $p \in (0, 1)$ und $b \in \mathbb{R}_{>0}$ gilt die Ungleichung $g''_K(f) < 0$ für alle Anteile $f \in [0, 1)$, womit die Striktkonkavität der Funktion g_K nachgewiesen ist. Die notwendige Optimalitätsbedingung $g'_K(f) = 0$ ist äquivalent zu der Gleichung $pb(1-f) = (1-p)(1+bf)$. Ein Umstellen liefert den optimalen Wert $f^* = (bp - (1-p))/b$. Mit der Beziehung $o = b + 1$ folgt daraus die Gleichheit $bp - (1-p) = po - 1$. Im komplementären Fall $po \leq 1$ gilt für die Randableitung $g'_K(0) = pb - (1-p) \leq 0$. Aufgrund der nachgewiesenen Konkavität fällt die Funktion g_K auf dem gesamten Intervall $[0, 1)$ monoton, sodass das globale Maximum am Rand bei $f^* = 0$ angenommen wird. $\square$

Der Zähler $po - 1$ ist genau dann positiv, wenn die Wette einen positiven Erwartungswert besitzt. Dies motiviert die wertbasierte Wettbedingung aus Abschnitt 1.3, welche in der Form

$$\pi_{\text{Modell}} \cdot o > 1 + \delta$$

als eine geschärfte Variante unter Verwendung einer positiven Sicherheitsmarge $\delta \in \mathbb{R}_{>0}$ definiert ist. Das Kelly-Kriterium maximiert die asymptotisch fast sicher erreichte Wachstumsrate des Vermögens über eine Folge unabhängiger Wetten [18, 3]. Die in Modus A verwendete Mehrausgangsformel aus Abschnitt 8 verallgemeinert dieses fundamentale Resultat auf einen Markt mit mehreren sich gegenseitig ausschließenden Ausgängen und einem nicht investierten Restanteil. Diese Formulierung entspricht dem logarithmisch optimalen Portfolio für ein Pferderennen im Sinne von Cover und Thomas [9, Kap. 6]. Da die Zielfunktion eine Summe konkaver Logarithmen über einem konvexen Polytop bildet, bleibt das zugehörige Optimierungsproblem konvex und ist mit numerischen Standardverfahren eindeutig lösbar.

Bemerkung 2.1. *Das vollständige Kelly-Optimum ist empirisch hochvolatil und reagiert überproportional empfindlich auf eine Überschätzung der Gewinnwahrscheinlichkeit p . Das Entscheidungssystem verwendet daher durchgängig das fraktionale Kelly-Kriterium, welches mit einer zusätzlichen Schrumpfung auf das untere Ende des bayesianischen Kreditibilitätsintervalls kombiniert wird, wie in Abschnitt 8 ausgeführt ist.*

2.1 Lernen unter vollständiger Information

Modus B2 schätzt das Tippverhalten der Mitspieler fortlaufend aus Beobachtungen. Nach jedem Spieltag werden das tatsächliche Ergebnis sowie die Tipps sämtlicher Mitspieler sichtbar, und da die Punktefunktion bekannt ist, lässt sich der Ertrag jeder möglichen eigenen Tippabgabe kontrafaktisch bestimmen. Dieses Szenario ist die Prädiktion mit Expertenrat im Sinne von Cesa-Bianchi und Lugosi [7, Kap. 2], also Onlinelernen mit vollständiger Rückmeldung. Es unterscheidet sich grundlegend vom stochastischen Banditenproblem, in dem ausschließlich der Ertrag des gewählten Arms beobachtbar ist und Exploration deshalb unvermeidlich wird.

Die Abgrenzung ist quantitativ bedeutsam. Der Regret bezeichnet dabei den kumulierten Mehrverlust gegenüber der im Rückblick besten festen Aktion. Für K Aktionen und einen Horizont von n Runden besitzt der stochastische Bandit eine Minimaxschranke der Ordnung

$\Omega(\sqrt{Kn})$ [21, Kap. 15], deren Herleitung gerade die Kosten der Exploration bei unvollständiger Rückmeldung abbildet. Unter vollständiger Information sinkt die erreichbare Schranke auf die Ordnung $\Theta(\sqrt{n \log K})$. Bei $K = (X_{\max} + 1)^2$ Ergebniszellen, wobei $X_{\max}$ die erst in Abschnitt 3.1 eingeführte Zensurschwelle des Ergebnissgitters bezeichnet, ist dies eine exponentiell günstigere Abhängigkeit von der Aktionszahl, deren Ursache exakt der Wegfall der Explorationskosten ist. Aus diesem Grund modelliert das System die Gegnerschätzung als Verfahren der Regretminimierung unter vollständiger Information und nicht als Banditenalgorithmus. Der zeitlichen Instationarität des Tippverhaltens begegnet es durch Diskontierung älterer Beobachtungen, etwa über eine exponentielle Gewichtung oder ein gleitendes Fenster.

3 Problemformulierung

3.1 Notation

Sei $\mathcal{I}$ die endliche Menge aller betrachteten Teams und $\mathcal{M}$ die Menge aller Spiele. Für jedes Spiel $m \in \mathcal{M}$ bezeichne $i(m) \in \mathcal{I}$ das erstgenannte Team (Heimteam), $j(m) \in \mathcal{I}$ das zweitgenannte Team (Gastteam) und $t_m \in \mathbb{R}$ den Anpfiff-Zeitpunkt. Der Ausgang eines Spiels $m \in \mathcal{M}$ nach regulärer Spielzeit wird durch die diskreten Zufallsvariablen X_m und Y_m modelliert, wobei das Tupel (X_m, Y_m) Werte in $\mathbb{N}_0 \times \mathbb{N}_0$ annimmt. Dabei bezeichnen X_m und Y_m die Anzahl der erzielten Tore von Team $i(m)$ bzw. $j(m)$. Der diskrete Index $t \in \mathbb{N}_0$ zählt die Entscheidungszeitpunkte (Spieltage) in der durch die Anstoßzeiten t_m gegebenen chronologischen Ordnung, sodass beide Zeitbegriffe über diese Ordnung verknüpft sind.

Wir verwenden im Folgenden diese Notationen und Definitionen.

- $\mathcal{P}_m: \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow [0, 1]$ bezeichne die vom Modell geschätzte Wahrscheinlichkeitsfunktion für das Spiel m , definiert durch $\mathcal{P}_m(x, y) = \mathbb{P}(X_m = x, Y_m = y)$ für alle $x, y \in \mathbb{N}_0$. In der praktischen Implementierung wird die Wahrscheinlichkeitsfunktion bei einem endlichen Schwellenwert $X_{\max} \in \mathbb{N}$ rechnerisch zensiert, wobei die verbleibende Restmasse beider Ränder auf die zugehörigen Randzellen des Gitters $\{0, \dots, X_{\max}\}^2$ kumuliert wird, sodass etwa die Eckzelle $(X_{\max}, X_{\max})$ die gemeinsame Wahrscheinlichkeit $\mathbb{P}(X_m \geq X_{\max}, Y_m \geq X_{\max})$ trägt. Der Parameter $X_{\max}$ wird so gewählt, dass die abgeschnittene Restmasse unterhalb von 10^{-6} liegt und der numerische Fehler für die Erwartungswertberechnung der erst in Abschnitt 3.2 eingeführten Punktfunktion S damit vernachlässigbar bleibt. Gleichzeitig garantiert der endliche Träger $\{0, \dots, X_{\max}\}^2$ eine effiziente algorithmische Auswertung unter exakter Erhaltung des Wahrscheinlichkeitsmaßes ($\sum_{x,y} \mathcal{P}_m(x, y) = 1$).
- $\pi_m = (\pi_m^{i(m)}, \pi_m^R, \pi_m^{j(m)})^T \in [0, 1]^3$ bezeichne den Vektor der drei Tendenzwahrscheinlichkeiten (Sieg von Team $i(m)$, Remis, Sieg von Team $j(m)$) für ein Spiel $m \in \mathcal{M}$. Da zwingend genau einer dieser drei Ausgänge eintreten muss, summieren sich ihre Wahrscheinlichkeiten auf 1. Dieser Vektor wird abgeleitet, indem die Wahrscheinlichkeiten aller relevanten Einzelergebnisse (z. B. 1:0, 2:0, 2:1 für einen Sieg von Team $i(m)$) aus der Ergebnismatrix $\mathcal{P}_m$ aufaddiert werden.
- $o_m = (o_m^{i(m)}, o_m^R, o_m^{j(m)})^T \in [1, \infty)^3$ bezeichne den Vektor der dezimalen Marktquoten der Buchmacher für das Spiel m , aufgeteilt nach den Ausgängen Sieg von Team $i(m)$, Remis und Sieg von Team $j(m)$. Sei $q_m = (q_m^{i(m)}, q_m^R, q_m^{j(m)})^T \in [0, 1]^3$ der zugehörige Vektor der von der Buchmachermarge bereinigten Marktwahrscheinlichkeiten, deren Komponenten sich auf 1 summieren (Details siehe Abschnitt 7).
- $f_m = (f_m^{i(m)}, f_m^R, f_m^{j(m)})^T \in [0, f_{\max}]^3 \subset [0, 1]^3$ bezeichne den Einsatzvektor für das Spiel m , dessen Komponenten die relativen Anteile der aktuellen Bankroll $B_t \in \mathbb{R}_{>0}$ zum Zeitpunkt $t \in \mathbb{N}_0$ definieren, die auf die jeweiligen Tendenzen (Sieg von Team $i(m)$, Remis, Sieg von Team $j(m)$) gesetzt werden. Mit der Zustandsmenge der Tendenzen $\Omega_m = \{i(m), R, j(m)\}$ unterliegt der Vektor der Budgetrestriktion $\sum_{\omega \in \Omega_m} f_m^\omega \leq f_{\max}$, wobei $f_{\max} \in (0, 1]$ den maximal zulässigen Anteil der Bankroll für ein Einzelspiel limitiert.

- Sei $(\Omega, \mathcal{F}, \mathbb{P})$ der zugrundeliegende Wahrscheinlichkeitsraum, der alle möglichen Turnierverläufe abbildet, und $(\mathcal{F}_t)_{t \geq 0}$ eine darauf definierte Filtration, die den exakten Informationsstand zum Zeitpunkt t repräsentiert. Sämtliche Prognosen für ein Spiel $m \in \mathcal{M}$ müssen ausschließlich $\mathcal{F}_{t_m}$ -messbar sein (Zeitkausalität).

Die folgende Tabelle fasst die wiederkehrenden Symbole zusammen, wobei jedes Symbol genau eine Bedeutung trägt.

Symbol	Bedeutung	Symbol	Bedeutung
$\mathcal{I}, \mathcal{M}$	Teams, Spiele	α_k, β_k	Angriff, Verteidigung
$i(m), j(m)$	Heim, Gast	γ	Niveauparameter
Ω_m	Tendenzmenge, Element ω	η	Heimvorteilsskalierung
$\mathcal{C}, \mathcal{B}$	Konföderationen, Basismodelle	ρ	Dixon-Coles-Korrelation
X_m, Y_m	Tore von $i(m), j(m)$	θ	Dixon-Coles-Parametervektor
Z_m	realisierter Ausgang	ϑ	Copula-Parameter
$X_{\max}$	Zensurschwelle	ξ	Zerfallsrate
$\mathcal{P}_m$	Ergebnismatrix	$g(\Delta t)$	Zeitgewichtsfunktion
π_m	Modell-Tendenzen	$w_{c(m)}$	Wettbewerbsgewicht
q_m	Markt-Tendenzen (entvigt)	ψ	Marktwert-Skalierung
o_m	Marktquoten	ν	Hedge-Lernrate
$f_m, f_{\max}$	Einsatz, Obergrenze	$p_{\min}$	Log-Loss-Untergrenze
ϕ	fraktionaler Kelly-Faktor	$\kappa_{\text{ET}}, \kappa_{\text{ko}}$	Dämpfung ET, Knockout
δ	Sicherheitsmarge	E_i	Elo-Rating von Team i
a	Risikoaversion (CRRA)	B_t	Bankroll (Wettkapital)
S	Punktfunktion	R_t	Punktstände der Teilnehmer
C_m	Gegnermodell (B2)	τ	Risikoschwelle (B2)
(u, v)	Tipp-Kandidat (Modus B)	$w_{i,m}$	Ensemblegewichte
V_m	Overround (Vig)	$\chi, c_{\max}$	CVaR-Niveau, Verlusttoleranz
L_{Tag}	Tagesverlust	n_{sim}	Anzahl Simulationspfade
$\text{conf}(k)$	Konföderation von Team k	H	Planungshorizont (CRRA)

3.2 Die Entscheidungsprobleme

Modus A (Capital Allocator). Mit der Notation aus Abschnitt 3.1 sei $Z_m \in \Omega_m$ die diskrete Zufallsvariable des tatsächlichen Spielausgangs mit $\mathbb{P}(Z_m = \omega) = \pi_m^\omega$. Der zulässige Aktionsraum der Einsatzvektoren ist definiert als

$$\mathcal{A}_m = \left\{ f = \left(f^{i(m)}, f^R, f^{j(m)} \right)^\top \in [0, f_{\max}]^3 \subseteq [0, 1]^3 \mid \sum_{\omega \in \Omega_m} f^\omega \leq f_{\max} \right\}.$$

Die Aufgabe besteht darin, den optimalen Vektor $f_m^* \in \mathcal{A}_m$ zu wählen, der das erwartete logarithmische Bankroll-Wachstum maximiert, also

$$\begin{aligned} f_m^* &= \arg \max_{f_m \in \mathcal{A}_m} \mathbb{E} \left[\ln \left(1 + f_m^{Z_m} \cdot o_m^{Z_m} - \sum_{\omega \in \Omega_m} f_m^\omega \right) \right] \\ &= \arg \max_{f_m \in \mathcal{A}_m} \sum_{\omega \in \Omega_m} \pi_m^\omega \ln \left(1 + f_m^\omega \cdot o_m^\omega - \sum_{\nu \in \Omega_m} f_m^\nu \right) \end{aligned}$$

(Abschnitt 8). Aufgrund der logarithmischen Nutzenfunktion ist die Optimierung skaleninvariant bezüglich des absoluten Kapitals B_t . Im Gegensatz zu positionsbezogenen Risiken bei Turnieren (vgl. Modus B2) ist das Risiko hier strikt monetär. Die Aktionsmenge $\mathcal{A}_m$ schließt die Nullaktion $f_m = (0, 0, 0)$ explizit ein, welche das Kapital bei fehlendem positiven stochastischen Erwartungswert vor Erosion schützt und im Allgemeinfall die optimale Lösung darstellt.

Modus B1 (Kicktipp: Einzelspieler-Baseline). Sei $\mathcal{K} \subset \mathbb{N}_0$ die diskrete Menge der möglichen Punkterträge (hier $\mathcal{K} = \{0, 2, 3, 4\}$). Gegeben sei die auf den Träger $\{0, \dots, X_{\max}\}^2$ zensierte Wahrscheinlichkeitsfunktion $\mathcal{P}_m: \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow [0, 1]$ mit $\mathcal{P}_m(x, y) = \mathbb{P}(X_m = x, Y_m = y)$ sowie eine Punktefunktion $S: \mathbb{N}_0^2 \times \mathbb{N}_0^2 \rightarrow \mathcal{K}$. Die Punktefunktion S definiert für jedes tatsächliche Ergebnis $(x, y) \in \mathbb{N}_0^2$ und jeden gewählten Tipp $(x^*, y^*) \in \mathbb{N}_0^2$ den Punktertrag. Die Aufgabe besteht darin, exakt einen Tipp $(x^*, y^*) \in \{0, \dots, X_{\max}\}^2$ *verpflichtend* zu wählen, der den erwarteten Punktertrag

$$\mathbb{E}[S((X_m, Y_m), (x^*, y^*))] = \sum_{x=0}^{X_{\max}} \sum_{y=0}^{X_{\max}} \mathcal{P}_m(x, y) \cdot S((x, y), (x^*, y^*))$$

maximiert (Abschnitt 9). Es existiert weder eine Nullaktion noch zu allozierendes Kapital. Das Risiko ist nicht monetär, sondern positionsbezogen bezüglich des Ranges in der Tipprunde.

Modus B2 (Kicktipp: Mehrspieler-Dynamik). Sei $N \in \mathbb{N}$ die Anzahl der Teilnehmer. Der Vektor $R_t = (r_{1,t}, \dots, r_{N,t})^T \in \mathbb{N}_0^N$ bildet den aktuellen Punktestand aller Teilnehmer zum Zeitpunkt $t \in \mathbb{N}_0$ ab, wobei die Komponente $r_{k,t} \in \mathbb{N}_0$ den Punktestand des Teilnehmers k bezeichnet (ein Teilnehmer ohne korrekte Tipps hat null Punkte). Sei $K = (X_{\max} + 1)^2$ die Anzahl der diskreten Ergebniszellen des Score-Gitters. Das *Gegnermodell* (Opponent Model) $C_m \in [0, 1]^K$ ist ein Wahrscheinlichkeitsvektor, dessen Komponenten die geschätzten Auftretenswahrscheinlichkeiten jedes möglichen Ergebnisses $(x, y) \in \{0, \dots, X_{\max}\}^2$ abbilden, normiert durch $\|C_m\|_1 = 1$.

In der kompetitiven Realität transformiert sich das Modell zu einem dynamischen, spieltheoretischen Optimierungsproblem. Die globale Zielfunktion verschiebt sich von der isolierten Punktemaximierung zur Maximierung der Sieg- bzw. Platzierungswahrscheinlichkeit am Turnierende $T \in \mathbb{N}_0$. Dabei bezeichnet $\text{Rang}_T \in \{1, \dots, N\}$ den Rang des eigenen Systems im finalen Punktestand R_T , wobei bei Punktgleichheit die Anzahl der Spieltagsiege entscheidet (Abschnitt 9.1). Das Gegnermodell C_m wird dabei nicht als bekannt vorausgesetzt, sondern fortlaufend aus den beobachteten Tipps geschätzt (Abschnitte 2.1 und 9.4), und die Formalisierung behandelt jeweils die aktuelle Schätzung als gegeben. Das Ziel ist die Maximierung des Erwartungswertes der Indikatorfunktion für den Turniersieg über die eigene Tipp-Politik, also über die Folge der eigenen Tippabgaben,

$$\max_{(x_m^*, y_m^*)_m} \mathbb{E}[\mathbb{I}_{\{\text{Rang}_T=1\}}].$$

Im Gegensatz zur isolierten Einzelspieler-Baseline ist die optimale Entscheidungsfindung in Modus B2 kein statischer Prozess, sondern skaliert substanziell mit dem aktuellen Zustandsraum, namentlich dem Punkterückstand und dem verbleibenden Turnierhorizont $(T - t)$ (vgl. [22, 5]). Spieltheoretische Analysen mittels Rückwärtsinduktion [22, 5] legen nahe, dass die auf Erwartungswertmaximierung basierende Strategie von Modus B1 in kompetitiven Umgebungen bei Abweichungen vom Idealverlauf nicht mehr das globale Optimum darstellt. Sobald der Punkterückstand das durch Modus B1 inhärent aufholbare Varianzpotential übersteigt, transformiert das System seine Strategie dynamisch. Zur Maximierung der Siegbedingung erfolgt bei Rückstand eine bewusste Reduktion der Korrelation zu C_m (*Contrarian Play*), während bei eigener Führung die Korrelation zu C_m maximiert wird (*Hedging*), um den relativen Vorsprung durch Konsenswahrung gegen stochastische Ausreißer zu immunisieren (operationalisiert in Abschnitt 9.4).

Die explizite Trennung zwischen der Einzelspieler-Baseline (Modus B1) und der Mehrspieler-Dynamik (Modus B2) ist auch dann methodisch geboten, wenn das Teilnehmerfeld ausschließlich aus unstrategischen Gelegenheitsspielern besteht, die rein heuristisch oder intuitiv agieren. Die Notwendigkeit dieser spieltheoretischen Erweiterung stützt sich auf drei stochastische Kernargumente.

1. *Das Extremwert-Problem:* Das globale Optimierungsziel eines Turniers besteht nicht darin, den durchschnittlichen Mitspieler zu schlagen, sondern das Maximum der gegnerischen

Punkteverteilung zu übertreffen. Bei kurzen Turnierhorizonten (z. B. $|\mathcal{M}| = 51$ bei einer Europameisterschaft) und einer moderaten Teilnehmeranzahl führt die inhärente stochastische Varianz des Fußballs dazu, dass mit hoher Wahrscheinlichkeit mindestens ein Gelegenheitsspieler durch rein zufällige Kumulation von Extremereignissen eine exzeptionell hohe Punktzahl erreicht. Modus B1 agiert aufgrund der reinen Erwartungswertmaximierung inhärent konservativ und stark favoritenlastig. Liegt das System im späten Turnierverlauf im Rückstand, reicht die verbleibende Varianz von Modus B1 mathematisch nicht aus, um diesen statistischen Ausreißer zu kompensieren.

2. *Die Verwässerung des Grenzertrags (Payoff Dilution):* Unstrategische Spieler verhalten sich keineswegs stochastisch unkorreliert, sondern unterliegen systematischen kognitiven Verzerrungen (z. B. Favoriten- oder Heimat-Bias). Diese systemischen Verzerrungen manifestieren sich in einer Konzentration der Tipp-Dichte C_m auf bestimmte Ergebnisse. Deklariert Modus B1 beispielsweise ein 2 : 1 als das Ergebnis mit dem höchsten Erwartungswert, so wird dieses Ergebnis aufgrund der identischen Heuristiken im Teilnehmerfeld in der Verteilung C_m eine hohe Dichte aufweisen. Tritt dieses Ergebnis tatsächlich ein, so wird eine große Anzahl an Mitspielern denselben Punktertrag erzielen; der erwartete Punkterückstand zur Spitze bleibt somit konstant. Dies reduziert die Möglichkeit, die Lücke zu schließen, auf seltene stochastische Zufallstreffer statt auf strategische Überlegenheit. Modus B2 löst dieses Defizit, indem er gezielt suboptimale Ergebnisse mit niedrigerem isolierten Erwartungswert, aber signifikant höherer strategischer Divergenz relativ zur Tipp-Dichte C_m wählt.
3. *Adaptives Lernen des Gegnermodells.* Das Gegnermodell C_m operiert losgelöst von der Annahme rationaler Agenten und schätzt die systematischen Verzerrungen des Teilnehmerfeldes wie Favoritenneigung, Heimatneigung und die mit wachsendem Rückstand zunehmende Varianzsuche fortlaufend aus den nach jedem Spieltag vollständig beobachtbaren Tipps. Formal ist dies eine Regretminimierung unter vollständiger Information und kein stochastisches Banditenproblem, wie in Abschnitt 2.1 ausgeführt wird. Die mathematische Überlegenheit von Modus B2 resultiert somit nicht aus der Vorhersage einer fixen Rationalität, sondern aus der laufenden Monetarisierung informationeller Ineffizienzen, indem das System systematische Fehlallokationen des Kollektivs identifiziert und in einem dynamischen Optimierungsprozess zur Maximierung der Siegwahrscheinlichkeit ausnutzt. Da die Schätzung der Tippdichte C_m über ein kurzes Turnier teils hohem Schätzrauschen unterliegt, wird der tatsächliche Edge von Modus B2 im Backtest explizit gegen Modus B1 evaluiert und mit statistischen Konfidenzbändern ausgewiesen.

Strategische Adaption des Risiko-Ertrag-Verhältnisses. Die Divergenz von der Baseline-Strategie B1 hin zu einer spieltheoretischen Strategie in Modus B2 erfolgt nicht unkontrolliert. Es handelt sich um ein stetiges Optimierungsproblem, das den Erwartungswert $\mathbb{E}[S]$ als *Constraint* (Nebenbedingung) behandelt. Sei $s \in \{1, \dots, N\}$ der Index des eigenen Systems und $r_{k,t}$ der aktuelle Punktstand des Teilnehmers $k \in \{1, \dots, N\}$ als Eintrag k des Vektors der Punktstände $R_t \in \mathbb{N}_0^N$. Der Rückstand des eigenen Systems zur Führung zum Zeitpunkt t ist dann

$$\Delta_t = \max_{k \in \{1, \dots, N\}} r_{k,t} - r_{s,t}.$$

Das System maximiert die Gewinnwahrscheinlichkeit $\mathbb{P}(\text{Rang}_T = 1)$ unter der Nebenbedingung, dass der erwartete Punktertrag $\mathbb{E}[S]$ nicht unter ein kritisches Niveau fällt. Dieses Niveau ist eine Funktion $\tau: \mathbb{N}_0 \times \mathbb{N}_0 \rightarrow \mathbb{R}$, die dem aktuellen Punktrückstand Δ_t und der verbleibenden Turnierlänge $T - t$ die Mindestanforderung $\tau(\Delta_t, T - t)$ zuordnet und im Backtest kalibriert wird.

$$(x^*, y^*)_{B2} = \arg \max_{(x^*, y^*) \in \{0, \dots, X_{\max}\}^2} \mathbb{P}(\text{Rang}_T = 1 \mid x^*, y^*, \Delta_t, C_m) \quad \text{u.d.N.} \quad \mathbb{E}[S] \geq \tau(\Delta_t, T - t) \quad (1)$$

Die bedingte Wahrscheinlichkeit $\mathbb{P}(\text{Rang}_T = 1 \mid \cdot)$ ist dabei kein myopischer Ausdruck über lediglich das aktuelle Spiel. Sie wird über die vollständige Monte-Carlo-Turniersimulation aus Abschnitt 6 ausgewertet, welche alle verbleibenden Spiele unter dem Gegnermodell C_m ausrollt und die eigenen künftigen Tipps gemäß derselben Politik wählt. Auf diese Weise geht der Fortsetzungswert der Rückwärtsinduktion in die Bewertung des aktuellen Tipps ein. Diese Formulierung stellt sicher, dass das System niemals äußerst unwahrscheinliche oder punktemäßig ineffiziente Ergebnisse wählt, sondern ausschließlich solche, die eine mathematisch begründete Wahrscheinlichkeit für eine erfolgreiche Aufholjagd bei gleichzeitig vertretbarem punktetechnischen Erwartungswert bieten. Das System wählt somit einen *risikoadjustierten* Tipp, der das Risiko des Punktverlustes gegen die Opportunität des Turniergewinns abwägt.

Bemerkung 3.1 (Warum die Modi nicht ineinander überführbar sind). *Modus A optimiert die absolute Wachstumsrate des Kapitals gegenüber einem Marktmechanismus. Diese Zielsetzung ist disjunkt zu Modus B1, da dieser ausschließlich den Erwartungswert der Punkte maximiert und dabei weder Wettquoten noch Kapitalallokation adressiert. Eine Überführbarkeit scheitert hier an der fundamentalen Differenz zwischen der Maximierung des erwarteten Punktertrags unter einem Punkteschema (B1) und der Ausnutzung von Marktineffizienzen (A). Eine Äquivalenz zu Modus B2 ist ebenfalls ausgeschlossen, da dieser den relativen Rang in einem kompetitiven Umfeld maximiert. Strategien aus Modus A sind in Modus B2 suboptimal, da sie die strategische Interaktion mit Mitspielern sowie die Dynamik des Turnierverlaufs ignorieren, während B2 hingegen die individuellen Marktquoten aus A ignoriert. Zusammenfassend adressiert Modus A Kapitalmärkte, Modus B1 reine Statistik und Modus B2 spieltheoretischen Wettbewerb.*

4 Datenarchitektur

4.1 Kanonisches Datenmodell

Alle Quellen werden in ein kanonisches Match-Schema überführt (ein Datensatz pro Spiel):

Feld	Typ	Beschreibung
match_id	str	deterministischer Hash aus Datum + Teams
date	date	Spieltag (Kalenderdatum)
team_home/away	str	kanonisch normalisierte Teamnamen (Mapping <code>former_names.csv</code>)
goals_home/away	int	Tore nach 90 Min.
goals_home/away_aet	int?	Tore nach Verlängerung (falls K.o.)
penalty_winner	str?	Sieger Elfmeterschießen (falls)
tournament	enum	WM, EM, Quali, Freundschaftsspiel, ...
stage	enum	Gruppe, Achtelfinale, ... (gejoint, nur Turniere)
neutral	bool	neutraler Spielort
host_home/away	bool	Team ist Gastgeber des Turniers
city, country	str	Spielort (für Reise-/Höhenfeatures)
elo_home/away	float	Elo-Rating zum Stichtag vor dem Spiel
odds_open/close	float ³	Marktquoten 1X2 (sofern verfügbar)

Ein Fragezeichen hinter einem Typ (etwa `int?` oder `str?`) kennzeichnet ein optionales Feld, das leer bleiben darf, wenn die Information fehlt oder nicht anwendbar ist (etwa Verlängerungstore bei einem Gruppenspiel).

Annahme 4.1 (Zeitstempel-Disziplin). *Jedes abgeleitete Feature (Elo, Form, Marktwert) trägt einen Gültigkeits-Zeitstempel und wird ausschließlich mit Informationsstand vor Anpfiff berechnet. Dies wird technisch erzwungen, nicht nur konventionell vereinbart (Abschnitt 10.1).*

4.2 Datenquellen und Priorisierung

Daten	Quelle	Kosten	Prio	Verwendung
Ergebnisse und Ratings				
Länderspiele seit 1872 (Ergebnis, Ort, Turnier)	Kaggle „International football results“ (martj42)	frei	P0	Modelltraining
Elo Nationalteams, zeitkausal pro Spiel	eigene Engine aus Ergebnissen nach eloratings.net Methodik	frei	P0	Feature, Baseline
Elo Live Snapshot	eloratings.net	frei	P1	Quervervalidierung
FIFA Ranking 1992 bis 2024	Kaggle Archive	frei	P1	Feature
SPI Ratings und Matchprognosen 2016 bis 2023	FiveThirtyEight (spi_matches_int1)	frei	P2	Benchmark und Feature
Club Elo tagesgenau 2000 bis 2026	clubelo.com	frei	P2	Vereinsmodell
Quoten				
Turnierquoten 1X2 Nationalteams 2005 bis 2016 (Closing, EM 2016 Open und Close)	Beat The Bookie	frei	P0 ^(A)	Backtest Modus A, Benchmark
Turnierquoten 1X2 WM, EM, Copa 2018 bis 2024	FootyStats (c-dl.php)	frei	P0 ^(A)	Backtest Modus A (Test Set)
Vereinsliga Quoten 1X2, Open ab 2002, Close ab 2012/13, Historie ab 1993/94	football-data.co.uk	frei	P0 ^(A)	Modus A Proof of Concept
UEFA Klubquoten 2005 bis 2016 (Closing, Open und Close)	Beat The Bookie	frei	P2	Eurocup Backtest
Quoten live WM 2026	The Odds API (Free Tier)	frei	P0 ^(A)	Betrieb Modus A
Eurocup und Bundesliga				
UEFA Klubwettbewerbe Ergebnisse 1955 bis 2026 (rund 28000)	Kaggle (rtx666x3)	frei	P2	Klubstärke Kontext
Club Football Engineered 2000 bis 2025 (230000 Spiele mit Elo, Form, Quoten)	Kaggle (adamgbor)	frei	P2	Referenz und Klubmodell
OpenLigaDB BL1 und BL2 2010 bis 2025 mit Tor-Timelines	OpenLigaDB	frei	P3	minutengenau, jenseits des Pre-Match-Scopes
European Soccer Database 2008 bis 2016 (Aufstellungen, FIFA Attribute)	Kaggle	frei	P2	schliesst xG Luecke EM 2016
Spieler und Kader				
Kader Marktwerte Nationalteams	Transfermarkt Mirror	frei (ToS)	P1	Stärke Prior (log Skala)
Spielerbelastung (Vereinsminuten je Spiel)	Kaggle player-scores (appearances)	frei	P2	Phase 2
Verletzungshistorie und Verfügbarkeit	Transfermarkt via worldfootballR, Kaggle Mirror	frei (ToS)	P3	Verfügbarkeit von Schlüsselspielern

Daten	Quelle	Kosten	Prio	Verwendung
Spieler Athletik FIFA 15 bis FC 26, alle Jahrgänge	Kaggle EA FC und sofifa	frei	P2	Phase 2
Football Manager Datenbanken (FM17, FM20, FM21, FM23)	Community Mirrors	frei	P2	Attribut Tiefe
xG Turnierspiele 2018 bis 2024	StatsBomb Open Data	frei	P2	Phase 2
Aufstellungen Turnierspiele	StatsBomb Open Data	frei	P2	HHI, Legionäre
Kaderlisten und Spielerratings je Turnier	FootyStats (type=players)	frei	P2	HHI, Legionäre
Internationale xG ab 2018	FBref (Opta) via soccerdata	frei (ToS)	P3	xG vor StatsBomb Abdeckung
Wyscout Event Daten (Pappalardo, rund 520 MB)	Figshare	frei	P3	eigenes xG Modell (Future Work)
Kontext und alternative Signale				
Trainerhistorie Nationalteams	Wikidata SPARQL	frei	P2	Trainerwechsel Indikator
WM 2026 Base Camps	Wikipedia	frei	P2	Reise und Akklimatisierung
Anstoss Wetter je Turnierspiel	Open-Meteo Archiv	frei	P2	Klima Features
Höhenlage der Spielorte	Open-Meteo Elevation	frei	P2	Altitude Kovariate
Geokoordinaten und Zeitzonen	Open-Meteo Geocoding	frei	P2	Reisedistanz, Jetlag
Schiedsrichterprofile (Karten und Elfmeterdaten)	abgeleitet aus Match Daten	frei	P2	Tiebreaker Heuristik, Bias
Wikipedia Pageviews	Wikimedia REST API	frei	P3	Aufmerksamkeits Proxy
Prediction Markets (Polymarket, Manifold)	oeffentliche APIs	frei	P3	Markt Quervalidierung
News Tonalität	GDELT DOC API	frei	P3	Stimmungs-Proxy
Suchinteresse Google Trends	pytrends bzw. offizielle Alpha API	frei	P3	Aufmerksamkeit, Beschaffung fragil
Strukturierte Ergebnisse und Kaderlisten	openfootball, football.db (CC0)	frei	P3	Quervalidierung

P0 ist Pflicht für den Kern. Das Kürzel ⁽⁴⁾ markiert eine Pflicht nur für Modus A. P1 ist stark erwünscht. P2 ist optional bzw. Phase 2. P3 ist explorativ bzw. Future Work. Das Kürzel HHI bezeichnet den Herfindahl-Hirschman-Index der Kaderkonzentration, also die Summe der quadrierten Anteile (etwa der Vereinszugehörigkeiten) innerhalb eines Kaders.

4.3 Datenqualität und bekannte Probleme

- **Teamnamen-Normalisierung:** historische Umbenennungen und Rechtsnachfolgen (UdSSR→Russland, Jugoslawien→Serbien, Tschechoslowakei) werden über eine explizite Mapping-Tabelle mit Gültigkeitszeiträumen behandelt.
- **Verlängerungstore:** Quelldatensätze mischen teils 90-Minuten- und 120-Minuten-Ergebnisse. Für K.o.-Spiele werden *beide* Ergebnisse rekonstruiert (90 Minuten und Endstand inkl. Verlängerung samt Elfmeter-Sieger): Die Zielrunde wertet nach Elfmeterschießen (Abschnitt 9.1), Backtests anderer Schemata und das Modelltraining benötigen die 90-Minuten-Basis.
- **Quoten-Survivorship (Turniere):** Für ältere Turniere existieren Quoten nur von wenigen Buchmachern; wir dokumentieren pro Turnier die Abdeckung und rechnen ROI-Backtests nur auf Spielen mit belegten Quoten.

- **Zusammengesetzte Turnierquoten-Basis:** Da keine einzelne freie Quelle alle Zielturniere abdeckt, wird die Turnierquoten-Basis aus drei Quellen zusammengesetzt: (i) der Beat-The-Bookie-Datensatz liefert Closing-Quoten für Senior-Nationalmannschaftsspiele 2005–2015 (u. a. WM 2006/2010/2014, EM 2008/2012) sowie, aus den Quoten-Zeitreihen der Serie B, Opening- und Closing-Quoten für 2016 inkl. der kompletten EM 2016; (ii) FootyStats liefert pre-match 1X2-Quoten für die jüngeren Turniere (WM 2018/2022, EM 2021/2024, Copa 2019/2021/2024); (iii) das WorldCup-Workbook von football-data.co.uk dient als Quervervalidierung für WM 2014–2022 und liefert die 2026er-Qualifikation. Die Quellen unterscheiden sich in Quotentyp (Closing vs. pre-match) und Buchmacher-Aggregation; die Heterogenität wird im Backtest-Bericht je Turnier ausgewiesen, und CLV-Analysen sind nur auf der Open/Close-belegten Teilmenge zulässig.
- **Quoten-Abdeckung football-data.co.uk:** Diese Quelle deckt ausschließlich nationale Vereinsligen ab, keine WM-/EM-Turnierspiele. Open-Quoten (1X2) liegen für die Topligen ab ~2002/03 vor, Closing-Quoten (inkl. Pinnacle, nötig für CLV) erst ab 2012/13 (schottische Unterligen ab 2016/17). Modus A wird daher zunächst auf Vereinsligen 2012/13–heute als Proof-of-Concept validiert (exzellente, reichhaltige Quoten-Coverage, Heimat des Dixon-Coles-Modells); die Turnier-Backtests laufen separat auf der dünneren, aber zielrelevanten Turnierquoten-Basis.
- **Freundschaftsspiele:** systematisch geringere Intensität (Rotation); sie erhalten im Modell ein eigenes Wettbewerbsgewicht (Abschnitt 5.2).

4.4 Abgeleitete Merkmalsdatensätze

Aus den vorhandenen Rohdaten werden mehrere Datensätze *generiert*, die latentes Signal sichtbar machen, das in keiner Einzelquelle direkt steht. Jeder entsteht durch ein reproduzierbares Skript der Standardbibliothek und liegt unter `Data/Custom_Data`. Wo sie als Merkmal dienen, sind sie strikt zeitkausal berechnet. Sie gelten als Hypothesen und gehen erst dann in den Kern ein, wenn sie im zeitkausalen Backtest out of sample einen Mehrwert belegen (Abschnitt 10).

Die erste Gruppe arbeitet auf der Nationalteam- und Quotenebene und kann direkt als Kernmerkmal kandidieren.

- **Konföderationskalibrierung.** Aus den interkontinentalen Spielen wird je Konföderation ein Elo Offset geschätzt, der die schwach identifizierte Niveaurelation zwischen den Konföderationen korrigiert. Der Befund ist deutlich, denn das Elo überschätzt sämtliche Konföderationen außer UEFA und CONMEBOL (`confederation_elo_offsets.csv`).
- **Form und Finishing Residuen.** Tatsächliche Punktausbeute minus Elo Erwartung sowie Tore minus Expected Goals, jeweils als vor dem Spiel bekannter gleitender Mittelwert (`elo_form_residuals.csv`, `xg_finishing_residuals.csv`).
- **Reise und Höhenlast der WM 2026.** Je Team die kumulierten Reisekilometer, Zeitzonensprünge und Höhenmeter über den Gruppenspielplan (`wc2026_team_burden_summary.csv`).
- **Linienbewegung und Closing Line Value.** Drift der entvigten Wahrscheinlichkeiten von der Eröffnung zur Schlussquote als Proxy für informierten Geldfluss. In fast allen geprüften Ligen ist die Schlusslinie schärfer als die Eröffnung (`line_movement_clv.csv`).
- **Crowd Tip Prior.** Eine nach Favoritenstärke bedingte Verteilung über Ergebnistipps als Startwert für das Gegnermodell C_m in Modus B2, bevor Live Tipps vorliegen (`crowd_tip_prior_by_band.csv`).
- **Favorite Longshot Bias.** Die empirische Kalibrierung der Quoten je Favoritenband über rund 420000 Spiele zeigt, dass starke Favoriten leicht unterbewertet und schwache Aussenseiter stark überbewertet werden (`favorite_longshot_bias.csv`).

Die zweite Gruppe entsteht aus frei verfügbaren Eventdaten (Wyscout 2017/18 und StatsBomb) und liegt damit auf Vereins- und Turnierebene. Diese Datensätze sind explorativ und dienen der Merkmalsforschung. Kein Kernbaustein der WM-Prognose konsumiert sie derzeit, sie sind ausdrücklich als Future Work eingestuft (Abschnitt 13).

- **Spielstilmetriken.** Je Team und Spiel ein Stilprofil aus Ballbesitzanteil, Field Tilt, PPDA als Pressingmass, Defensivhöhe und Direktheit sowie erwarteten Toren für und gegen (`match_style.csv`).
- **Passnetzwerke.** Je Team und Spiel Kennzahlen des Passspiels wie Vertikalität, Netzwerkzentralisierung sowie genutzte gegen ungenutzte Passlinien (`passing_networks.csv`).
- **Granulare Passlinien.** Das vollständige Passnetzwerk je Spiel als Kantenliste von Passgeber zu Empfänger mit Anzahl und Vorwärtsanteil (`passing_lanes.csv`).
- **Neuartige Spielermetriken.** Rollenbeiträge jenseits klassischer Statistik je Spieler und Einzelspiel, etwa der mitspielende Torwart über Aktionen außerhalb des Strafraums, dazu Ballfortschrittswert und progressive Pässe, mehr als 128000 Zeilen aus Wyscout und StatsBomb (`player_metrics.csv`).
- **Erwartete Bedrohung (xT).** Jeder Feldzone wird ein Bedrohungswert zugeordnet, sodass eine erfolgreiche Ballbewegung mit der Wertdifferenz zwischen Ziel und Ausgang bewertet wird. Das Gitter wird auf dem Wyscout Korpus gelernt und auf StatsBomb angewandt, damit die Werte quellenübergreifend vergleichbar bleiben (`xt_player_match.csv`, `xt_team_match.csv`, `xt_grid.csv`).
- **Stilstabilität.** Die Schwankung der Stilkennzahlen eines Teams von Spiel zu Spiel, innerhalb von Wettbewerb und Saison standardisiert. Ein konstantes Profil bedeutet taktische Vorhersehbarkeit (`team_style_stability.csv`).
- **Pressresistenz.** Wie gut ein Spieler den Ball unter gegnerischem Druck behält und weiterspielt, aus dem StatsBomb Merkmal `under pressure` (`press_resistance.csv`).
- **Stilarchetypen und Matchups.** Jedes Team erhält je Saison einen Stilarchetyp, und je Paarung wird die Bedrohungsbilanz gemessen. Auf der Ebene der erwarteten Tore zeigt sich dabei kein Schere Stein Papier, vielmehr erzeugt Ballbesitzdominanz gegen jeden Stil mehr xG, weil dieser Archetyp faktisch Qualität abbildet (`team_style_archetype.csv`, `style_matchup_matrix.csv`).
- **Schiedsrichtereskalation.** Die Wechselwirkung aus Foulrate eines Teams und Strenge des Schiedsrichters auf die Kartenzahl. Der Effekt ist vorhanden, aber klein (`referee_escalation.csv`, `referee_strictness.csv`).
- **Disziplinarbild je Spiel.** Je Spieler und Spiel die Fouls und Karten zusammen mit Gegner und Hauptschiedsrichter, dazu je Spiel eine Schiedsrichterübersicht (`player_match_discipline.csv`, `match_officiating.csv`).

5 Das stochastische Modell (Schicht 1)

Dieses Kapitel beschreibt mehrere Modellfamilien. Der verbindliche Kernpfad besteht aus dem Dixon-Coles-Modell mit Zeitgewichtung (Abschnitte 5.2), dem Elo-Referenzmodell (Abschnitt 5.7) und der Kalibrierung. Alle weiteren Familien dieses Kapitels (Copula, Zustandsraum, bayesianische Hierarchie, Gradient Boosting, Ensemble) sind optionale Erweiterungen, die einzeln ihren Mehrwert out of sample belegen müssen, bevor sie in den Kern aufsteigen.

5.1 Unabhängige Poisson-Zählprozesse als Basismodell

Als Ausgangspunkt für die stochastische Modellierung dient der Ansatz von Maher [23]. Für ein Spiel $m \in \mathcal{M}$ zwischen dem Heimteam $i = i(m)$ und dem Gastteam $j = j(m)$ nehmen wir an, dass die Torzahlen X_m und Y_m bedingt auf die Intensitäten (λ_m, μ_m) unabhängig und Poisson-verteilt sind. Das heißt, es existieren Intensitätsparameter $\lambda_m > 0$ und $\mu_m > 0$, sodass für alle $x, y \in \mathbb{N}_0$

$$\mathbb{P}(X_m = x, Y_m = y) = \frac{\lambda_m^x e^{-\lambda_m}}{x!} \cdot \frac{\mu_m^y e^{-\mu_m}}{y!}$$

gilt. Die erwarteten Tor-Intensitäten λ_m und μ_m werden als log-lineare Funktionen der latenten Teamstärken modelliert. Dabei stellt $\gamma \in \mathbb{R}$ einen globalen Niveau-Parameter (die Basis-

Torfrequenz) dar. Für jedes Team $k \in \mathcal{I}$ seien $\alpha_k \in \mathbb{R}$ die Angriffsstärke und $\beta_k \in \mathbb{R}$ die Verteidigungsstärke. Zudem wird der Indikator für einen eventuellen Heimvorteil des Teams i im Spiel m durch $h_m \in \{0, 1\}$ abgebildet und über den zugehörigen Skalierungsparameter $\eta \in \mathbb{R}$ gewichtet. Es gilt

$$\log \lambda_m = \gamma + \alpha_i - \beta_j + \eta \cdot h_m, \quad \log \mu_m = \gamma + \alpha_j - \beta_i. \quad (2)$$

Um die formale Identifizierbarkeit des Parametervektors sicherzustellen, werden zusätzlich die linearen Nebenbedingungen $\sum_{k \in \mathcal{I}} \alpha_k = 0$ und $\sum_{k \in \mathcal{I}} \beta_k = 0$ gefordert.

Spielstätten-Effekte und geografische Belastung. Die erwartete Tor-Intensität wird durch spezifische Kovariaten modifiziert:

- **Regulärer Heimvorteil (η):** In Qualifikationsspielen existiert ein starker Heimvorteil, der über den Indikator h_m aktiviert wird.
- **Host-Effekt (η_{host}):** Bei Turnieren gibt es keinen regulären Heimvorteil (neutraler Boden), aber der Gastgeber profitiert von Fanunterstützung und vertrautem Klima. Dieser Effekt ist historisch stark, aber schwächer als der reguläre Vereinsheimvorteil [27, 28]. Bei Turnieren mit mehreren Gastgebern wird der Effekt granular vergeben.
- **Höhenlage (Altitude):** Ein relevanter Faktor bei Spielen in großer Höhe. Die zugrundeliegende Evidenz stammt aus südamerikanischen Begegnungen (etwa La Paz), überträgt sich aber auf die hochgelegenen Austragungsorte der WM 2026 wie Mexiko-Stadt auf rund 2240 Metern. Teams aus dem Flachland verzeichnen dort einen messbaren Leistungsabfall durch physiologische Ermüdung [24].
- **Reisedistanz & Zeitzone:** Extreme Distanzen führen zu Jetlag und verlorenen Trainingstagen [29], was als dämpfende Kovariate in die Intensitätsgleichung einfließt. Um eine Parameterinflation und ein Überanpassungsrisiko auf den relativ dünnen Länderspieldaten zu vermeiden, wird für all diese Kovariaten eine sparsame Grundspezifikation erzwungen. Jeder Zusatzterm muss seinen Mehrwert zwingend in einer Ablationsstudie außerhalb der Stichprobe belegen, andernfalls entfällt er.

5.2 Dixon-Coles-Korrektur und Zeitgewichtung

Empirisch weichen niedrige Ergebnisse ($0 : 0, 1 : 1, 1 : 0, 0 : 1$) von der Unabhängigkeitsannahme ab. Zur Korrektur führen Dixon und Coles [11] einen Interaktionsparameter $\rho \in \mathbb{R}$ ein (der typisch leicht negativ ist), welcher die stochastische Abhängigkeit kontrolliert. Zusammen mit den Tor-Intensitäten $\lambda > 0$ und $\mu > 0$ moduliert der Faktor $\tau_{\lambda, \mu}(x, y)$ die gemeinsame Wahrscheinlichkeitsfunktion

$$\mathbb{P}(X = x, Y = y) = \tau_{\lambda, \mu}(x, y) \cdot \frac{\lambda^x e^{-\lambda}}{x!} \cdot \frac{\mu^y e^{-\mu}}{y!}.$$

Hierbei ist der Korrekturfaktor fallweise definiert als

$$\tau_{\lambda, \mu}(x, y) = \begin{cases} 1 - \lambda\mu\rho & \text{für } (x, y) = (0, 0), \\ 1 + \lambda\rho & \text{für } (x, y) = (0, 1), \\ 1 + \mu\rho & \text{für } (x, y) = (1, 0), \\ 1 - \rho & \text{für } (x, y) = (1, 1), \\ 1 & \text{sonst.} \end{cases}$$

Damit alle Zellwahrscheinlichkeiten nichtnegativ bleiben, ist der Parameter ρ auf den Bereich $\max(-1/\lambda, -1/\mu) \leq \rho \leq \min(1/(\lambda\mu), 1)$ beschränkt. Die Parameterschätzung für den Parametervektor θ erfolgt durch die Maximierung einer zeit- und wettbewerbsgewichteten Log-Likelihood

zum Prognosezeitpunkt t . Sei $N = |Z|$ die Anzahl der betrachteten Nationalteams. Der Parametervektor θ bündelt sämtliche zu schätzenden Modellkomponenten und ist definiert als

$$\theta = (\alpha_1, \dots, \alpha_N, \beta_1, \dots, \beta_N, \gamma, \eta, \rho)^T.$$

Aufgrund der mathematischen Nebenbedingungen und Modellrestriktionen liegt θ in einem eingeschränkten Parameterraum $\Theta \subset \mathbb{R}^{2N+3}$, welcher durch folgende Menge beschrieben wird

$$\Theta = \left\{ \theta \in \mathbb{R}^{2N+3} \mid \sum_k \alpha_k = \sum_k \beta_k = 0, \max\left(-\frac{1}{\lambda_m}, -\frac{1}{\mu_m}\right) \leq \rho \leq \min\left(\frac{1}{\lambda_m \mu_m}, 1\right) \text{ für alle } m \right\}.$$

Durch die beiden Identifizierbarkeitsbedingungen (Nullsummen-Restriktionen) verbleiben innerhalb von Θ exakt $2N + 1$ frei zu optimierende Dimensionen.

Hierbei reguliert die Zerfallsrate $\xi > 0$ eine zeitliche Gewichtungsfunktion $g: \mathbb{R}_{\geq 0} \rightarrow (0, 1]$, ausgewertet an der Zeitdifferenz $\Delta t = t - t_m$ zwischen Prognosezeitpunkt und Anpfiff, sodass weiter in der Vergangenheit liegende Spiele einen exponentiell gegen Null sinkenden Einfluss aufweisen. Die sportliche Aussagekraft eines historischen Spiels m wird über ein spezifisches Wettbewerbsgewicht $w_{c(m)} > 0$ gesteuert, wobei die Kategorienabbildung $c: \mathcal{M} \rightarrow \{1, 2, 3, 4\}$ jedem Spiel seine Turniereinstufung zuordnet. Die im Parameterraum Θ zu maximierende Zielfunktion lautet

$$\ell(\theta; t) = \sum_{m: t_m < t} g(t - t_m) \cdot w_{c(m)} \cdot \log \mathbb{P}_\theta(X_m = x_m, Y_m = y_m), \quad (3)$$

wobei die Intensitäten λ_m und μ_m innerhalb von $\mathbb{P}_\theta$ gemäß (2) vom Parametervektor θ abhängen. Die zeitliche Dämpfung wird dabei durch die Funktion

$$g(\Delta t) = e^{-\xi \Delta t}.$$

definiert. Das funktionale Wettbewerbsgewicht $w_{c(m)}$ differenziert die sportliche Relevanz anhand von vier diskreten Kategorien:

- **Tier 1 (Faktor 1,0):** WM- und EM-Endrundenspiele, Copa América (beste A-Kader, 100 % Einsatz).
- **Tier 2 (Faktor $\sim 0,7$ – $0,8$):** Kontinentale Qualifikationsspiele (WM-Quali, EM-Quali).
- **Tier 3 (Faktor $\sim 0,5$ – $0,6$):** UEFA Nations League (oft kompetitiv, aber experimenteller).
- **Tier 4 (Faktor $\sim 0,2$ – $0,3$):** Offizielle Freundschaftsspiele (extreme Rotation, Taktiktests).

Diese Likelihood-Gewichte (ξ und $w_{c(m)}$) skalieren direkt den Einfluss eines historischen Spiels in der Zielfunktion (3). Sie werden explizit nicht in-sample gefittet, sondern über eine zeitkausale Kreuzvalidierung auf dem Validierungsfenster optimiert.

5.3 Alternative Kopplung und Überdispersion

Die Formulierung des Modells sieht verschiedene mathematische Architekturen vor, welche als alternative Kandidaten im Quellcode verankert sind und außerhalb der Stichprobe miteinander konkurrieren. Diese Modellvarianten werden nicht innerhalb einer gemeinsamen Likelihood verschmolzen, sondern zunächst getrennt geschätzt. Ihre fertigen Prognosen werden erst auf der Ausgabeebene durch das Ensemble aus Abschnitt 5.8 konvex kombiniert.

Variante 1 mit einer geteilten Poisson-Komponente Als strukturelle Alternative für die stochastische Abhängigkeit betrachten wir den Ansatz von Karlis und Ntzoufras [17]. Für einen Index $k \in \{1, 2, 3\}$ seien Z_k unabhängige Poisson-verteilte Zufallsvariablen mit den Intensitätsparametern $\lambda_k > 0$. Die Modellierung der Torvariablen erfolgt linear. Es gilt

$$X = Z_1 + Z_3, \quad Y = Z_2 + Z_3.$$

Der geteilte Prozess Z_3 repräsentiert hierbei eine latente gemeinsame Spielintensität. Dadurch entsteht auf natürliche Weise eine positive Kovarianz $\text{Cov}(X, Y) = \lambda_3 > 0$.

Wie Abbildung 1 illustriert, löst dieser Ansatz das Problem unabhängiger Torverteilungen. Während ein Modell ohne gemeinsame Intensität eine nahezu unkorrelierte Torverteilung erzeugt, streckt ein aktiver geteilter Prozess die Wahrscheinlichkeitsmasse entlang der Diagonalen. Hohe und unentschiedene Ergebnisse erhalten dadurch systemisch höhere Wahrscheinlichkeiten, was das empirische Phänomen eines beidseitig offenen Schlagabtauschs abbildet.




Abbildung 1: Vergleich der Torverteilungen im bivariaten Poisson Modell. Das linke Bild zeigt ein taktisch geschlossenes Spiel ohne gemeinsame Intensität. Die Verteilung der Tore ist stochastisch unkorreliert. Das rechte Bild simuliert einen offenen Schlagabtausch. Der geteilte Prozess zwingt die Verteilung auf die Diagonale und erzeugt eine starke positive Korrelation, was torreiche Remis und knappe hohe Ergebnisse wahrscheinlicher macht.

Der gravierende Nachteil dieser ersten Variante liegt jedoch in der Beibehaltung der Poisson-Ränder. Das Modell erzwingt somit trotz der Korrelation weiterhin die strikte Äquidispersion $\text{Var}(X) = \mathbb{E}[X]$, wodurch das empirische Phänomen der Überdispersion unberücksichtigt bleibt. Aus diesem Grund liegt der primäre Fokus bei der programmtechnischen Umsetzung auf der nachfolgenden Copula-Architektur, während dieses Poisson-Netzwerk lediglich als algorithmische Baseline herangezogen wird.

Variante 2: Behandlung der Überdispersion via diskreter Copula. Um zusätzlich die bei extremen Leistungsunterschieden auftretende empirische Überdispersion, bei welcher die Varianz den Erwartungswert übertrifft, abzufangen, dürfen die Randverteilungen nicht naiv mit der Korrektur von Dixon und Coles multipliziert werden. Diese Korrektur ist exakt für Poisson-Ränder hergeleitet und verfälscht bei anderen Verteilungsformen die Wahrscheinlichkeitsmasse. Wir weichen daher auf das Theorem von Sklar [33] für diskrete Verteilungen aus, unter bewusster Beachtung des Eindeutigkeitsproblems der Copula bei Zähldaten [13]. Die Ränder werden durch marginale Negativbinomialmodelle gebildet, welche über einen Dispersionsparameter $\alpha_{\text{disp}} \in \mathbb{R}_{>0}$ verfügen. Für die Auswertung definieren wir die kumulativen Verteilungsfunktionen dieser Ränder als $F_X(x) \in [0, 1]$ und $F_Y(y) \in [0, 1]$. Die Kopplung der gemeinsamen Verteilungsfunktion erfolgt über eine bivariat definierte Copula C_ϑ mit dem Abhängigkeitsparameter $\vartheta \in \mathbb{R} \setminus \{0\}$, wie beispielsweise der Frank-Copula. Die multivariate Verteilungsfunktion für die diskreten Zufallsvariablen der Tore $X \in \mathbb{N}_0$ und $Y \in \mathbb{N}_0$ lautet

$$\mathbb{P}(X \leq x, Y \leq y) = C_\vartheta(F_X(x), F_Y(y)).$$

Für die Berechnung der diskreten Punktwahrscheinlichkeiten auf dem unendlichen Träger nutzen wir die Transformationen $u_x = F_X(x) \in [0, 1]$ sowie $v_y = F_Y(y) \in [0, 1]$. Unter Einbeziehung der um eins reduzierten Randwerte $u_{x-1} = F_X(x-1)$ und $v_{y-1} = F_Y(y-1)$, wobei für negative Argumente der Funktionswert als null definiert ist, bestimmen wir die Wahrscheinlichkeiten durch

eine endliche Differenzierung auf dem diskreten Gitter. Die exakten Zellwahrscheinlichkeiten der Ergebnismatrix lauten

$$\mathbb{P}(X = x, Y = y) = C_{\vartheta}(u_x, v_y) - C_{\vartheta}(u_{x-1}, v_y) - C_{\vartheta}(u_x, v_{y-1}) + C_{\vartheta}(u_{x-1}, v_{y-1}).$$

Dieser Formalismus garantiert die Erhaltung des Wahrscheinlichkeitsmaßes mit einer Summe von eins über den gesamten Träger bei gleichzeitig exaktem Erhalt der überdispersen Randmomente. Die funktionale Interpretation der Parameter verdeutlicht die stochastische Flexibilität dieser Architektur. Während die Erwartungswerte die generelle Torgefährlichkeit abbilden, reguliert der Dispersionsparameter α_{disp} die reine Tagesform und somit die Volatilität eines Teams völlig isoliert von der Stärke des Gegners. Ein großer Wert erhöht das Risiko für ein vollkommenes Versagen der Offensive, fördert aber simultan die Wahrscheinlichkeit für unerwartet hohe Kantersiege. Der Parameter ϑ steuert unabhängig von diesen Rändern das gemeinsame Taktikband zwischen den Mannschaften.

Wie in Abbildung 2 veranschaulicht wird, kann dieser Kopplungsparameter völlig verschiedene Spielverläufe generieren. Ein positiver Wert zieht die Ergebnisse elastisch auf die Diagonale und bildet einen offenen Schlagabtausch ab. Ein negatives Vorzeichen stellt hingegen eine absolute Dominanz dar, bei welcher ein Team das Spiel kontrolliert und Wahrscheinlichkeitsmasse von der Diagonalen in die extremen Randbereiche verdrängt.




Abbildung 2: Einfluss der stochastischen Kopplung in der diskreten Frank-Copula mit negativen Binomialrändern. Das linke Bild zeigt eine positive Abhängigkeit, bei welcher ein offener Schlagabtausch torreiche Remis fördert. Das rechte Bild illustriert eine negative Abhängigkeit. Hierbei führt ein dominantes Spiel zu einer Abstoßung von der Diagonalen, wodurch einseitige Siege wahrscheinlicher werden.

Anstatt sich am Ende auf eine einzige isolierte Architektur zu verlassen, implementiert das System ein dynamisches Ensemble. Die verschiedenen Modellkandidaten besitzen situative Stärken. Während die Copula bei asymmetrischen Begegnungen mit hoher Varianz brilliert, liefert das klassische Modell von Dixon und Coles in datenarmen oder stark taktisch geprägten Spielen eine extrem robuste und sichere Prognose. Die finalen Vorhersagewahrscheinlichkeiten werden daher nicht durch eine harte Selektion bestimmt, sondern über eine gewichtete Kombination aller Kandidaten aggregiert. Die jeweiligen Gewichtungsfaktoren der einzelnen Modelle werden hierbei strikt out of sample anhand ihres historischen Log-Loss auf der vollen Ergebnismatrix fortlaufend berechnet (Details in Abschnitt 5.8).

5.4 Dynamische Teamstärken in einer Zustandsraum-Formulierung

Statische Angriffsstärken und Verteidigungsstärken erweisen sich über den mehrjährigen historischen Betrachtungszeitraum der Trainingsdaten als unzureichend, da Generationenwechsel

oder Trainereffekte die Leistungsfähigkeit der Nationalmannschaften zwischen den Endrunden kontinuierlich verändern. Wir modellieren die zeitlichen Pfade der latenten Parameter daher als stochastische Prozesse im Rahmen eines Random-Walk-Modells [31, 20]. Für ein Team $k \in \mathcal{I}$ und einen diskreten Zeitindex t seien $\varepsilon_{k,t}^\alpha \sim \mathcal{N}(0, \sigma_\alpha^2)$ sowie $\varepsilon_{k,t}^\beta \sim \mathcal{N}(0, \sigma_\beta^2)$ unabhängige und normalverteilte Innovationsfehler mit den konstanten Varianzen $\sigma_\alpha^2 \in \mathbb{R}_{>0}$ und $\sigma_\beta^2 \in \mathbb{R}_{>0}$. Die Evolution der Angriffsstärke $\alpha_{k,t} \in \mathbb{R}$ und der Verteidigungsstärke $\beta_{k,t} \in \mathbb{R}$ wird durch die Differenzengleichungen

$$\alpha_{k,t+1} = \alpha_{k,t} + \varepsilon_{k,t}^\alpha, \quad \beta_{k,t+1} = \beta_{k,t} + \varepsilon_{k,t}^\beta$$

beschrieben. Die informationelle Verknüpfung mit den realen Torbeobachtungen erfolgt hierbei invariant über die loglineare Beobachtungsgleichung (2). Der hierarchische Prior aus Abschnitt 5.5 bezieht sich dabei auf die Startwerte $\alpha_{k,0}$ und $\beta_{k,0}$ dieses Random-Walks, von denen die Innovationen anschließend driften.

Heteroskedastische Innovationsvarianz Empirische Evidenz aus der sportstatistischen Literatur zeigt, dass der Stärkedrift im historischen Verlauf nicht homoskedastisch verläuft [14, 16]. Nationalmannschaften in einer fundamentalen Umbruchphase durch einen neuen Trainer oder einen hohen Anteil an Debütanten weisen eine signifikant höhere kurzfristige Volatilität auf [10, 26]. Die Basisvariante des Systems nutzt die konstanten Varianzen aus dem vorangehenden Absatz. Die folgende heteroskedastische Erweiterung ist als Phase-2-Verfeinerung eingestuft und ersetzt die Basisvariante erst nach belegtem Mehrwert. Für die lineare Gewichtung definieren wir die reellen Koeffizienten $b_0 \in \mathbb{R}$, $b_1 \in \mathbb{R}$ und $b_2 \in \mathbb{R}$. Die zeitliche Dynamik wird durch die metrische Altersvarianz des aktuellen Kaders $V_{k,t}^{\text{Alter}} \in \mathbb{R}_{\geq 0}$ (aus den Kaderlisten der Datenarchitektur) sowie durch einen binären Indikator für einen kürzlichen Wechsel auf der Trainerposition $I_{k,t}^{\text{Trainer}} \in \{0, 1\}$ (aus der Trainerhistorie, Abschnitt 4.2) operationalisiert. Die zeitvariable Innovationsvarianz der Angriffsstärke bestimmt sich durch die loglineare Beziehung

$$\log \sigma_{\alpha,k,t}^2 = b_0 + b_1 \cdot V_{k,t}^{\text{Alter}} + b_2 \cdot I_{k,t}^{\text{Trainer}}.$$

Im bayesianischen hierarchischen Netzwerk der zweiten Schicht führt eine situativ erhöhte Innovationsvarianz automatisch zu einem breiteren Posterior für das betroffene Team. Diese mathematische Unsicherheit pflanzt sich bis in die finale Einsatzsteuerung fort und führt über ein autonomes Unsicherheits-Shrinkage in Abschnitt 8.3 zu einer risikoaversen Reduzierung der Wetteinsätze. Die Innovationsvarianzen kontrollieren somit direkt die Geschwindigkeit, mit welcher die latenten Fähigkeiten im Zeitverlauf driften dürfen.

Strukturelle Hierarchie der Implementierung Die exakte kontinuierliche Filterung über einen hochdimensionalen Partikelfilter ist theoretisch möglich, bricht jedoch in der Praxis an den harten Restriktionen der verfügbaren Rechenzeit. Das Gesamtsystem etabliert daher eine pragmatische hierarchische Architektur, welche aus drei komplementären Stufen besteht.

1. **Stufe 1** Die erste Stufe nutzt das zuvor definierte Modellensemble bestehend aus der Copula-Architektur sowie den Ansätzen von Dixon und Coles und Karlis und Ntzoufras. Unter Einbeziehung der exponentiellen Zeitgewichtung zur impliziten Approximation der zeitlichen Dynamik wird hierbei eine recheneffiziente Schätzung und Gewichtung aller Kandidaten innerhalb weniger Minuten realisiert.
2. **Stufe 2** Die zweite Stufe implementiert ein bayesianisches hierarchisches Modell mit einem entsprechenden Random-Walk-Prior auf der Ebene von zweijährigen Turnierzyklen, wodurch der volle Posterior über PyMC oder NumPyro in einer vertretbaren Rechenzeit extrahiert wird.
3. **Stufe 3** Die dritte Stufe repräsentiert die zukünftige Entwicklungsstufe und sieht die vollständige Integration kontinuierlicher Partikelfilter auf der Mikroebene der einzelnen Spiele vor.

5.5 Bayesianische Hierarchie und das Sparse-Data-Problem der Nationalteams

Nationalteams absolvieren im Durchschnitt lediglich zehn Länderspiele pro Jahr, welche zumeist gegen Kontrahenten aus demselben Kontinentalverband stattfinden [15]. Daraus resultieren zwei fundamentale Kernprobleme. Einerseits entsteht eine immense Parameterunsicherheit pro Team und andererseits eine schwache Identifikation der interkontinentalen Stärkerelationen. Diese globale Hierarchie zwischen den Kontinentalverbänden ist bei einer Weltmeisterschaft jedoch ein zentrales Entscheidungskriterium.

Das System adressiert diese Limitationen über eine partielle Pooling Architektur. Sei $\mathcal{C} := \{\text{UEFA}, \text{CONMEBOL}, \text{CONCACAF}, \text{CAF}, \text{AFC}, \text{OFC}\}$ die endliche Menge der sechs globalen Kontinentalverbände. Die administrative Zugehörigkeit eines Nationalteams wird durch eine deterministische und eindeutige Abbildung $\text{conf}: \mathcal{I} \rightarrow \mathcal{C}$ formalisiert. Für ein spezifisches Team $k \in \mathcal{I}$ bezeichnet somit $\text{conf}(k) \in \mathcal{C}$ exakt den Dachverband, unter welchem das Team seine offiziellen Qualifikationsspiele bestreitet. Der Erwartungswert der Angriffsstärke auf dieser kontinentalen Ebene wird folglich durch $\mu_{\text{conf}(k)}^\alpha$ abgebildet. Die Unsicherheiten werden hierarchisch durch die Varianz auf Verbandsebene σ_{conf}^2 sowie die Varianz auf Teamebene σ_{team}^2 quantifiziert. Als exogenes prädiktives Signal dient der normierte und zeitgestempelte aggregierte Kadermarktwert $\widetilde{\text{MV}}_k$, welcher über den Gewichtungskoeffizienten $\psi \in \mathbb{R}_{>0}$ skaliert wird. Die Restriktion auf positive Werte ist eine fachlich begründete Prior-Annahme, denn ein höherer Marktwert senkt die erwartete Stärke nicht. Unter Verwendung dieser Parameter erfolgt die Modellierung der Angriffsstärke α_k durch die Verteilungen

$$\alpha_k \sim \mathcal{N}(\mu_{\text{conf}(k)}^\alpha + \psi \cdot \log \widetilde{\text{MV}}_k, \sigma_{\text{team}}^2), \quad \mu_c^\alpha \sim \mathcal{N}(0, \sigma_{\text{conf}}^2), \quad c \in \mathcal{C}.$$

Die Modellierung für die Verteidigungsstärke β_k erfolgt vollständig analog. Das Modell schrumpft die Parameter von Teams mit wenigen Beobachtungen somit nicht rigoros auf null, sondern zieht sie in Richtung des kontinentalen Durchschnitts, ergänzt um dieses exogene Marktwertsignal. Seltene interkontinentale Begegnungen bei globalen Endrunden oder interkontinentalen Playoffs dienen dabei der expliziten mathematischen Identifikation der übergeordneten Erwartungswertparameter μ_c^α für alle Verbände $c \in \mathcal{C}$.

Algorithmische Inferenz Die statistische Inferenz erfolgt mittels Hamiltonian-Monte-Carlo-Algorithmen wie dem NUTS-Sampler, implementiert in PyMC oder NumPyro. Die Konvergenzdiagnostik erfordert eine strikte Begrenzung der Gelman-Rubin-Statistik auf $\hat{R} < 1,01$ sowie eine ausreichende Anzahl effektiver Stichproben. Die finale Modellvalidierung nutzt Posterior Predictive Checks gegen die empirischen Torhistogramme.

Propagierung der Parameterunsicherheit Die modellierte Parameterunsicherheit wird über alle Schichten des Systems vollständig durchgereicht. Die in Abschnitt 3.1 definierte diskrete Wahrscheinlichkeitsfunktion $\mathcal{P}_m(x, y)$ für ein konkretes Ergebnis im Spiel m berechnet sich formal als Erwartungswert über den gesamten Posterior $p(\theta \mid \mathcal{D})$, wobei $\mathcal{D}$ die Menge der bis zum Prognosezeitpunkt beobachteten Spiele samt Kovariaten bezeichnet. Die Integration über den gesamten Parameterraum Θ lautet

$$\mathcal{P}_m(x, y) = \int_{\Theta} \mathbb{P}(X_m = x, Y_m = y \mid \theta) p(\theta \mid \mathcal{D}) d\theta.$$

Für den späteren Einsatz im Modus A steht somit nicht nur dieser punktuelle Mittelwert, sondern die komplette Verteilung der geschätzten Modellwahrscheinlichkeit zur Verfügung. Ein vermeintlicher statistischer Vorteil, welcher nur unter isolierten und günstigen Parameterausprägungen existiert, löst gemäß Abschnitt 8.3 eine risikoaverse Verkleinerung der monetären Einsätze aus.

Abbildung extremer Ereignisse und Heavy Tails Klassische Zählprozesse unterschätzen die Wahrscheinlichkeit extremer Resultate maßgeblich, da die starre Poisson-Verteilung eine Gleichheit von Erwartungswert und Varianz erzwingt. Das hier entwickelte Modellsystem generiert stattdessen systematische Heavy Tails durch zwei ineinandergreifende stochastische Mechanismen. Erstens entkoppelt die zugrundeliegende negative Binomialverteilung innerhalb der Copula-Architektur die Varianz von dem Erwartungswert, wodurch außergewöhnliche Formschwankungen und taktische Aufgabeneffekte am Spieltag mathematisch zulässig werden. Zweitens transformiert die bayesianische Hierarchie die punktuellen Teamstärken in breite Wahrscheinlichkeitsverteilungen. Die finale Integration über den gesamten Parameterraum verschiebt signifikante Wahrscheinlichkeitsmasse aus dem Zentrum in die Ränder der prädiktiven Verteilung. Extreme Resultate treten in der Modellrealität somit wesentlich häufiger auf als unter der Prämisse vollkommen konstanter Parameter.

Zukünftige Erweiterung durch spieterspezifische Leistungsdaten Die Aggregation von individuellen Spielerdaten aus dem hochfrequenten Vereinsfußball bietet eine vielversprechende methodische Alternative zum rein finanziellen Kadermarktwert. Hierbei wird die Leistungsfähigkeit eines Akteurs über marginale Effekte quantifiziert. Das System analysiert die offensive und defensive Intensität des jeweiligen Vereins sowohl mit als auch ohne den spezifischen Spieler auf dem Platz. Diese isolierte Leistungsdifferenz wird in der fortgeschrittenen Sportstatistik als Adjusted-Plus-Minus-Metrik bezeichnet. Da auf Vereinsebene eine signifikant höhere Datendichte herrscht, ließe sich aus diesen wöchentlichen Beobachtungen ein empirisch fundierter Leistungsindex für die Nationalmannschaft konstruieren, welcher als prädiktives Signal in den Prior der bayesianischen Hierarchie einfließt. Der pragmatische Verzicht auf diese Bottom-Up-Architektur in der vorliegenden Basisversion begründet sich ausschließlich durch den erheblichen Aufbauaufwand der benötigten Dateninfrastruktur sowie die mathematisch komplexe Multikollinearität von Stammspielern auf Vereinsebene. Diese spielerfokussierte Aggregation verbleibt somit als primärer Entwicklungspfad für zukünftige Modelliterationen (vgl. Abschnitt 1.4 und Abschnitt 13).

5.6 Regimewechsel und turnierspezifische Strukturbrüche

Die in Abschnitt 5.4 definierte Zustandsraum Modellierung fängt einen graduellen Formdrift der Teams ab. Spezifische Turniersituationen weisen jedoch abrupte und diskrete Strukturbrüche auf welche das System durch die nachfolgenden Erweiterungen explizit berücksichtigt.

a) Das Turnierformat als struktureller Bruch und stochastischer Gleichstand

Die Erweiterung der Weltmeisterschaft auf 48 teilnehmende Mannschaften verändert die Anreizstruktur und die Wahrscheinlichkeiten für ein Weiterkommen signifikant im Vergleich zu allen historischen Turnieren des Validierungszeitraums. Das Reglement sieht zwölf Gruppen aus jeweils vier Teams vor, wobei neben den Erstplatzierten und Zweitplatzierten auch die acht besten Gruppendritten in die finale Phase einziehen. Die Monte-Carlo-Turniersimulation in Abschnitt 6 implementiert dieses exakte Regelwerk vollständig inklusive der neuen Struktur des Turnierbaums. Da die isolierte Prognose einzelner Spiele formatunabhängig ist, bleibt diese von dem Strukturbruch unberührt. Ein teamübergreifender Vergleich der Gruppendritten führt bei Punktgleichstand und Torgleichstand gelegentlich zu Pattsituationen, die das Reglement über nachgeordnete Kriterien und in letzter Instanz über einen Losentscheid auflöst. Da die für eine Fairplay Wertung nötigen Schiedsrichteransetzungen vor dem Turnier nicht zeitkausal verfügbar sind und diese Wertung historisch ohnehin fast nie den Ausschlag gibt, löst die Monte-Carlo-Engine diese seltene letzte Stufe durch einen symmetrischen und mit festem Startwert reproduzierbaren Zufallsentscheid, wie ihn das Reglement vorsieht. Die methodische Limitation, dass formatsensitive Größen auf historischen Turnieren mit lediglich 32 Teams nur eingeschränkt validierbar sind, wird im Validierungsbericht gesondert dokumentiert.

b) **Zustandsabhängige Intensitäten bei irrelevanten Spielen**

Ein zweiter Strukturbruch entsteht in den abschließenden Gruppenspielen, wenn das Weiterkommen oder Ausscheiden einer Mannschaft bereits vor dem Anpfiff mathematisch feststeht. In diesen sportlich bedeutungslosen Partien verschiebt sich die Torverteilung empirisch messbar durch eine erhöhte Kaderrotation und stark abfallende Motivationseffekte. Um diese Dynamik abzufangen, führen wir eine Indikatorvariable $I_{\text{dead}} \in \{0, 1\}$ ein, welche zeitkausal aus dem exakten Tabellenstand vor Anpfiff berechenbar ist. Diese Variable wird mit einem auf historischen Daten geschätzten reellen Koeffizienten $\zeta \in \mathbb{R}$ skaliert. Das System erweitert die Intensitätsgleichung (2) folglich um den additiven Term $\zeta \cdot I_{\text{dead}}$. Im 48er-Format mit acht besten Gruppendritten ist die Bedeutungslosigkeit eines dritten Gruppenspiels allerdings nur selten vor Anpfiff mathematisch eindeutig. Der Indikator wird daher konservativ nur bei Eindeutigkeit gesetzt und entfaltet seine Wirkung vor allem auf den historischen Turnieren des Trainingszeitraums.

c) **Exogene Strukturbrüche durch globale Ereignisse**

Als dritter Faktor müssen Spiele während der globalen Pandemie in den Jahren 2020 und 2021 bereinigt werden. Diese Partien fanden weitestgehend ohne Zuschauer statt und zeigen einen stark dokumentierten Einbruch des statistischen Heimvorteils [12, 35]. Da bei internationalen Turnierspielen auf neutralem Boden regulär ohnehin kein mathematischer Heimvorteil existiert, wäre eine direkte Korrektur dieses Parameters in der Turnierprognose wirkungslos. Das Modell korrigiert stattdessen die Heimvorteilswirkung η rückwirkend in den betroffenen historischen Trainingsspielen der Qualifikation und der Nations League über eine zeitlich begrenzte Skalierung. Zusätzlich wird der spezifische Host-Effekt η_{host} für die Europameisterschaft 2021 gesondert parametrisiert, da dieses Turnier paneuropäisch ausgetragen wurde und beispielsweise England sechs von sieben Partien im heimischen Stadion absolvierte.

d) **Spieltheoretische Strukturbrüche in der Knockout-Phase**

Der Übergang von der Gruppenphase in die Knockout-Phase repräsentiert einen spieltheoretischen Regimewechsel. Während in der Vorrunde ein taktisches Unentschieden oftmals den strategischen Erwartungswert maximiert, erzwingt die Eliminierungsrunde zwingend eine finale Entscheidung über ein Weiterkommen. Diese veränderte Anreizstruktur führt empirisch zu einer messbaren Risikoaversion beider Mannschaften und folglich zu einer reduzierten Torintensität in der regulären Spielzeit. Das System modelliert diesen Effekt durch einen binären Indikator $I_{\text{ko}} \in \{0, 1\}$ für Spiele der finalen Turnierphase. Dieser Indikator wird mit einem empirisch geschätzten Parameter $\kappa_{\text{ko}} \in \mathbb{R}$ skaliert, dessen Vorzeichen nicht vorab fixiert, aufgrund der beschriebenen Risikoaversion jedoch negativ erwartet wird. Der resultierende Term $\kappa_{\text{ko}} \cdot I_{\text{ko}}$ fließt anschließend als additive Komponente in die Intensitätsgleichung (2) beider Teams ein.

5.7 Referenzmodell basierend auf dem Elo-System

Als einfaches und robustes Referenzmodell implementiert das System zusätzlich einen klassischen Ansatz basierend auf dem World Football Elo Rating [16, 36]. Dieses Konstrukt dient als verpflichtende mathematische Basislinie für die Leistungsbewertung aller zuvor definierten Architekturen. Für eine spezifische Begegnung definieren wir die aktuellen Elo-Punktzahlen als $E_i \in \mathbb{R}$ für das erste Team und $E_j \in \mathbb{R}$ für das zweite Team. Die zugehörige numerische Leistungsdifferenz wird als $d = E_i - E_j$ definiert. Um den eventuellen Vorteil eines Turnierausrichters zu quantifizieren, führen wir zudem den binären Indikator $I_{\text{host}} \in \{0, 1\}$ ein. Eine nachgelagerte Poisson-Regression transformiert diese metrischen Distanzen anschließend in die zu erwartenden Torintensitäten $\lambda \in \mathbb{R}_{>0}$ für die erste Mannschaft und $\mu \in \mathbb{R}_{>0}$ für die zweite Mannschaft. Für diese loglineare Abbildung schätzt das Modell die drei reellen Regressionskoeffizienten c_0 , c_1 und c_2 . Die Herleitung

der Erwartungswerte erfolgt durch die Gleichungen

$$\log \lambda = c_0 + c_1 d + c_2 \cdot I_{\text{host}}, \quad \log \mu = c_0 - c_1 d.$$

Aufgrund der extrem geringen Komplexität von lediglich drei zu schätzenden Parametern ist diese Architektur nahezu immun gegenüber einer Überanpassung an die historischen Trainingsdaten. Die empirische Vorhersagekraft dieses minimalistischen Systems erweist sich in der statistischen Literatur als außerordentlich stabil. Aus genau diesem Grund fungiert dieser Ansatz als die Messlatte, welche jede komplexe Erweiterung der stochastischen Zählprozesse zwingend schlagen muss.

5.8 Feature-basiertes Machine-Learning-Modell und dynamisches Ensemble

Als dritte Säule integriert das System ein Gradient-Boosting-Modell basierend auf Entscheidungsbäumen wie LightGBM oder XGBoost, welches auf zeitpunktkorrekten Features operiert. Zu den erklärenden Variablen zählen die metrische Elo-Differenz, das logarithmierte Marktwertverhältnis, die aktuelle sportliche Form gemessen an der gewichteten Tordifferenz der letzten n_{Form} Spiele (einem Hyperparameter, typischerweise zehn) sowie physische Faktoren wie Ruhetage und Reisedistanzen, ergänzt um den Wettbewerbstyp und die Turnierphase. Optional fungieren die um die Buchmachermarge bereinigten Marktquoten als zusätzliches Feature. Diese Integration der Quoten erfolgt exklusiv für den später definierten Modus B. In Modus A wäre der Wettmarkt andernfalls simultan Input und Benchmark, wodurch der mathematische Nachweis einer realen Überrendite gemäß Bemerkung 5.1 zirkulär und somit wissenschaftlich invalid würde.

Integration heterogener und hochdimensionaler Datenstrukturen Die vorliegende Architektur erlaubt die nahtlose Integration der verfügbaren massiven und stark heterogenen Datenquellen. Das Spektrum reicht hierbei von klassischen Spielresultaten über Videospiel-Datenbanken bis hin zu alternativen Informationsströmen wie globalen Wettermetriken, aggregierten Nachrichtenstimmungen oder detaillierten taktischen Eventdaten. Um dieses gewaltige Datenvolumen für das dynamische Ensemble nutzbar zu machen, dürfen diese isolierten Metriken nicht direkt in die stochastischen Basismodelle gezwungen werden. Stattdessen dienen sie als Rohmaterial für ein umfangreiches Feature-Engineering innerhalb des maschinellen Lernmodells. Ein baumbasierter Algorithmus kann somit komplexe nichtlineare Interaktionen erlernen und beispielsweise historische Wetterbedingungen mit taktischen Werten für erwartete Tore kreuzen. Das resultierende Modell generiert daraus eine eigenständige Matrix an Torwahrscheinlichkeiten. Sobald dieses datengetriebene Modell als vollwertiger Kandidat in die nachfolgend definierte Indexmenge $\mathcal{B}$ aller Basismodelle aufgenommen ist, entscheidet der nachgelagerte Hedge-Algorithmus völlig autonom und rein leistungsorientiert, ob diese spezifischen Datenkombinationen einen echten und messbaren Vorhersagewert für das spezifische Turnierspiel besitzen.

Dynamische Modellgewichtung via Hedge-Algorithmus Die Vorhersagen der zugrundeliegenden Basismodelle werden nicht starr kombiniert, sondern sequenziell über die stochastische Theorie des Lernens unter vollständiger Information aggregiert. Die fundamentale Prämisse lautet, dass mathematische Modelle während eines Turniers Phasen unterschiedlicher Kalibrierung durchlaufen. Wir definieren zunächst die Variablen für die systematische Zusammenführung. Die Spiele in $\mathcal{M}$ seien chronologisch geordnet und mit $m = 1, 2, \dots$ durchnummeriert. Sei $\mathcal{B}$ die endliche Indexmenge aller implementierten Basismodelle. Für ein spezifisches Spiel m und ein spezifisches Modell $i \in \mathcal{B}$ bezeichne $\mathcal{P}_{i,m}$ die zugehörige diskrete Wahrscheinlichkeitsfunktion für das exakte Torergebnis. Das dynamische Gewicht dieses Modells für das betrachtete Spiel m wird durch die Variable $w_{i,m} \in [0, 1]$ definiert. Um das Ensemble als anteilige Mischung aller verfügbaren Kandidaten zu konstruieren, beläuft sich die Summe dieser Gewichte über alle $i \in \mathcal{B}$ auf exakt Eins. Für eine spezifische Realisierung von $x \in \mathbb{N}_0$ Toren der ersten Mannschaft und $y \in \mathbb{N}_0$ Toren

der zweiten Mannschaft bildet das Ensemble die finale aggregierte Wahrscheinlichkeit folglich als konvexe Kombination

$$\mathcal{P}_{\text{Ens},m}(x, y) = \sum_{i \in \mathcal{B}} w_{i,m} \mathcal{P}_{i,m}(x, y).$$

Nach der Offenlegung des tatsächlichen Spielausgangs in Form der erzielten Tore (x_m, y_m) erleidet jedes Modell i einen quantifizierbaren Informationsverlust. Zur Sicherstellung der für den Algorithmus zwingend notwendigen Regretgarantien definieren wir eine strikte Wahrscheinlichkeitsuntergrenze $p_{\min} = 10^{-4}$. Der resultierende Log-Loss $L_{i,m}$ berechnet sich über die nach unten begrenzte Wahrscheinlichkeit als $L_{i,m} = -\log(\max(p_{\min}, \mathcal{P}_{i,m}(x_m, y_m)))$. Für die Anpassung der Modellgewichte für das darauffolgende Spiel $m+1$ führen wir die strikt positive Lernrate $\nu \in \mathbb{R}_{>0}$ ein. Diese Variable steuert die Reaktivität des Ensembles auf kurzfristige Strukturbrüche wie beispielsweise eine unerwartete Überdispersion im aktuellen Turnierverlauf. Die Gewichte werden anschließend über den Exponential-Weights-Algorithmus aktualisiert durch die Gleichung

$$w_{i,m+1} = \frac{w_{i,m} \exp(-\nu \cdot L_{i,m})}{\sum_{j \in \mathcal{B}} w_{j,m} \exp(-\nu \cdot L_{j,m})}.$$

Schlecht kalibrierte Modelle verlieren durch diese exponentielle Bestrafung gemäß der sublinearen Regretschranke an Einfluss, während performante Modelle im laufenden Prozess systematisch höher gewichtet werden.

Bemerkung 5.1 (Markt als Feature und die Behandlung der Zirkularität). *Für den Modus B, in welchem das System nicht direkt gegen den Markt wettet, ist die integrierte Marktquote ein legitimes und prädiktiv starkes Feature. Für den Modus A evaluieren wir hingegen zwei vollständig getrennte Varianten. Die erste Variante ist ein Modell gänzlich ohne Marktinput, welches als einziger Ansatz ein echtes und unabhängiges statistisches Alpha belegen kann. Die zweite Variante beinhaltet den Marktinput und ist ausschließlich für die Erzielung der praktisch bestmöglichen Prognose relevant. Diese strikte methodische Trennung wird im späteren Backtest-Bericht konsequent durchgehalten.*

Verarbeitung kurzfristiger Informationsschocks vor Spielbeginn Kurzfristig verfügbare Informationen unmittelbar vor Spielbeginn wie offizielle Startaufstellungen, plötzliche Verletzungen oder finale Quotenbewegungen am Wettmarkt besitzen eine exzeptionelle prädiktive Relevanz. Diese späten stochastischen Schocks reduzieren die Informationsasymmetrie zwischen dem Modell und der Realität drastisch. Das auf maschinellem Lernen basierende Basismodell ist algorithmisch in der Lage, diese späten Datenpunkte als dynamische Variablen zu verarbeiten. Da die konvexen Gewichte des Ensembles bereits nach der Auswertung des vorherigen Spiels mathematisch fixiert wurden, evaluiert das System bei Eintreffen dieser neuen Parameter lediglich die isolierte Ergebnismatrix des betroffenen Modells neu. Die finale Wahrscheinlichkeitsverteilung des Ensembles passt sich somit in Echtzeit an die aktualisierte Informationslage an, ohne die strukturelle Integrität der mathematischen Architektur zu verletzen.

5.9 Knockout-Phase sowie Verlängerung und Elfmeterschießen

Ein Elfmeterschießen findet ausschließlich in der Knockout-Phase statt und auch dort nur, wenn nach der regulären Spielzeit und einer angesetzten Verlängerung von zweimal fünfzehn Minuten kein Sieger feststeht. In der vorangegangenen Gruppenphase endet ein Spiel stattdessen als reguläres Remis. Für Partien der finalen Turnierphase wird die empirische Verteilung des Endergebnisses folglich dreistufig aufgebaut.

a) Modellierung der regulären Spielzeit

Die diskrete Ergebnismatrix $\mathcal{P}_m$ für die ersten neunzig Minuten berechnet sich identisch zur Methodik der Gruppenphase. Wie in Abschnitt 5.6 eingeführt, werden die zugrundeliegenden Intensitäten λ und μ lediglich um den spezifischen Dämpfungsfaktor der Knockout-Phase

korrigiert, da die Risikoaversion beider Mannschaften einen signifikanten Abfall der erzielten Tore provoziert.

b) **Stochastische Verlängerung**

Bedingt auf ein Remis nach der regulären Spielzeit wird die Verlängerung als unabhängiger Poisson-Prozess modelliert. Für die Anpassung der Intensitäten definieren wir den zeitlichen Anteil der Verlängerung als exakt ein Drittel der regulären Spielzeit. Zudem führen wir einen empirisch geschätzten Dämpfungsfaktor $\kappa_{\text{ET}} \in (0, 1)$ ein, welcher die extrem vorsichtige Spielweise in dieser Phase quantifiziert und die Positivität der Intensitäten sichert. Die Intensitäten für die Verlängerung ergeben sich somit als $\lambda^{\text{ET}} = \kappa_{\text{ET}} \cdot \frac{1}{3}\lambda$ für die erste Mannschaft und $\mu^{\text{ET}} = \kappa_{\text{ET}} \cdot \frac{1}{3}\mu$ für die zweite Mannschaft.

c) **Siegwahrscheinlichkeit im Elfmeterschießen**

Bedingt auf ein erneutes Remis nach der Verlängerung modelliert das System das anschließende Elfmeterschießen als approximativ faire Münze, welche um einen marginalen Stärkeeffect ergänzt wird. Für zwei Mannschaften i und j sei $d_{ij} = E_i - E_j$ die Elo-Differenz aus Abschnitt 5.7, gemessen in Elo-Punkten. Wir führen einen konstanten reellen Skalierungsparameter $c_{\text{ES}} \in \mathbb{R}$ ein. Die Wahrscheinlichkeit für einen Sieg des Teams i ergibt sich darauffolgend durch die inverse logistische Funktion $\text{logit}^{-1}(z) = 1/(1 + e^{-z})$ in der Form $\mathbb{P}(i \text{ gewinnt}) = \text{logit}^{-1}(c_{\text{ES}} \cdot d_{ij})$. Ein potenzieller Reihenfolgeeffekt wird aufgrund der widersprüchlichen empirischen Replikationslage in der wissenschaftlichen Literatur [1, 19] in dieser Basisformulierung explizit ausgeklammert.

Zur Ermittlung der finalen Weiterkommenswahrscheinlichkeit für ein Team i in einem spezifischen Spiel m definieren wir zunächst die elementaren Ereignisse. Sei D_{90} das stochastische Ereignis eines Unentschiedens nach neunzig Minuten und D_{120} das Ereignis eines fortbestehenden Remis nach hundertzwanzig Minuten. Für die reguläre Spielzeit bezeichne π_m^H die Wahrscheinlichkeit eines Heimsieges und π_m^D die korrespondierende Wahrscheinlichkeit für ein Unentschieden. Unter Integration der konditionalen Wahrscheinlichkeiten für die Verlängerung und das Elfmeterschießen ergibt sich die totale Wahrscheinlichkeit für ein Weiterkommen durch die Gleichung

$$\mathbb{P}(i \text{ kommt weiter}) = \pi_m^H + \pi_m^D \cdot [\mathbb{P}(i \text{ gewinnt ET} \mid D_{90}) + \mathbb{P}(D_{120} \mid D_{90}) \cdot \mathbb{P}(i \text{ gewinnt ES} \mid D_{120})].$$

Finale Ergebnismatrix für den Tippmodus nach dem Elfmeterschießen Die finale Bewertungsrunde gemäß Abschnitt 9.1 wertet die Partien der Knockout-Phase explizit nach dem Endstand inklusive einer möglichen Verlängerung und einem Elfmeterschießen. Die dafür benötigte Verteilungsmatrix $\mathcal{P}_m^{\text{final}}$ entsteht durch die stochastische Faltung der drei definierten Phasen. Für ein exaktes Endergebnis von $x \in \mathbb{N}_0$ Toren und $y \in \mathbb{N}_0$ Toren lautet die Faltungsgleichung

$$\mathcal{P}_m^{\text{final}}(x, y) = \underbrace{\mathcal{P}_m(x, y)}_{\text{reguläre Spielzeit}} \mathbf{1}\{x \neq y\} + \sum_{z \geq 0} \mathcal{P}_m(z, z) \cdot \mathbb{P}(\text{ET und ES führt von } (z, z) \text{ zu } (x, y)).$$

Der stochastische Übergangskern ist hierbei als formale Komposition der zweiten und dritten Stufe definiert. Die Tore der Verlängerung folgen den Intensitäten λ^{ET} und μ^{ET} . Bei einem fortwährenden Remis bestimmt die dritte Stufe den finalen Sieger. Für das Elfmeterschießen appliziert das System die offizielle Bewertungskonvention externer Tippspiele, bei welcher dem Sieger exakt ein fiktives Tor zu dem Zwischenstand nach der Verlängerung addiert wird¹. Ein reales Finale, welches nach hundertzwanzig Minuten drei zu drei endet und anschließend im Elfmeterschießen durch die erste Mannschaft gewonnen wird, resultiert systemintern somit in einem gewerteten Endstand von vier zu drei. Ein Tipp von eins zu null erhielte auf diesen gewerteten Endstand nach dem Schema der Zielrunde die Tordifferenzpunkte, ein Remis-Tipp hingegen null

¹Diese Konvention wird vor der finalen Implementierung gegen die offizielle Dokumentation verifiziert und als Testfall in der Datenpipeline verankert.

Punkte. Diese deterministische Regel modifiziert den Raum der zulässigen Vorhersagen für den Optimierer tiefgreifend. In der Knockout-Phase besitzt die Verteilung $\mathcal{P}_m^{\text{final}}$ keinerlei Masse auf der Hauptdiagonalen, weshalb Tipps auf ein Remis mathematisch strikt dominiert sind. Gleichzeitig transferiert die Addition des fiktiven Tores erhebliche Wahrscheinlichkeitsmasse auf knappe Siege, wodurch der isolierte erwartete Punktertrag $\mathbb{E}[S]$ für diese Resultate systematisch ansteigt.

6 Von Intensitäten zur Ergebnismatrix (Schicht 2)

6.1 Analytische Auswertung als Standardpfad

Da Schicht 1 parametrische Verteilungen liefert, ist die Ergebnismatrix analytisch berechenbar. Wir identifizieren dabei die Wahrscheinlichkeitsfunktion $\mathcal{P}_m$ mit ihrer Matrixdarstellung $\mathcal{P}_m \in [0, 1]^{(X_{\max}+1) \times (X_{\max}+1)}$ auf dem zensierten Gitter $\{0, \dots, X_{\max}\}^2$. Für das Dixon-Coles-Basismodell folgt die Matrix direkt aus den Parametern $\lambda, \mu \in \mathbb{R}_{>0}$ und $\rho \in \mathbb{R}$, für die Copula-Variante aus der Zellformel in Abschnitt 5.3, und das Ensemble mischt die fertigen Matrizen gemäß Abschnitt 5.8. In allen Fällen ist die Auswertung analytisch, denn Monte-Carlo wäre hierfür unnötig und würde nur Simulationsrauschen addieren.

6.2 Monte-Carlo, wo es tatsächlich gebraucht wird

Für die Simulation verwenden wir typischerweise eine Anzahl von $n_{\text{sim}} = 100000$ Pfaden. Diese stochastische Auswertung kommt an drei Stellen zum Einsatz, an denen analytische Lösungen unpraktikabel sind.

1. **Parameterunsicherheit.** Wir ziehen Parametervektoren $\theta^{(s)}$ aus dem zulässigen Parameterraum Θ gemäß der Posterior-Verteilung und werten die resultierende Matrix $\mathcal{P}_m^{(s)}$ aus. Dies dient der Aggregation zur prädiktiven Matrix und zur Verteilung der Tendenzwahrscheinlichkeiten für das Kelly-Shrinkage in Abschnitt 8.3.
2. **Turniersimulation.** Wir führen eine vollständige WM-Simulation durch, welche Gruppenausgänge inklusive Tiebreaker-Regeln sowie den K.o.-Baum gemäß Abschnitt 5.9 umfasst. Dies liefert die Wahrscheinlichkeiten für ein Weiterkommen, das Halbfinale und den Titelgewinn, welche für Outright-Märkte und Kicktipp-Bonusfragen benötigt werden.
3. **Strategie-Backtests.** Wir simulieren die Verteilung von Bankroll-Pfaden in Modus A, um Drawdown-Quantile anstelle isolierter Erwartungswerte zu ermitteln.

Bemerkung 6.1. *Die Trennung zwischen analytischer Auswertung und bedarfsgerechter Simulation ist eine bewusste Designentscheidung. Sie hält den Prognosepfad deterministisch, testbar und schnell. Stochastik wird nur dort eingeführt, wo sie einen Informationsgewinn liefert.*

7 Implizite Wahrscheinlichkeiten und Entvigung der Marktdaten

Buchmacherquoten enthalten eine Marge, die sogenannte Vig. Wir übernehmen die Notation aus Abschnitt 3.1, insbesondere die Tendenzmenge Ω_m und den Quotenvektor o_m . Aus diesem Quotenvektor berechnet sich der lokale Buchungsüberschuss (Overround) $V_m \in \mathbb{R}_{>1}$ durch die Summe der Kehrwerte aller Komponenten, das heißt

$$V_m = \sum_{\omega \in \Omega_m} \frac{1}{o_m^\omega}.$$

Wir implementieren zwei Entvigungsverfahren, um diese Marge im laufenden Betrieb präzise zu bereinigen.

(a) Proportionale Normierung (Baseline). Die proportionale Normierung dient als Baseline. Für einen spezifischen Ausgang $\omega \in \Omega_m$ berechnet sich die von der Marge bereinigte Marktwahrscheinlichkeit $q_m^\omega \in [0, 1]$ durch die gewichtete Aufteilung

$$q_m^\omega = \frac{1/o_m^\omega}{V_m}.$$

(b) Shin-Modell (Standard). Das Shin-Modell [32] fungiert als Standardverfahren und modelliert die Marge als Schutz des Buchmachers vor Insider-Wetten. Für das betrachtete Spiel $m \in \mathcal{M}$ wird der latente Insider-Anteil durch den Parameter $z_m \in [0, 1]$ beschrieben. Unter Verwendung dieses Parameters und für einen Ausgang $\omega \in \Omega_m$ berechnet sich die bereinigte Wahrscheinlichkeit $q_{m,\text{Shin}}^\omega \in [0, 1]$ numerisch aus dem Gleichungssystem

$$q_{m,\text{Shin}}^\omega = \frac{\sqrt{z_m^2 + 4(1 - z_m) \frac{(1/o_m^\omega)^2}{V_m}} - z_m}{2(1 - z_m)}, \quad \sum_{\omega \in \Omega_m} q_{m,\text{Shin}}^\omega = 1.$$

Shin korrigiert das bekannte Favorite-Longshot-Bias-Muster besser als die proportionale Normierung. Die empirische Überlegenheit wird im Backtest verifiziert, indem die Wahrscheinlichkeiten gegen realisierte Frequenzen kalibriert werden. Die aus den Verfahren resultierenden, entvigten Wahrscheinlichkeitsvektoren $q_m = (q_m^{i(m)}, q_m^R, q_m^{j(m)})^T \in [0, 1]^3$ dienen als Benchmark-Prognose, als Feature in Modus B sowie als Gegenseite der Value-Bedingung in Modus A.

8 Der Capital Allocator (Schicht 3, Modus A)

8.1 Value-Identifikation

Wir betrachten ein Spiel $m \in \mathcal{M}$ und einen möglichen Ausgang $\omega \in \Omega_m$. Für diesen Ausgang sei die zugehörige Modellwahrscheinlichkeit durch $\pi_m^\omega \in [0, 1]$ und die verfügbare Marktquote durch $o_m^\omega \in [1, \infty)$ gegeben. Eine Platzierung einer Wette auf diesen spezifischen Ausgang besitzt einen erwarteten Nettoertrag pro gesetzte Einheit $\mathbb{E}[\text{Ertrag}_m^\omega] \in \mathbb{R}$, welcher sich durch die Beziehung

$$\mathbb{E}[\text{Ertrag}_m^\omega] = \pi_m^\omega o_m^\omega - 1$$

berechnet. Für die Formulierung der endgültigen Entscheidungsregel definieren wir eine positive Sicherheitsmarge $\delta \in \mathbb{R}_{>0}$, welche im Backtest kalibriert wird und typischerweise in einer Größenordnung zwischen 2 % und 5 % liegt. Die wertbasierte Wettbedingung für den Ausgang $\omega \in \Omega_m$ des Spiels $m \in \mathcal{M}$ lautet dann

$$\pi_m^\omega o_m^\omega > 1 + \delta. \quad (4)$$

Die Sicherheitsmarge δ kompensiert die inhärente Parameterunsicherheit sowie verbleibende Modellfehler. Ohne diese Marge würde das Entscheidungssystem bereits bei jeder noch so kleinen positiven Differenz zwischen Modell und Markt setzen. Da diese Differenz teils aus echtem Value und teils aus Modellfehler besteht, ohne dass beide unterscheidbar wären, würde das System überproportional oft gerade dann setzen, wenn nicht der Markt, sondern das eigene Modell die schlechtere Schätzung liefert. Dieser Selektionseffekt entspricht dem Winner's Curse der Differenz zwischen Modell und Markt.

8.2 Einsatzdimensionierung nach Kelly

Für die Bestimmung der optimalen Einsatzgröße greifen wir auf das theoretische Fundament aus Proposition 2.1 zurück. Für ein betrachtetes Spiel $m \in \mathcal{M}$ und einen Ausgang $\omega \in \Omega_m$ sei die zugehörige Modellwahrscheinlichkeit durch $\pi_m^\omega \in [0, 1]$ und die verfügbare Marktquote durch

$o_m^\omega \in [1, \infty)$ gegeben. Der unbeschränkte optimale Bankroll-Anteil $f_m^{*,\omega} \in (-\infty, 1)$ ergibt sich darauffolgend durch die direkte Anwendung der Beziehung

$$f_m^{*,\omega} = \frac{\pi_m^\omega o_m^\omega - 1}{o_m^\omega - 1}.$$

Dieser unbeschränkte Wert kann bei fehlendem Value negativ werden. Unter Einbeziehung der praktisch zulässigen Menge $[0, f_{\max}]$ mit einer harten Obergrenze $f_{\max} \in (0, 1]$ lautet die kapitalgewichtete Lösung gemäß der entscheidungstheoretischen Vorgabe entsprechend $\min\{\max\{0, f_m^{*,\omega}\}, f_{\max}\}$, wobei das Abschneiden am unteren Rand bei null die Nichtwette erzwingt. Es zeigt sich, dass der berechnete Anteil $f_m^{*,\omega}$ genau dann strikt positiv ist, wenn die wertbasierte Wettbedingung (4) mit einem Parameterwert von $\delta = 0$ erfüllt ist. Das Kelly-Kriterium maximiert asymptotisch fast sicher die Wachstumsrate des Vermögens [3] und verhindert einen Ruin des Gesamtsystems. Dieser klassische Ansatz reagiert jedoch hochgradig volatil auf eine potenzielle Überschätzung der Wahrscheinlichkeiten.

8.3 Fraktionales Kelly und Unsicherheits-Shrinkage

Aus zwei Gründen wird in der operativen Praxis auf das vollständige Kelly-Optimum verzichtet.

1. **Schätzfehler.** Bei einer Überschätzung der wahren Wahrscheinlichkeit $\pi_m^\omega \in [0, 1]$ erweist sich das vollständige Kelly-Kriterium aufgrund der asymmetrischen Verlustfunktion bezüglich des Anteils $f \in [0, 1)$ als überproportional schädlich. Die Standardpraxis verwendet daher das fraktionale Kelly-Kriterium, welches durch die Beziehung $f = \phi f_m^{*,\omega}$ mit einem festen Skalierungsparameter $\phi \in (0, 1]$ definiert ist, der in der Praxis typischerweise zwischen 0,10 und 0,25 gewählt wird.
2. **Bayesianisches Shrinkage.** Da das zugrunde liegende Modell die vollständige Posteriorverteilung der Wahrscheinlichkeit liefert, bestimmen wir die Untergrenze $\underline{\pi}_m^\omega \in (0, 1)$ und die Obergrenze $\bar{\pi}_m^\omega \in (0, 1)$ eines definierten Intervalls $[\underline{\pi}_m^\omega, \bar{\pi}_m^\omega]$, welches beispielsweise ein 80 %-Kreditintervall darstellt. Der tatsächliche Einsatz $f \in [0, 1)$ berechnet sich darauffolgend durch die konservative Dimensionierung

$$f = \phi \cdot \min_{\pi' \in [\underline{\pi}_m^\omega, \bar{\pi}_m^\omega]} f^*(\pi').$$

Ist der funktionale Wert $f^*(\underline{\pi}_m^\omega) \leq 0$, wird keine Wette platziert, selbst wenn der Punktschätzer einen positiven Ertrag anzeigt.

Zusätzlich gilt für den finalen Anteil $f \in [0, 1)$ eine harte Obergrenze, wobei diese Schranke als ein konstanter Wert $f_{\max} \in (0, 1]$ festgelegt wird, welcher beispielsweise 2 % der gesamten Bankroll pro Spiel entspricht.

8.4 Grenzen der Asymptotik und Finite-Horizon-Effekte

Die asymptotische Optimalität des Kelly-Kriteriums, welche in der Maximierung der fast sicheren Wachstumsrate besteht, beruht auf dem Starken Gesetz der großen Zahlen für eine Anzahl an Wetten $N_{\text{Wetten}} \rightarrow \infty$ [18, 3]. Im Kontext einer Weltmeisterschaft liegt die reale Stichprobengröße jedoch bei lediglich $N_{\text{Wetten}} \approx 15$ bis 35.

In diesem endlichen, non-asymptotischen Regime ist das klassische Kelly-Kriterium unvollständig. Dieser Abschnitt ordnet die Wahl des Skalierungsfaktors ϕ deshalb theoretisch ein. Anstatt das fraktionale Kelly-Kriterium heuristisch festzulegen, formulieren wir das Einsatzproblem als stochastische dynamische Programmierung für einen endlichen Zeithorizont $H \in \mathbb{N}$. Wir betrachten das Endkapital $W_H \in \mathbb{R}_{>0}$ sowie einen konstanten Risikoavversionsparameter $a \in (1, \infty)$. Für jeden Zeitschritt $t \in \{1, \dots, H\}$ definieren wir die Kontrollvariable des Einsatzanteils $f_t \in [0, 1)$. Das Ziel der Optimierung ist die Maximierung des Erwartungswertes einer isoelastischen Nutzenfunktion

(CRRA) des Endkapitals, ausgedrückt durch

$$\max_{(f_t)_{t=1}^H} \mathbb{E} \left[\frac{W_H^{1-a}}{1-a} \right].$$

Die Lösung der zugehörigen Bellman-Gleichung führt zur expliziten Berücksichtigung des endlichen Horizonts. Für eine Binärwette mit einer Gewinnwahrscheinlichkeit $p \in (0, 1)$ und einer Dezimalquote $o \in [1, \infty)$ im zeitstetigen, lognormalen Grenzfall nach Merton [25] ergibt sich der optimale Einsatzanteil $f_{\text{Merton}}^* \in \mathbb{R}$ durch

$$f_{\text{Merton}}^* = \frac{1}{a} \cdot \frac{p \cdot o - 1}{o - 1}.$$

Für diskrete Wetten über einen endlichen Horizont gilt diese analytische Gleichheit zwar nicht exakt, da die exakte Lösung der Bellman-Gleichung zustands- und zeitabhängig wird. Dennoch dient der Skalierungsfaktor $\phi \in (0, 1]$ aus Abschnitt 8.3 hier als fundierte Approximation. Er entspricht in diesem theoretischen Grenzfall dem Kehrwert der Risikoaversion, das heißt $\phi \approx 1/a$, was unmittelbar aus der obigen Merton-Formel ablesbar ist. Die Ableitung der Aversion a aus der maximal tolerierbaren Drawdown-Wahrscheinlichkeit (dem größten hinnehmbaren zwischenzeitlichen Kapitalrückgang) für die verbleibende Anzahl der Turnierspiele ist hingegen eine Heuristik und wird im Backtest überprüft.

8.5 Portfolio-Sicht bei gleichzeitigen Spielen

In der Gruppenphase finden bis zu vier Spiele pro Tag statt, weshalb gleichzeitige Wetten über die gemeinsame Bankroll interagieren. Da die zugrundeliegenden Modellwahrscheinlichkeiten $\pi_m^\omega \in [0, 1]$ zudem über den gemeinsamen bayesianischen Posterior und insbesondere über den Kontinentalverbands-Prior $\mu_c^\alpha \in \mathbb{R}$ stochastisch abhängig sind, wäre eine Optimierung über das Produkt der Randverteilungen fehlspezifiziert. Da Turnierspiele am selben Tag häufig zeitlich versetzt und damit sequenziell stattfinden, greift eine rein simultane Tages-Optimierung zu kurz. Sie blockiert Kapital, das bei einem Gewinn des frühen Spiels bereits für das spätere Spiel reinvestiert werden könnte, wodurch der Intraday-Zinseszinsseffekt entfällt.

Um dies zu modellieren, betrachten wir $M \in \mathbb{N}$ chronologisch geordnete Spiele an einem Turniertag. Für ein Spiel $m \in \{1, \dots, M\}$ bezeichne $Z_m \in \Omega_m$ den realisierten Ausgang. Wir definieren den diskreten Raum der möglichen Historien vor Beginn dieses Spiels als das kartesische Produkt $\mathcal{H}_m = \prod_{k=1}^{m-1} \Omega_k$, wobei ein Vektor der bereits beendeten Ausgänge durch $Z_{<m} \in \mathcal{H}_m$ gegeben ist. Die verfügbare Startbankroll sei durch $B_{\text{Start}} \in \mathbb{R}_{>0}$ gegeben. Die Portfolio-Optimierung wird darauffolgend als bedingte Politik $\varsigma = (f_1, \dots, f_M)$ formuliert. Hierbei ist jede funktionale Komponente $f_m : \mathcal{H}_m \rightarrow [0, 1)$ eine Abbildung, welche den Einsatzanteil für das Spiel m in Abhängigkeit der beobachteten Historie determiniert. Der absolute Ertrag eines Spiels wird durch die Funktion $G_m : [0, 1) \times \Omega_m \rightarrow \mathbb{R}$ modelliert. Wir mitteln über $n_{\text{post}} \in \mathbb{N}$ gezogene Parametervektoren $\theta^{(s)}$ aus der Posterior-Verteilung und lösen das Problem per Rückwärtsinduktion über die Startzeiten des Tages durch

$$\max_{\varsigma} \frac{1}{n_{\text{post}}} \sum_{s=1}^{n_{\text{post}}} \mathbb{E}_{Z|\theta^{(s)}} \left[\log \left(B_{\text{Start}} + \sum_{m=1}^M G_m(f_m(Z_{<m}), Z_m) \right) \right]. \quad (5)$$

Bei echten Simultan-Spielen, wie beispielsweise am dritten Gruppenspieltag, zerfällt die Politik automatisch in die Standard-Portfolio-Optimierung über die gemeinsamen Ausgänge. Da der Zinseszinsseffekt innerhalb eines Tages bei Einsatzanteilen um zwei Prozent gering ist, dient die statische Tagesallokation als Kernlösung, während die beschriebene Rückwärtsinduktion eine optionale Erweiterung darstellt.

Risiko-Overlay (CVaR) Ergänzend zur Kelly-Zielfunktion implementieren wir ein Risiko-Overlay. Hierfür betrachten wir den absoluten Tagesverlust $L_{\text{Tag}} \in \mathbb{R}$. Wir definieren ein Konfidenzniveau $\chi \in (0, 1)$ und eine maximale Verlusttoleranz $c_{\max} \in (0, 1)$. Der Value at Risk ist dabei das χ -Quantil der Verlustverteilung, also $\text{VaR}_\chi(L_{\text{Tag}}) = \inf\{l \in \mathbb{R} \mid \mathbb{P}(L_{\text{Tag}} \leq l) \geq \chi\}$. Um extreme Drawdowns zu begrenzen, formulieren wir eine Nebenbedingung basierend auf dem Conditional Value at Risk (CVaR), welche sicherstellt, dass der erwartete Verlust jenseits dieses Quantils den Anteil $c_{\max}$ der täglichen Bankroll B_{Start} nicht überschreitet. Diese Restriktion lautet

$$\text{CVaR}_\chi(L_{\text{Tag}}) = \mathbb{E}[L_{\text{Tag}} \mid L_{\text{Tag}} \geq \text{VaR}_\chi(L_{\text{Tag}})] \leq c_{\max} B_{\text{Start}}.$$

Für eine typische Parametrisierung mit $\chi = 0,95$ und $c_{\max} = 0,05$ bedeutet dies, dass der erwartete Verlust in den schlechtesten fünf Prozent der Tage fünf Prozent der verfügbaren Bankroll nicht übersteigen darf. Unter Hinzunahme dieser Nebenbedingung bleibt das statische, simultane Problem nach der Formulierung von Rockafellar und Uryasev [30, Satz 1] konvex und ist mit numerischen Standardsolvern lösbar. Der in Gleichung (5) beschriebene sequentielle Fall wird stattdessen als Rückwärtsinduktion über konvexe Teilprobleme charakterisiert.

Bemerkung 8.1 (Einordnung der Risikobeschränkung). *Um die Funktionsweise dieser Restriktion abschließend zu bewerten, definieren wir zunächst die isolierten Komponenten der individuellen Anlageentscheidung. Sei $f_m^{*,\omega}$ der theoretisch optimale Kelly-Anteil des Gesamtkapitals für einen Ausgang $\omega \in \Omega_m$ eines spezifischen Spiels m . Sei zudem $\phi \in (0, 1]$ der global deklarierte und dämpfende Skalierungsfaktor. Das Produkt $\phi f_m^{*,\omega}$ repräsentiert folglich die finale und real ausgeführte Einsatzgröße. Für eine praktisch relevante Allokation, bei welcher dieser tatsächliche Einsatz die Grenze von zwei Prozent, das heißt $\phi f_m^{*,\omega} \leq 0,02$, nicht überschreitet, bindet die beschriebene Restriktion des Conditional Value at Risk empirisch äußerst selten. Sie fungiert stattdessen primär als ein algorithmisches Sicherheitsnetz gegen Kalendertage mit einer ungewöhnlich hohen Dichte an simultanen und vermeintlich profitablen Wettsignalen. Ein solch extremer Ausreißer entspricht exakt jenem kritischen Szenario, in welchem stark korrelierte Modellfehler die größte Gefahr für den absoluten Kapitalerhalt des Systems darstellen. Ein anschauliches Beispiel für diese unsichtbare systemische Gefahr wäre ein algorithmisch falsch geschätzter statistischer Prior auf der Ebene der Kontinentalverbände, welcher identische fatale Fehlbewertungen in dutzenden parallelen Länderspielen provoziert.*

8.6 Betriebsregeln Modus A

Für den praktischen Livebetrieb des Decision Engines gelten zwingende operationelle Restriktionen.

Revisionssichere Protokollierung. Die Erfassung der Marktdaten erfolgt über einen dedizierten Quoten-Snapshot zu einem exakt definierten Zeitpunkt, beispielsweise zwei Stunden vor dem jeweiligen Anpfiff. Alle resultierenden Entscheidungen sowie die zugrundeliegenden stochastischen Parameter wie die isolierte Modellwahrscheinlichkeit π_m^ω , die bereinigte Marktwahrscheinlichkeit q_m^ω , der identifizierte mathematische Edge $\pi_m^\omega o_m^\omega - 1$ und der berechnete Einsatzanteil f werden algorithmisch und revisionssicher protokolliert. Diese Fixierung geschieht zwingend vor dem Beginn der sportlichen Begegnung.

Restriktion auf isolierte Einzelausgänge. Das System allokiert Kapital auf höchstens einen einzigen Ausgang pro Spiel, nämlich jenen mit dem maximalen optimalen Einsatzanteil f^* . Diese Beschränkung ist eine bewusste Risikoheuristik zur Vereinfachung des Livebetriebs und keine Aussage über mathematische Optimalität. Simultane Einsätze auf mehrere Ausgänge derselben Partie können den erwarteten logarithmischen Vermögenszuwachs im Sinne von Gleichung (5) durchaus erhöhen, werden hier jedoch aus Gründen der operativen Robustheit ausgeschlossen.

Erwartungshaltung an die Selektivität. An die algorithmische Selektivität wird eine exakte Erwartungshaltung formuliert. Auf den hocheffizienten Märkten einer Weltmeisterschaft geht das System als Arbeitshypothese davon aus, dass in einem Großteil der absolvierten Partien

(in der Größenordnung von 70 bis 85 Prozent) kein messbarer mathematischer Vorteil existiert. Diese Erwartung wird im Backtest überprüft. Eine signifikant höhere Wettfrequenz stellt somit keinen algorithmischen Erfolg dar, sondern fungiert als kritisches Warnsignal für ein strukturell zu selbstsicheres Modell.

Risikofreier Standardbetrieb. Der standardisierte Betriebsmodus der Software ist ein isoliertes Paper Trading ohne reales finanzielles Risiko. Der tatsächliche Einsatz von Echtgeld repräsentiert eine rein persönliche Ermessensentscheidung, welche vollständig außerhalb der algorithmischen Systemgrenzen getroffen wird.

Marktfriktionen und Einsatzlimitierungen. Rückwirkend berechnete, hypothetische Kapitalverläufe ignorieren in der sportstatistischen Literatur oftmals die reale Praxis von Kontosperrungen und individuellen Einsatzlimits bei herkömmlichen Buchmachern. Zur Vermeidung dieses massiven Verzerrungseffekts limitiert das System den maximalen absoluten Einsatz in retrospektiven Backtests künstlich auf realistische Grenzwerte der verfügbaren Marktliquidität. Im operativen Livebetrieb weicht die Architektur hierfür primär auf asiatische Broker oder professionelle Wettbörsen aus.

API-Latenzen und trügerischer Geister-Value. Da zeitkritische Quotenbewegungen zumeist unmittelbar kurz vor dem Anpfiff stattfinden, führen technische Caching-Verzögerungen insbesondere innerhalb kostenloser Schnittstellen zu algorithmischen Scheinerfolgen im Protokoll. Das System würde in diesem Fall fiktives Kapital auf real längst veraltete Quoten platzieren. Die definierte Betriebsregel erzwingt daher ein engmaschiges High-Frequency-Polling exakt in den letzten sechzig Minuten vor Spielbeginn. Sämtliche Quoten, welche im finalen Platzierungsfenster auf dem realen Markt nicht mehr ausführbar sind, werden vom System zwingend als ungültig deklariert und von der stochastischen Optimierung ausgeschlossen.

9 Der Kicktipp-Optimierer (Schicht 3, Modus B)

9.1 Punktefunktion der Zielrunde

Die Zielrunde ist die Kicktipp-Runde mit folgenden, den offiziellen Spielregeln entnommenen Parametern:

	Tendenz	Tordifferenz	Ergebnis
Sieg	2	3	4
Unentschieden	2	.	4

Da die Runde Turnierspiele auf neutralem Platz wertet, sind Heim- und Auswärtssieg punktgleich. Formal ist die Punktefunktion für einen Tipp (u, v) (das Paar übernimmt die Rolle von (x^*, y^*) aus Abschnitt 3.2 und ist von den Teamindizes $i(m), j(m)$ verschieden) und ein gewertetes Ergebnis (x, y) gegeben durch

$$S(u, v \mid x, y) = \begin{cases} 4 & (u, v) = (x, y) \\ 3 & u - v = x - y \text{ und } (u, v) \neq (x, y) \text{ und } u \neq v \\ 2 & \text{sgn}(u - v) = \text{sgn}(x - y) \text{ und } (u, v) \neq (x, y) \\ & \text{und } (u - v \neq x - y \text{ oder } u = v) \\ 0 & \text{sonst.} \end{cases}$$

Bemerkung 9.1 (Remis-Abwertung in dieser Runde). *In vielen Tipprunden erhält ein in der Tendenz richtiger Remis-Tipp die Tordifferenz-Punktzahl (hier wären das 3 Punkte), da bei Remis Tordifferenz und Tendenz zusammenfallen. Die Zielrunde vergibt dafür jedoch nur die Tendenz-Punktzahl 2 (Beispiel: Tipp 1:1, Ergebnis 2:2 ergibt 2 Punkte). Remis-Tipps sind hier also strukturell schwächer als im verbreiteten 4/3/2-Schema: Ein Sieg-Tipp kann drei Punkteklassen treffen (4/3/2), ein Remis-Tipp nur zwei (4/2). Der Optimierer berücksichtigt das automatisch*

über (6); erwartbare Konsequenz ist eine gegenüber dem Standardschema reduzierte Häufigkeit optimaler Remis-Tipps.

Weitere Regelparameter der Zielrunde.

- **Tippmodus:** genaues Ergebnis, gewertet „nach Elfmeterschießen“, relevant nur für die K.o.-Phase (Abschnitt 5.9); Gruppenspiele werden nach 90 Minuten gewertet, Remis ist dort ein regulärer Ausgang.
- **Bonusfragen:** 4 Punkte pro richtiger Antwort, Reihenfolge ohne Bedeutung. Antworten werden aus der Monte-Carlo-Turniersimulation (Abschnitt 6) abgeleitet: Maximierung der Trefferwahrscheinlichkeit je Frage.
- **Tippabgabe bis Anpfiff** (0 Minuten Vorlaufzeit): operativ wertvoll, da Tipps mit dem spätesten verfügbaren Quoten- und Aufstellungsstand abgegeben werden können.
- **Punktegleichstand:** Platzierung per Anzahl der Spieltagsiege, relevant für die Rangoptimierung, denn Spieltagsiege erhöhen den Wert varianzreicher Tipps an Spieltagen, an denen man ohnehin nicht führt.

Konfigurierbarkeit. Das Punkteschema bleibt ein injizierter Parameter (Konstruktor-Argument), die obigen Werte sind die Default-Konfiguration der Zielrunde, Backtests gegen andere Schemata (z. B. Standard 4/3/2 mit Remis-Tordifferenz) bleiben möglich.

9.2 Optimaler Tipp als Erwartungsnutzen-Maximierung

Der Optimierer berechnet den erwarteten Punktertrag $\mathbb{E}[S(u, v)]$ für jeden Kandidaten-Tipp (u, v) auf dem Kandidatengitter $\{0, \dots, 5\}^2$. Höhere Tipps erweisen sich bei realistischen Intensitäten λ, μ empirisch als nicht optimal, das Gitter ist jedoch konfigurierbar. Die Auswertung summiert über das volle zensierte Gitter mit $X_{\max} = 10$, also

$$\mathbb{E}[S(u, v)] = \sum_{x=0}^{X_{\max}} \sum_{y=0}^{X_{\max}} \mathbb{P}(X = x, Y = y) \cdot S(u, v \mid x, y), \quad (u^*, v^*) = \arg \max_{(u, v)} \mathbb{E}[S(u, v)]. \quad (6)$$

Das ist eine exakte, geschlossene Berechnung (36×121 Auswertungen pro Spiel) und somit kein Schätzproblem, sobald $\mathcal{P}$ vorliegt.

Proposition 9.1 (Tipp $\neq$ Modus der Verteilung). *Unter dem Punkteschema der Zielrunde aus Abschnitt 9.1 und dem Gitter $\{0, \dots, X_{\max}\}^2$ existieren Intensitäten (λ, μ) , für die der punktoptimale Tipp (u^*, v^*) aus (6) nicht mit dem wahrscheinlichsten Ergebnis (dem Modus von $\mathcal{P}$) übereinstimmt.*

Beweis. Direkte Auswertung von (6) für unabhängige Poisson-Margen mit $\lambda = 1,8$ und $\mu = 1,2$ (moderater Favorit): Der Modus der Ergebnismatrix ist das Remis 1:1 mit $\mathbb{P}(1:1) = 0,108$, aber $\mathbb{E}[S(1, 1)] = 0,678$.

Der optimale Tipp ist 2:1 mit $\mathbb{E}[S(2, 1)] = 1,354$ (knapp vor 1:0 mit $\mathbb{E}[S(1, 0)] = 1,347$), was fast dem doppelten erwarteten Punktertrag des Modus-Tipps entspricht, da der Remis-Tipp die Tordifferenz-Punkteklasse verliert (Bemerkung 9.1) und nur zwei statt drei Punkteklassen abdeckt. $\square$

Diese Rechnung dient zugleich als handverifizierter Testfall für Meilenstein M4; der Optimierer macht die Abwägung zwischen Trefferwahrscheinlichkeit und Nachbarschafts-Abdeckung exakt statt intuitiv.

9.3 Sensitivität und Diagnostik

Pro Spiel werden die Top-5-Tipps nach $\mathbb{E}[S(u, v)]$, deren Erwartungswerte und die Differenz zum naiven Modus-Tipp ausgegeben. Da die $\mathbb{E}[S(u, v)]$ -Landschaften oft flach sind (Differenzen $< 0,05$ Punkte), dokumentieren wir die Robustheit des optimalen Tipps gegen Posterior-Unsicherheit in $\mathcal{P}$ (Anteil der Posterior-Draws, in denen (u^*, v^*) optimal bleibt).

9.4 Rangmaximierung statt Punktemaximierung als Erweiterung

Die Punktemaximierung nach (6) ist optimal für die *erwartete* Punktzahl, doch das eigentliche Ziel der Zielrunde ist die in Abschnitt 3.2 definierte Maximierung der Platzierungswahrscheinlichkeit (1). Dieser Abschnitt beschreibt die praktische Operationalisierung genau dieser Zielfunktion und keine davon abweichende Formalisierung. Da das Verhalten der Mitspieler stark korreliert (Herdenverhalten auf Favoriten), ist Modus B2 im Kern ein nicht-kooperatives Spiel.

Sei $\mathbf{T}_m$ der unbekannte Vektor der Tipps aller $N - 1$ Mitspieler für Spiel m . Wir führen ein empirisches Crowd-Modell $Q(\cdot \mid q_m)$ ein, das jedem Tipp (u, v) die Wahrscheinlichkeit $Q((u, v) \mid q_m)$ zuordnet, mit der ein zufälliger Mitspieler ihn bedingt auf die entvigten Markt-Tendenzen q_m wählt. Das Gegnermodell C_m aus Abschnitt 3.2 entsteht aus genau diesem Crowd-Modell, indem seine Komponenten über $C_m(u, v) = Q((u, v) \mid q_m)$ befüllt und nach jedem Spieltag aus den beobachteten Tipps aktualisiert werden. Die auf das aktuelle Spiel eingeschränkte, myopische Näherung der Zielfunktion (1) maximiert nicht den erwarteten Punktertrag, sondern die Wahrscheinlichkeit, die Mitspieler in diesem Spiel zu übertreffen, also

$$\max_{(u,v)} \sum_{x,y} \mathcal{P}_m(x, y) \sum_{\mathbf{T}_m} \mathbb{P}(\mathbf{T}_m \mid Q) \cdot \mathbb{I}_{\{S(u,v|x,y) > \max_k S(T_{m,k}|x,y)\}}.$$

Den vollen Turnierhorizont stellt das System her, indem es diese Einzelspiel-Näherung gemäß (1) in den Fortsetzungswert der Monte-Carlo-Turniersimulation aus Abschnitt 6 einbettet, sodass die Nebenbedingung an den erwarteten Punktertrag $\mathbb{E}[S] \geq \tau$ gewahrt bleibt. Da der Zustandsraum bereits für gut zehn Mitspieler kombinatorisch explodiert, verwendet das System zur Schätzung der Population eine *Mean-Field-Approximation*, indem es statt einzelner Mitspieler die erwartete Punkteverteilung der gesamten Population berechnet. Das Problem transformiert sich in eine Mean-Variance-Optimierung auf Tipp-Erträgen, denn wir suchen den Tipp (u, v) , der die Kovarianz $\text{Cov}(S_{\text{eigen}}, S_{\text{crowd}})$ minimiert, während der isolierte Erwartungswert $\mathbb{E}[S(u, v)]$ hoch bleibt. Dabei bezeichnen S_{eigen} den zufälligen Punktertrag des eigenen Tipps und S_{crowd} den Punktertrag eines gemäß Q gezogenen Crowd-Tipps im selben Spiel. Dies überträgt die Tournament-Theory-Resultate aus dem Fondsmanagement [4] in einer handhabbaren Näherung auf das Tipster-Problem.

Das Absicherungs-Paradoxon beim Hedging in der Endphase. Während die Mean-Field-Approximation das globale Herdenverhalten abbildet, mutiert die Anreizstruktur an den letzten Spieltagen für Spitzenreiter der Tipprunde fundamental. Liegt der Nutzer in Führung, maximiert die reine Punkte-Optimierung nach (6) nicht mehr zwingend die Sieg-Wahrscheinlichkeit des Turniers. Das System implementiert für die Finalphase eine dynamische Absicherungs-Logik (Hedging). Sobald der Vorsprung eine als Hyperparameter kalibrierte Schwelle überschreitet, schrumpfen die abgegebenen Tipps in Richtung der erwarteten Tipps der direkten Verfolger (Varianz-Minimierung durch Spiegelung), anstatt risikoreiche Außenseiter-Tipps mit hohem solitärem $\mathbb{E}[S(u, v)]$ zu wählen.

10 Validierung und Backtesting

10.1 Designprinzipien und Leakage-Kontrolle

1. **Walk-Forward, keine zufälligen Splits:** Training ausschließlich auf $\mathcal{F}_{t_m}$. Für Turnier-Backtests: Parameterschätzung mit Datenstand *vor Turnierbeginn*, optional tägliche Re-Schätzung während des Turniers (nur mit bereits gespielten Turnierspielen).
2. **Feature-Zeitkausalität technisch erzwungen:** Jede Feature-Berechnung erhält den Prognose-Zeitpunkt als Pflicht-Parameter; Tests stellen sicher, dass kein Feature auf Daten mit späterem Zeitstempel zugreift (Look-Ahead-Bias als Testfall, nicht als Konvention).
3. **Hyperparameter-Disziplin und Bayesian Optimization:** Die Likelihood-Gewichte (ξ, w_c) sowie δ, ϕ und die Ensemble-Lernrate ν spannen einen hochdimensionalen Parameterraum auf. Da eine erschöpfende Raster-Suche (Grid Search) hierfür rechenineffizient ist, erfolgt die Kalibrierung über **Bayesian Optimization**. Ein *Gaussian Process* modelliert die Performance (RPS oder CLV) über dem Parameterraum. Eine Acquisition Function (z. B. *Upper Confidence Bound* oder *Thompson Sampling*) wählt iterativ diejenige Parameterkombination für den nächsten Backtest-Lauf, die das Explore-Exploit-Dilemma der Parametersuche mathematisch optimal löst. Die auf dem *Validierungsfenster* (WM 2014, EM 2016, WM 2018) gefundenen Optima werden anschließend eingefroren und auf dem vorregistrierten Test-Set unverändert angewendet.
4. **Vorregistrierung:** Vor der WM 2026 wird die finale Konfiguration (Modelle, Hyperparameter, δ, ϕ , Punkteschema) in einem getaggten Commit eingefroren; alle WM-Prognosen sind dadurch nachweislich ex-ante.

10.2 Evaluationsdatensätze

Fenster	Turniere	Rolle
Training (rollierend)	alle Länderspiele bis t	Parameterschätzung
Validierung	WM 2014, EM 2016, WM 2018	Hyperparameter, Modellwahl
Test (eingefroren)	EM 2021, WM 2022, EM 2024, Copa 2024	finale Bewertung
Live	WM 2026	vorregistrierter Ernstfall

Das ergibt 179 Validierungsspiele (WM 2014, EM 2016, WM 2018) und 198 Testspiele (EM 2021, WM 2022, EM 2024, Copa América 2024), also genug für probabilistische Metriken, aber knapp für ökonomische (daher Bootstrap, Abschnitt 10.7).

10.3 Proper Scoring Rules zur probabilistischen Güte

Accuracy ist für probabilistische Prognosen ungeeignet. Wir verwenden ausschließlich *proper Scoring Rules* (Anreizverträglichkeit: ehrliche Wahrscheinlichkeiten minimieren den erwarteten Score):

Ranked Probability Score (primär). Für die geordneten Ausgänge (Heimsieg vor Remis vor Auswärtssieg) mit Prognose $p = (p_1, p_2, p_3)$ und Ergebnisindikator $e \in \{0, 1\}^3$ (One-Hot-Kodierung des realisierten Ausgangs) lautet er

$$\text{RPS} = \frac{1}{2} \sum_{k=1}^2 \left(\sum_{l=1}^k (p_l - e_l) \right)^2.$$

RPS respektiert die Ordnung der Ausgänge („knapp daneben“ ist besser als „völlig daneben“) und ist Standard der Fußballprognose-Literatur [8]. Erwartete Größenordnung guter Modelle auf Turnierdaten: $\text{RPS} \approx 0,19\text{--}0,21$.

Log-Loss / Ignorance Score. $-\log p_{\text{Ergebnis}}$; bestraft Überkonfidenz drastisch. Zusätzlich auf der *Ergebnismatrix* ausgewertet ($-\log \mathbb{P}(x, y)$), was die volle Verteilung statt nur der Tendenz testet und damit relevant für Modus B ist.

Brier Score. Quadratischer Multikategorie-Score als Robustheits-Check.

Kalibrierung. Reliability-Diagramme und Kalibrierungs-Regression (prognostizierte vs. realisierte Frequenz in Wahrscheinlichkeits-Bins) für Tendenzen und für ausgewählte Ergebnis-Wahrscheinlichkeiten. Ein unkalibriertes Modell ist für Modus A disqualifiziert, selbst bei gutem RPS.

Stratifizierung nach Quotenbändern. Die Kalibrierungsanalyse wird ergänzend explizit nach Quotenbändern (starke Favoriten vs. extreme Außenseiter) geschnitten. Dies dient als spezifisches Prüfkriterium, um nachzuweisen, ob das eigene Modell gegen das marktweit dokumentierte *Favorite-Longshot-Bias* [6] kalibriert ist oder dieses systematisch repliziert.

10.4 Baselines (Mindesthürden)

- BL1. **Klimatologie:** historische Basisraten (z. B. Heim/Remis/Auswärts $\approx 45/27/28\%$ in Turnieren, neutral korrigiert).
- BL2. **Nur-Elo** (Abschnitt 5.7).
- BL3. **Entvigter Markt** (q_m): die harte Benchmark. Modelle ohne Markinput, die BL3 im RPS schlagen, belegen echtes Alpha, Gleichstand ist bereits ein starkes Resultat.
- BL4. **Kicktipp-Heuristiken** (nur Modus B): „immer 2:1 für den Favoriten“, „immer 1:0 für den Quoten-Favoriten“, „Modus der Markt-impliziten Ergebnisverteilung“.

10.5 Ökonomische Validierung Modus A

Auf historischen Quoten (Abdeckung dokumentiert) wird die volle Strategie simuliert (Value-Filter, Shrinkage-Kelly, CVaR-Overlay, Transaktionsannahmen):

- **Equity Curve** und Endkapital-Verteilung (über Bootstrap-Resamples der Spielmenge);
- **ROI** pro Wette und p. a.; **Profit Factor** (Quotient aus Bruttogewinnen und Bruttoverlusten);
- **Maximum Drawdown** (maximaler zwischenzeitlicher Kapitalrückgang) und Drawdown-Dauer;
- **Sharpe Ratio** der Wettrendite-Reihe (mittlere Rendite je Einheit Renditestreuung; mit der gebotenen Vorsicht: nicht-normale, schiefe Erträge, ergänzt um die Sortino Ratio, die nur das Abwärtsrisiko bestraft);
- **Closing Line Value (CLV):** mittlere relative Bewegung der Quote zwischen Wettzeitpunkt und Schlussquote auf den bewetteten Ausgängen. CLV ist der stärkste verfügbare Indikator für echten Edge, da er nicht vom Ergebnisausgang abhängt. Da die Validität des CLV jedoch zwingend eine scharfe Schlusslinie (typischerweise Pinnacle) voraussetzt, weist der Backtestbericht explizit aus, gegen welche Schlussquelle der CLV für Turniere vs. Vereinsligen gemessen wird;
- **Wettfrequenz** und Edge-Verteilung (Plausibilitäts-Check gegen Überkonfidenz).

Data-Snooping und Backtest-Overfitting. Da bei der iterativen Modell- und Hyperparameterwahl auf dem Validierungsfenster implizit eine Vielzahl an Konfigurationen (ξ, w_e, δ) verglichen wird, unterliegt der resultierende Backtest einem Selektionsbias (Data-Snooping). Um die Gefahr von Scheinerfolgen statistisch zu bereinigen, unterziehen wir die Sharpe-Ratio der Equity Curve einem Korrekturverfahren analog zu *White's Reality Check* [34] bzw. berechnen die *Deflated Sharpe Ratio* (DSR) nach Bailey und López de Prado [2].

10.6 Validierung Modus B

Pro Test-Turnier vergleichen wir die erzielten Kicktipp-Punkte des Optimierers mit allen BL4-Heuristiken sowie mit dem Optimierer auf Basis der entvigten Markt-Ergebnismatrix. Für letztere werden die Intensitäten λ und μ eines Dixon-Coles-Modells so gewählt, dass die implizierten Tendenzwahrscheinlichkeiten die entvigten Marktwahrscheinlichkeiten q_m exakt treffen, während ρ aus der Historie fixiert wird. Zusätzlich: erwartete vs. realisierte Punkte (Kalibrierung der Punkteprognose) und Verteilung der Punktzahl über simulierte Turnierverläufe (wo hätte der Optimierer in einer typischen Tipprunde gelegen?).

10.7 Statistische Signifikanz

Bei 198 Testspielen sind Konfidenzintervalle breit, wir berichten sie immer mit:

- **Bootstrap-Konfidenzintervalle** (Spiel-Level-Resampling) für RPS-Differenzen, ROI und Punktdifferenzen;
- **Paarweise Tests** für Scoring-Rule-Differenzen (Diebold-Mariano-artig auf Spiel-Level-Scoredifferenzen);
- **Ehrlichkeitsklausel:** Ergebnisse, deren Konfidenzintervall die Null überdeckt, werden als „nicht unterscheidbar“ berichtet. Insbesondere ist ein positiver Backtest-ROI auf etwa 50 bis 80 Wetten *kein* Beleg für profitables Wetten, und das Dokument sagt das auch so.

11 Software-Architektur

11.1 Schichtenmodell

Schicht	Paket	Verantwortung (SRP)
Ingestion	src/data/	Quellen laden, validieren, kanonisches Schema bauen
Features	src/features/	zeitpunktkorrekte Feature-Berechnung
Modelle	src/models/	$\mathcal{F}_t \rightarrow \mathcal{P}_m$ (Schicht 1+2)
Markt	src/market/	Quoten laden, entvigen (Shin)
Entscheidung	src/decision/	$\mathcal{P}_m \rightarrow$ Aktion (Modus A/B)
Backtest	src/backtest/	Walk-Forward-Engine, Metriken, Berichte
Helpers	src/helpers/	constants.py, dtos.py, enums.py
Einstieg	main.py	CLI: predict / tip / bet / backtest

11.2 Zentrale Abstraktionen

- **ScorelineDistribution** (DTO): die Ergebnismatrix samt Ableitungen (Tendenz, Tordifferenz-Verteilung), also die *einzige* Schnittstelle zwischen Modellen und Entscheidungen.
- **MatchPredictionModel** (ABC): `fit(matches, as_of)` und `predict(fixture) → ScorelineDistribution`.
Subklassen: `EloPoissonModel`, `DixonColesModel`, `BayesianHierarchicalModel`, `EnsembleModel` (Open/Closed: neue Modelle als neue Subklassen).
- **DecisionStrategy** (ABC): `decide(distribution, context) → Aktion`. Subklassen: `KellyBettingStrategy` (Kontext: Quoten, Bankroll), `KicktippStrategy` (Kontext: Punkteschema). Liskov: beide sind drop-in-austauschbar gegen die ABC.
- **ScoringScheme** (Wertobjekt, injiziert): kapselt $S(i, j \mid x, y)$ inklusive Sonderregeln.
- **WalkForwardEngine**: orchestriert Re-Fitting und Vorhersage entlang der Zeitachse; Modelle und Strategien werden per Dependency Injection übergeben (testbar mit Stub-Modellen).

Alle übrigen Konventionen (PEP 8, Black, Type Hints, uv, Funktionslängen, Konstanten-Klassen, Branch-/PR-Workflow) folgen den projektweiten Coding-Standards und werden hier nicht dupliziert.

12 Roadmap mit Verifikationskriterien

Die Meilensteine M1 bis M7 beschreiben den Aufbau vor Turnierbeginn, M8 den laufenden Turnierbetrieb.

- M1. **Daten-Pipeline:** kanonischer Datensatz (Kaggle + Elo gemerzt, Namens-Mapping, K.o.-Rekonstruktion).
Verifiziert durch: Validierungs-Suite grün (Zeilenzahlen, Null-Quoten, Stichproben gegen Originalquellen).
- M2. **Baseline-Modelle:** Elo-Poisson und Dixon-Coles mit Zeitgewichtung.
Verifiziert durch: RPS auf Validierungsturnieren im Literaturbereich (0,19–0,21); Kalibrierungsplots ohne systematische Verzerrung.
- M3. **Backtest-Engine + Metriken:** Walk-Forward, alle Scores, Baselines BL1–BL3.
Verifiziert durch: Leakage-Tests grün; Baseline-Resultate reproduzierbar (Seed-fixiert).
- M4. **Modus B: KicktippStrategy + Punkteschema.**
Verifiziert durch: Unit-Tests gegen handgerechnete $\mathbb{E}[S(u, v)]$ -Beispiele; Backtest-Punkte $\geq$ beste BL4-Heuristik auf Validierungsturnieren.
- M5. **Markt + Modus A:** Quoten-Pipeline, Shin-Entvigung, Shrinkage-Kelly, CVaR-Overlay.
Verifiziert durch: Unit-Tests Kelly/Shin gegen Handrechnung; Backtest-Bericht mit CLV, ROI inkl. Bootstrap-Intervallen.
- M6. **Bayesianisches Modell + Ensemble:**
Verifiziert durch: $\hat{R}$ -Diagnostik sowie Verbesserung im RPS (oder dokumentierte Nicht-Verbesserung) gegenüber M2 out of sample.
- M7. **Finalisierung Test-Set + Vorregistrierung:** eingefrorene Konfiguration, Bericht auf EM 2021–Copa 2024, getaggtter Commit.
Verifiziert durch: vollständiger, reproduzierbarer Ergebnisbericht (README mit Charts).
- M8. **WM-2026-Betrieb:** CLI-Workflow pro Spieltag (Quoten ziehen, Tipps/Wetten ausgeben, Logs).
Verifiziert durch: Trockenlauf auf den WM-Eröffnungsspieltagen mit vollständigem Log.

13 Future Work

In Reihenfolge des erwarteten Nutzen-Aufwand-Verhältnisses:

1. **Spielerbasierte Features** (Belastung, Verfügbarkeit von Schlüsselspielern, xG-Aggregate wo verfügbar).
2. **Partikelfilter** für kontinuierliche Stärke-Dynamik (Abschnitt 5.4, Stufe 3).
3. **Quotenbewegungs-Features** (Open-zu-Close-Drift als Smart-Money-Proxy). Der Rohdatensatz (`line_movement_clv.csv`, Abschnitt 4.4) liegt bereits vor. Offen sind das Feature-Engineering und die Frage, ob die Abdeckung für Turnierspiele ausreicht.
4. **GNN auf Interaktionsdaten**, nur falls die Event-Daten-Abdeckung für Länderspiele substanziell besser wird und aktuell nicht reproduzierbar umsetzbar (Abschnitt 1.4).

Literatur

- [1] J. Apesteguia, I. Palacios-Huerta, *Psychological pressure in competitive environments: Evidence from a randomized natural experiment*, American Economic Review 100 (2010), 2548–2564.
- [2] D. H. Bailey, M. López de Prado, *The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality*, The Journal of Portfolio Management 40 (2014), 94–107.
- [3] L. Breiman, *Optimal gambling systems for favorable games*, Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability 1 (1961), 65–78.
- [4] K. C. Brown, W. V. Harlow, L. T. Starks, *Of tournaments and temptations: An analysis of managerial incentives in the mutual fund industry*, The Journal of Finance 51 (1996), 85–110.
- [5] L. M. B. Cabral, *R&D competition when firms choose variance*, Journal of Economics & Management Strategy 12 (2003), 139–150.
- [6] M. Cain, D. Law, D. Peel, *The favourite-longshot bias and market efficiency in UK football betting*, Scottish Journal of Political Economy 47 (2000), 25–36.
- [7] N. Cesa-Bianchi, G. Lugosi, *Prediction, Learning, and Games*, Cambridge University Press, 2006.
- [8] A. C. Constantinou, N. E. Fenton, *Solving the problem of inadequate scoring rules for assessing probabilistic football forecast models*, Journal of Quantitative Analysis in Sports 8 (2012).
- [9] T. M. Cover, J. A. Thomas, *Elements of Information Theory*, John Wiley & Sons, New York, 1991.
- [10] M. De Paola, V. Scoppa, *The effects of managerial turnover: Evidence from coach dismissals in Italian soccer teams*, Journal of Sports Economics 13 (2012), 152–168.
- [11] M. J. Dixon, S. G. Coles, *Modelling association football scores and inefficiencies in the football betting market*, Journal of the Royal Statistical Society C 46 (1997), 265–280.
- [12] K. Fischer, J. Haucap, *Does crowd support drive the home advantage in professional football? Evidence from German ghost games during the COVID-19 pandemic*, Journal of Sports Economics 22 (2021), 982–1008.
- [13] C. Genest, J. Nešlehová, *A primer on copulas for count data*, ASTIN Bulletin 37 (2007), 475–515.
- [14] M. E. Glickman, *Parameter estimation in large dynamic paired comparison experiments*, Journal of the Royal Statistical Society Series C 48 (1999), 377–394.
- [15] A. Groll, C. Ley, G. Schaubberger, H. Van Eetvelde, *A hybrid random forest to predict soccer matches in international tournaments*, Journal of Quantitative Analysis in Sports 15 (2019), 271–287.
- [16] L. M. Hvattum, H. Arntzen, *Using ELO ratings for match result prediction in association football*, International Journal of Forecasting 26 (2010), 460–470.
- [17] D. Karlis, I. Ntzoufras, *Analysis of sports data by using bivariate Poisson models*, Journal of the Royal Statistical Society D 52 (2003), 381–393.

- [18] J. L. Kelly, Jr., *A new interpretation of information rate*, Bell System Technical Journal 35 (1956), 917–926.
- [19] M. G. Kocher, M. V. Lenz, M. Sutter, *Psychological pressure in competitive environments: New evidence from randomized natural experiments*, Management Science 58 (2012), 1585–1591.
- [20] S. J. Koopman, R. Lit, *A dynamic bivariate Poisson model for analysing and forecasting match results in the English Premier League*, Journal of the Royal Statistical Society A 178 (2015), 167–186.
- [21] T. Lattimore, C. Szepesvári, *Bandit Algorithms*, Cambridge University Press, 2020.
- [22] K. C. Lichtendahl, R. L. Winkler, *Probability elicitation, scoring rules, and competition among forecasters*, Management Science 53 (2007), 1745–1755.
- [23] M. J. Maher, *Modelling association football scores*, Statistica Neerlandica 36 (1982), 109–118.
- [24] P. E. McSharry, *Effect of altitude on physiological performance: a statistical analysis using results of international football games*, BMJ 335 (2007), 1278–1281.
- [25] R. C. Merton, *Lifetime portfolio selection under uncertainty: The continuous-time case*, Review of Economics and Statistics 51 (1969), 247–257.
- [26] G. Mühlheuser, S. Schneemann, D. Sliwka, *The impact of managerial change on performance: The role of team heterogeneity*, Economic Inquiry 54 (2016), 1128–1149.
- [27] A. M. Nevill, R. L. Holder, *Home advantage in sport: An overview of studies on the advantage of playing at home*, Sports Medicine 28 (1999), 221–236.
- [28] R. Pollard, *Home advantage in football: A current review of an unsolved puzzle*, Journal of Human Sport and Exercise 3 (2008), 12–14.
- [29] L. D. Recht, R. A. Lew, W. J. Schwartz, *Baseball teams beaten by jet lag*, Nature 377 (1995), 583.
- [30] R. T. Rockafellar, S. Uryasev, *Optimization of conditional value-at-risk*, Journal of Risk 2 (2000), 21–41.
- [31] H. Rue, Ø. Salvesen, *Prediction and retrospective analysis of soccer matches in a league*, Journal of the Royal Statistical Society D 49 (2000), 399–418.
- [32] H. S. Shin, *Measuring the incidence of insider trading in a market for state-contingent claims*, The Economic Journal 103 (1993), 1141–1153.
- [33] A. Sklar, *Fonctions de répartition à n dimensions et leurs marges*, Publications de l’Institut de Statistique de l’Université de Paris 8 (1959), 229–231.
- [34] H. White, *A reality check for data snooping*, Econometrica 68 (2000), 1097–1126.
- [35] F. Wunderlich, M. Weigelt, R. Rein, D. Memmert, *How does spectator presence affect football? Home advantage remains in European top-class football matches played without spectators during the COVID-19 pandemic*, PLoS ONE 16 (2021), e0248590.
- [36] World Football Elo Ratings (Datenquelle), *Methodology*, online verfügbar unter <https://www.eloratings.net/about>, abgerufen im Jahr 2024.