

Quant-WM-Guru

Ein probabilistisches Prognose- und Entscheidungssystem für die
FIFA-Weltmeisterschaft 2026

Konzeptdokumentation, Version 1.1

M. Dantschenko

Juni 2026

Zusammenfassung

Dieses Dokument spezifiziert Konzept, Mathematik, Datenarchitektur und Validierungsmethodik eines quantitativen Prognosesystems für Fußball-Länderspiele, mit der FIFA-WM 2026 als Anwendungsfall. Das System trennt strikt zwischen *Inferenz* (Schätzung einer vollständigen Wahrscheinlichkeitsverteilung über Spielausgänge) und *Entscheidung* (Ableitung optimaler Handlungen aus dieser Verteilung). Auf demselben stochastischen Kern operieren zwei entscheidungstheoretisch fundamental verschiedene Modi: (1) ein *Capital Allocator*, der Wetten als risikobehaftete Assets behandelt und Einsätze über das fraktionale Kelly-Kriterium mit Risiko-Nebenbedingungen dimensioniert, wobei Nicht-Wetten eine zulässige und häufig optimale Aktion ist; und (2) ein *Kicktipp-Optimierer*, der unter Tippzwang den erwarteten Punktertrag einer turnierspezifischen Punktefunktion maximiert. Die Validierung erfolgt über strikt zeitkausale Walk-Forward-Backtests auf historischen Turnieren (Validierung: WM 2014, EM 2016, WM 2018; eingefrorenes Test-Set: EM 2021, WM 2022, EM 2024, Copa América 2024) mit Proper Scoring Rules (Ranked Probability Score, Log-Loss, Brier Score), Kalibrierungsanalyse sowie ökonomischen Metriken (ROI, Maximum Drawdown, Closing Line Value) gegen explizit definierte Baselines, insbesondere den entvigten Buchmachermarkt.

Inhaltsverzeichnis

1	Einleitung und Zielsetzung	3
1.1	Motivation	3
1.2	Leitprinzip: Trennung von Inferenz und Entscheidung	3
1.3	Capabilities: Was das System leisten muss	3
1.4	Explizite Nicht-Ziele (Scope-Abgrenzung)	4
2	Problemformulierung	4
2.1	Notation	4
2.2	Die zwei Entscheidungsprobleme	4
3	Datenarchitektur	5
3.1	Kanonisches Datenmodell	5
3.2	Datenquellen und Priorisierung	5
3.3	Datenqualität und bekannte Probleme	6
4	Schicht 1: Das stochastische Modell	7
4.1	Basismodell: unabhängige Poisson-Zählprozesse	7
4.2	Dixon-Coles-Korrektur und Zeitgewichtung	7
4.3	Alternative Kopplung und Überdispersion	7

4.4	Dynamische Teamstärken: Zustandsraum-Formulierung	8
4.5	Bayesianische Hierarchie: das Sparse-Data-Problem der Nationalteams	8
4.6	Regimewechsel und turnierspezifische Strukturbrüche	9
4.7	Elo-basiertes Referenzmodell	9
4.8	Feature-basiertes ML-Modell und Ensemble	10
4.9	K.o.-Phase: Verlängerung und Elfmeterschießen	10
5	Schicht 2: Pricing Engine — von Intensitäten zur Ergebnismatrix	11
5.1	Analytische Auswertung als Standardpfad	11
5.2	Monte Carlo, wo es tatsächlich gebraucht wird	11
6	Marktdaten: implizite Wahrscheinlichkeiten und Entvigung	11
7	Schicht 3, Modus A: Der Capital Allocator	12
7.1	Value-Identifikation	12
7.2	Kelly-Kriterium: Herleitung	12
7.3	Fraktionales Kelly und Unsicherheits-Shrinkage	12
7.4	Grenzen der Asymptotik und Finite-Horizon-Effekte	12
7.5	Mehrere gleichzeitige Spiele: Portfolio-Sicht	13
7.6	Betriebsregeln Modus A	13
8	Schicht 3, Modus B: Der Kicktipp-Optimierer	14
8.1	Punktefunktion der Zielrunde	14
8.2	Optimaler Tipp als Erwartungsnutzen-Maximierung	14
8.3	Sensitivität und Diagnostik	15
8.4	Erweiterung: Rang- statt Punktemaximierung	15
9	Validierung und Backtesting	15
9.1	Designprinzipien und Leakage-Kontrolle	15
9.2	Evaluationsdatensätze	16
9.3	Probabilistische Güte: Proper Scoring Rules	16
9.4	Baselines (Mindesthürden)	17
9.5	Ökonomische Validierung Modus A	17
9.6	Validierung Modus B	17
9.7	Statistische Signifikanz	17
10	Software-Architektur	18
10.1	Schichtenmodell	18
10.2	Zentrale Abstraktionen	18
11	Roadmap mit Verifikationskriterien	18
12	Future Work	19

1 Einleitung und Zielsetzung

1.1 Motivation

Fußballspiele sind niedrig-skorende, stark verrauschte stochastische Ereignisse: Das bessere Team verliert regelmäßig, und einzelne Tore (Erwartungswert pro Spiel $\approx 2,5$ – $2,7$) dominieren das Ergebnis. Genau diese Eigenschaften machen Fußball zu einem idealen Testfall für quantitative Methoden, wie sie im Asset Management eingesetzt werden: probabilistische Modellierung statt Punktprognosen, Bewertung gegen einen effizienten Markt (Wettquoten), Positionsgrößenbestimmung unter Unsicherheit und rigorose Out-of-Sample-Validierung.

Das Projekt verfolgt zwei Ziele:

1. **Wissenschaftlich:** Ein methodisch sauberes, reproduzierbares Prognosesystem auf dem Stand der sportstatistischen Literatur [1, 2, 3, 4, 5].
2. **Praktisch:** Einsatz während der WM 2026 in zwei realen Entscheidungssituationen (frei wählbare Wetten; verpflichtende Kicktipp-Abgabe).

1.2 Leitprinzip: Trennung von Inferenz und Entscheidung

Das zentrale Designprinzip des Systems ist die strikte Trennung zweier Fragen:

1. *Was wird passieren?* — Inferenz: Schätzung der gemeinsamen Verteilung $\mathbb{P}(X = x, Y = y)$ der Tore beider Teams (Schichten 1 und 2, Abschnitte 4–5).
2. *Was soll ich tun?* — Entscheidung: Abbildung dieser Verteilung auf eine Handlung unter einer modusabhängigen Zielfunktion (Schicht 3, Abschnitte 7–8).

Beide Modi konsumieren *dieselbe* Wahrscheinlichkeitsmatrix. Unterschiede im Verhalten entstehen ausschließlich aus den Zielfunktionen, nicht aus unterschiedlichen Modellen. Dies ist zugleich das stärkste Argument des Projekts: derselbe stochastische Kern, angewandt auf zwei ökonomisch völlig verschiedene Probleme (diskretionäres Portfoliomanagement vs. Entscheidung unter Zwangsbedingungen).

1.3 Capabilities: Was das System leisten muss

- C1. Für jedes Spiel eine vollständige, kalibrierte gemeinsame Torverteilung $\mathbb{P}(X = x, Y = y)$ liefern, daraus abgeleitet: Tendenzwahrscheinlichkeiten (Sieg/Remis/Niederlage), exakte Ergebnisse, Tordifferenzen, Über-/Unter-Linien.
- C2. Quantifizierte Parameterunsicherheit ausweisen (bayesianische Posteriorverteilungen), keine reinen Punktschätzer.
- C3. Marktquoten einlesen, entvigen und als implizite Wahrscheinlichkeiten sowohl als *Benchmark* als auch als *Feature* nutzen.
- C4. Modus A: Value-Wetten identifizieren ($p_{\text{Modell}} \cdot o > 1 + \delta$), Einsätze via fraktionalem Kelly bestimmen, Risiko-Nebenbedingungen einhalten, explizit „keine Wette“ empfehlen können.
- C5. Modus B: für jedes Spiel den Tipp mit maximalem erwarteten Kicktipp-Punktertrag ausgeben, parametrisiert über ein konfigurierbares Punkteschema.
- C6. Backtests über historische Turniere ohne Look-Ahead-Bias durchführen und alle Metriken aus Abschnitt 9 reproduzierbar berichten.
- C7. Spielphasen korrekt behandeln: In der *Gruppenphase* zählt das 90-Minuten-Ergebnis (Remis möglich). In der *K.o.-Phase* tippt die Zielrunde im Modus „nach Elfmeterschießen“: Steht es nach 90 Minuten und Verlängerung unentschieden, entscheidet das Elfmeterschießen — das System benötigt dort die Endergebnis-Verteilung (Abschnitt 4.9) sowie

Weiterkommens-Wahrscheinlichkeiten (für Turniersimulation, Bonusfragen und Outright-Wetten).

1.4 Explizite Nicht-Ziele (Scope-Abgrenzung)

Auf Doktorarbeits-Niveau gehört die ehrliche Abgrenzung des Machbaren. Die folgenden, teils in frühen Brainstormings (u. a. extern vorgeschlagenen) Komponenten sind *bewusst* nicht Teil des Kernsystems, sondern dokumentiertes Future Work (Abschnitt 12):

- **Graph Neural Networks auf Passnetzwerken:** Ereignisdaten (Passnetzwerke, PP-DA, Ballbesitzzonen) liegen für Länderspiele nicht flächendeckend frei vor; für viele WM-Teilnehmer (z. B. AFC-/CAF-Qualifikation) existieren sie gar nicht. Ein GNN auf lückenhaften Daten erzeugt Scheinpräzision.
- **Hochfrequente Tick-by-Tick-Quotenhistorie (Betfair/Pinnacle):** Historische Tick-Daten sind kostenpflichtig bzw. für vergangene Turniere nicht mehr frei beschaffbar. Der Kern arbeitet mit Eröffnungs- und Schlussquoten (Open/Close), was für die CLV-Analyse (Abschnitt 9.5) ausreicht.
- **Spieler-Belastungsdaten (Minuten in Vereinen):** als aggregiertes Feature in Phase 2 vorgesehen, nicht im Kern — die Beschaffung (Scraping) ist aufwendig und der dokumentierte Zusatznutzen in der Literatur gering gegenüber Marktwert-Proxies.
- **In-Play-/Live-Wetten:** Das System prognostiziert ausschließlich pre-match.

Bemerkung 1.1. *Diese Abgrenzung ist keine Schwäche, sondern Methodendisziplin: Jede Komponente des Kernsystems ist mit frei verfügbaren Daten reproduzierbar. Reproduzierbarkeit ist ein härteres Qualitätskriterium als Architektur-Komplexität.*

2 Problemformulierung

2.1 Notation

Ein Spiel m zwischen Heim-/Erstgenanntem Team i und Gast j zum Zeitpunkt t_m erzeugt den Ausgang $(X_m, Y_m) \in \mathbb{N}_0^2$ (Tore nach 90 Minuten). Wir schreiben:

- $\mathcal{P}_m = (\mathbb{P}(X_m = x, Y_m = y))_{x,y \geq 0}$: die vom Modell geschätzte **Ergebnismatrix** (praktisch trunkiert auf $0 \leq x, y \leq X_{\max}$ mit $X_{\max} = 10$; Restmasse wird der Randzelle zugeschlagen).
- $\pi_m = (\pi_m^H, \pi_m^D, \pi_m^A)$: Tendenzwahrscheinlichkeiten (Heimsieg, Remis, Auswärtssieg), durch Aggregation von $\mathcal{P}_m$ über $\{x > y\}$, $\{x = y\}$, $\{x < y\}$.
- $o_m = (o_m^H, o_m^D, o_m^A)$: dezimale Marktquoten; q_m die daraus entvigten Marktwahrscheinlichkeiten (Abschnitt 6).
- $\mathcal{F}_t$: die Informationsmenge bis Zeitpunkt t (alle Spiele, Ratings, Quoten mit Zeitstempel $< t$). Sämtliche Prognosen für Spiel m dürfen nur $\mathcal{F}_{t_m}$ nutzen (Zeitkausalität, Abschnitt 9.1).

2.2 Die zwei Entscheidungsprobleme

Modus A (Capital Allocator). Gegeben Bankroll B_t , Quoten o_m und Modellverteilung π_m : Wähle Einsatzvektor $f_m \in [0, f_{\max}]^3$ (Anteile der Bankroll auf die drei Tendenzen, inkl. $f_m = 0$), sodass das erwartete logarithmische Bankroll-Wachstum unter Risiko-Nebenbedingungen maximiert wird (Abschnitt 7). Die Aktionsmenge enthält explizit die Nullaktion; empirisch wird sie bei der Mehrheit der Spiele gewählt.

Modus B (Kicktipp-Optimierer). Gegeben Modellmatrix $\mathcal{P}_m$ und Punktefunktion S : Wähle *verpflichtend* genau einen Tipp $(i^*, j^*) \in \mathbb{N}_0^2$, der den erwarteten Punktertrag maximiert (Abschnitt 8). Es gibt keine Nullaktion und kein Kapital; das Risiko ist nicht monetär, sondern positionsbezogen (Rang in der Tipprunde).

Bemerkung 2.1 (Warum die Modi nicht ineinander überführbar sind). *Modus A optimiert eine konkave Nutzenfunktion des Vermögens mit Verzichtsoption — der Wert des Systems entsteht überwiegend durch Selektion (wann wette ich?). Modus B ist ein reines Erwartungsnutzen-Problem über einer diskreten, endlichen Aktionsmenge ohne Verzichtsoption — der Wert entsteht ausschließlich durch die Qualität der Verteilung und die korrekte Ausnutzung der Punktefunktions-Geometrie. Ein gutes Modell für B kann in A wertlos sein (wenn es den Markt nicht schlägt); umgekehrt hilft Markt-Alpha in B nur indirekt.*

3 Datenarchitektur

3.1 Kanonisches Datenmodell

Alle Quellen werden in ein kanonisches Match-Schema überführt (ein Datensatz pro Spiel):

Feld	Typ	Beschreibung
match_id	str	deterministischer Hash aus Datum + Teams
date	date	Anpfiff (UTC)
team_home/away	str	ISO-normalisierte Teamnamen
goals_home/away	int	Tore nach 90 Min.
goals_home/away_aet	int?	Tore nach Verlängerung (falls K.o.)
penalty_winner	str?	Sieger Elfmeterschießen (falls)
tournament	enum	WM, EM, Quali, Freundschaftsspiel, ...
stage	enum	Gruppe, Achtelfinale, ...
neutral	bool	neutraler Spielort
host_home/away	bool	Team ist Gastgeber des Turniers
city, country	str	Spielort (für Reise-/Höhenfeatures)
elo_home/away	float	Elo-Rating <i>zum Stichtag vor</i> dem Spiel
odds_open/close	float ³	Marktquoten 1X2 (sofern verfügbar)

Annahme 3.1 (Zeitstempel-Disziplin). *Jedes abgeleitete Feature (Elo, Form, Marktwert) trägt einen Gültigkeits-Zeitstempel und wird ausschließlich mit Informationsstand vor Anpfiff berechnet. Dies wird technisch erzwungen, nicht nur konventionell vereinbart (Abschnitt 9.1).*

3.2 Datenquellen und Priorisierung

Daten	Quelle	Kosten	Prio	Verwendung
Länderspiele seit 1872 (Ergebnis, Ort, Turnier)	Kaggle „International football results“ (martj42)	frei	P0	Modelltraining
Elo-Ratings Nationalteams	elratings.net	frei	P0	Feature, Baseline
FIFA-Ranking (historisch)	Kaggle-Archive	frei	P1	Feature
Turnierquoten 1X2 (Senior-Nationalteams, 2005–2015)	Beat-The-Bookie-Datensatz (Closing)	frei	P0 ^(A)	Backtest Modus A (WM 2006–2014, EM 2008/2012), Benchmark
Turnierquoten 1X2 (WM/EM/Copa, 2018–2024)	FootyStats (c-dl.php)	frei	P0 ^(A)	Backtest Modus A (Test-Set)
Vereinsliga-Quoten 1X2 (Open ab ~2002, Close ab 2012/13)	football-data.co.uk	frei	P0 ^(A)	Modus-A-Validierung (Proof-of-Concept)
Quoten live (WM 2026)	The Odds API (Free Tier)	frei	P0 ^(A)	Betrieb Modus A
Kader-Marktwerte	Transfermarkt	frei (Scraping, ToS prüfen)	P1	Feature (log-Skala)
xG für Länderspiele	FBref (lückenhaft)	frei	P2	Phase 2
Spielerbelastung (Vereinsminuten)	FBref/Transfermarkt	frei, aufwendig	P2	Phase 2

P0 = Pflicht für den Kern; ^(A) = Pflicht nur für Modus A; P1 = stark erwünscht; P2 = optional/Phase 2.

3.3 Datenqualität und bekannte Probleme

- **Teamnamen-Normalisierung:** historische Umbenennungen und Rechtsnachfolgen (UdSSR→Russland, Jugoslawien→Serbien, Tschechoslowakei) werden über eine explizite Mapping-Tabelle mit Gültigkeitszeiträumen behandelt.
- **Verlängerungstore:** Quelldatensätze mischen teils 90-Minuten- und 120-Minuten-Ergebnisse. Für K.o.-Spiele werden *beide* Ergebnisse rekonstruiert (90 Minuten und Endstand inkl. Verlängerung samt Elfmeter-Sieger): Die Zielrunde wertet nach Elfmeterschießen (Abschnitt 8.1), Backtests anderer Schemata und das Modelltraining benötigen die 90-Minuten-Basis.
- **Quoten-Survivorship (Turniere):** Für ältere Turniere existieren Quoten nur von wenigen Buchmachern; wir dokumentieren pro Turnier die Abdeckung und rechnen ROI-Backtests nur auf Spielen mit belegten Quoten.
- **Zusammengesetzte Turnierquoten-Basis:** Da keine einzelne freie Quelle alle Zielturniere abdeckt, wird die Turnierquoten-Basis aus zwei Quellen zusammengesetzt: (i) der Beat-The-Bookie-Datensatz liefert Closing-Quoten für Senior-Nationalmannschaftsspiele 2005–2015 (u. a. WM 2006/2010/2014, EM 2008/2012), (ii) FootyStats liefert pre-match 1X2-Quoten für die jüngeren Turniere (WM 2018/2022, Copa 2024; EM 2016/2020/2024 nach Ergänzung der Wettbewerbs-IDs). Beide Quellen unterscheiden sich in Quotentyp (Closing vs. pre-match) und Buchmacher-Aggregation; die Heterogenität wird im Backtest-Bericht je Turnier ausgewiesen, und CLV-Analysen sind nur auf der Closing-belegten Teilmenge zulässig.
- **Quoten-Abdeckung football-data.co.uk:** Diese Quelle deckt ausschließlich nationale *Vereinsligen* ab, *keine* WM-/EM-Turnierspiele. Open-Quoten (1X2) liegen für die Topligen ab ~2002/03 vor, Closing-Quoten (inkl. Pinnacle, nötig für CLV) erst ab 2012/13 (schottische Unterligen ab 2016/17). Modus A wird daher zunächst auf Vereinsligen 2012/13–heute als Proof-of-Concept validiert (exzellente, reichhaltige Quoten-Coverage, Heimat des Dixon-Coles-Modells); die Turnier-Backtests laufen separat auf der dünneren, aber zielrelevanten

Turnierquoten-Basis.

- **Freundschaftsspiele:** systematisch geringere Intensität (Rotation); sie erhalten im Modell ein eigenes Wettbewerbsgewicht (Abschnitt 4.2).

4 Schicht 1: Das stochastische Modell

4.1 Basismodell: unabhängige Poisson-Zählprozesse

Ausgangspunkt (Maher [1]): Die Tore X, Y eines Spiels seien bedingt unabhängig Poisson-verteilt,

$$X \sim \text{Poisson}(\lambda), \quad Y \sim \text{Poisson}(\mu), \quad \mathbb{P}(X = x, Y = y) = \frac{\lambda^x e^{-\lambda}}{x!} \cdot \frac{\mu^y e^{-\mu}}{y!}, \quad (1)$$

mit log-linearen Intensitäten

$$\log \lambda = \gamma + \alpha_i - \beta_j + \eta \cdot h, \quad \log \mu = \gamma + \alpha_j - \beta_i, \quad (2)$$

wobei α_k die Angriffs- und β_k die Verteidigungsstärke von Team k , γ ein Niveau-Parameter und $h \in \{0, 1\}$ ein Heimvorteils-Indikator ist. Identifizierbarkeit wird über die Nebenbedingungen $\sum_k \alpha_k = 0$, $\sum_k \beta_k = 0$ hergestellt.

WM-Besonderheit: Heimvorteil auf neutralem Platz. Bei Turnierspielen ist $h = 0$ für beide Teams; stattdessen erhält der Gastgeber einen separaten Host-Effekt η_{host} (2026: USA, Mexiko, Kanada). Zusätzlich prüfen wir reisedistanz- und höhenbasierte Kovariaten (Mexiko-Stadt: 2.240 m) auf Signifikanz.

4.2 Dixon-Coles-Korrektur und Zeitgewichtung

Empirisch weichen niedrige Ergebnisse (0:0, 1:1, 1:0, 0:1) von der Unabhängigkeitsannahme ab. Dixon und Coles [2] korrigieren mit dem Faktor τ :

$$\mathbb{P}(X = x, Y = y) = \tau_{\lambda, \mu}(x, y) \frac{\lambda^x e^{-\lambda}}{x!} \frac{\mu^y e^{-\mu}}{y!}, \quad \tau_{\lambda, \mu}(x, y) = \begin{cases} 1 - \lambda\mu\rho & (x, y) = (0, 0) \\ 1 + \lambda\rho & (x, y) = (0, 1) \\ 1 + \mu\rho & (x, y) = (1, 0) \\ 1 - \rho & (x, y) = (1, 1) \\ 1 & \text{sonst,} \end{cases} \quad (3)$$

mit Abhängigkeitsparameter ρ (typisch leicht negativ). Damit alle Zellwahrscheinlichkeiten nicht-negativ bleiben, ist ρ auf den Bereich $\max(-1/\lambda, -1/\mu) \leq \rho \leq \min(1/(\lambda\mu), 1)$ beschränkt. Die Parameterschätzung maximiert die zeitgewichtete Log-Likelihood

$$\ell(\theta; t) = \sum_{m: t_m < t} \omega(t - t_m) \cdot w_{c(m)} \cdot \log \mathbb{P}_\theta(X_m = x_m, Y_m = y_m), \quad \omega(\Delta t) = e^{-\xi \Delta t}, \quad (4)$$

wobei $\xi > 0$ die Zerfallsrate der Zeitgewichtung festlegt (Halbwertszeit $\log 2/\xi$) und $w_{c(m)}$ ein Wettbewerbsgewicht ist (WM/EM-Spiele > Qualifikation > Freundschaftsspiele). ξ und w werden *nicht* in-sample gefittet, sondern per zeitkausaler Kreuzvalidierung auf dem Ranked Probability Score optimiert (Abschnitt 9.3).

4.3 Alternative Kopplung und Überdispersion

Als erste Robustheits-Variante implementieren wir Karlis/Ntzoufras [3]: $X = Z_1 + Z_3$, $Y = Z_2 + Z_3$ mit unabhängigen $Z_k \sim \text{Poisson}(\lambda_k)$, sodass $\text{Cov}(X, Y) = \lambda_3 > 0$.

Behandlung der Überdispersion (Negativ-Binomial-Modell). Die Poisson-Verteilung erzwingt die strikte Gleichheit von Mittelwert und Varianz ($\text{Var}(X) = \mathbb{E}[X] = \lambda$). Im internationalen Fußball führen extreme Leistungsunterschiede (insb. in Qualifikationsrunden gegen deutlich schwächere Verbände) häufig zu empirischer Überdispersion ($\text{Var}(X) > \mathbb{E}[X]$). Um die hierdurch entstehenden schweren Ränder der Torverteilung korrekt abzufangen und die Wahrscheinlichkeit extremer Kanter Siege nicht systematisch zu unterschätzen, implementieren wir als zweite Verteilungsalternative ein Negativ-Binomial-Modell: Jede Marge wird über eine eigene, unabhängige Gamma-Mischung des Poisson-Prozesses definiert (separate Frailty-Variablen für X und Y , sodass keine zusätzliche Kreuzkorrelation induziert wird), wodurch ein separater Dispersionsparameter $\alpha_{\text{disp}} > 0$ entsteht:

$$\text{Var}(X) = \lambda + \alpha_{\text{disp}} \lambda^2. \quad (5)$$

Der formale Modellvergleich gegen das klassische Dixon-Coles-Modell erfolgt out-of-sample. Da Überdispersion fast ausschließlich die Ränder der Ergebnisverteilung betrifft und die Tendenzwahrscheinlichkeiten kaum verändert, ist der Ranked Probability Score hierfür nahezu unempfindlich; primäre Vergleichsmetrik ist daher der Log-Loss auf der vollen Ergebnismatrix ($-\log \mathbb{P}(x, y)$, Abschnitt 9.3), der RPS wird nachrichtlich mitberichtet.

4.4 Dynamische Teamstärken: Zustandsraum-Formulierung

Statische α, β sind für ein Turnier-Setting unzureichend (Generationenwechsel, Trainereffekte). Wir modellieren die Stärken als latente Random-Walk-Prozesse [4, 5]:

$$\alpha_{k,t+1} = \alpha_{k,t} + \varepsilon_{k,t}^\alpha, \quad \varepsilon_{k,t}^\alpha \sim \mathcal{N}(0, \sigma_\alpha^2), \quad \beta_{k,t+1} = \beta_{k,t} + \varepsilon_{k,t}^\beta, \quad \varepsilon_{k,t}^\beta \sim \mathcal{N}(0, \sigma_\beta^2), \quad (6)$$

mit Beobachtungsgleichung (2). Die Innovationsvarianzen $\sigma_\alpha^2, \sigma_\beta^2$ kontrollieren, wie schnell Stärken driften dürfen.

Implementierungsentscheidung. Die exakte Filterung (Partikelfilter) ist möglich, aber für den Kern wählen wir die pragmatische Hierarchie:

1. **Stufe 1 (Kern):** Dixon-Coles mit exponentieller Zeitgewichtung (4) — approximiert die Dynamik und ist in Minuten schätzbar.
2. **Stufe 2 (Kern):** Bayesianisches hierarchisches Modell (Abschnitt 4.5) mit Random-Walk-Prior auf Turnier-Zyklus-Ebene (Stützstellen alle 2 Jahre statt pro Spiel) — voller Posterior in PyMC/NumPyro in vertretbarer Rechenzeit.
3. **Stufe 3 (Future Work):** kontinuierlicher Partikelfilter.

4.5 Bayesianische Hierarchie: das Sparse-Data-Problem der Nationalteams

Nationalteams spielen ~ 10 Spiele pro Jahr, oft gegen Gegner derselben Konföderation. Daraus folgen zwei Kernprobleme: (a) große Parameterunsicherheit pro Team, (b) schwache Identifikation der *interkonföderalen* Stärkerelationen (UEFA vs. CONMEBOL vs. AFC vs. CAF vs. CONCACAF vs. OFC) — ausgerechnet die Relation, die bei einer WM entscheidend ist.

Wir adressieren beides mit partieller Pooling-Struktur:

$$\alpha_k \sim \mathcal{N}(\mu_{\text{conf}(k)}^\alpha + \psi \cdot \log \widetilde{MV}_k, \sigma_{\text{team}}^2), \quad \mu_c^\alpha \sim \mathcal{N}(0, \sigma_{\text{conf}}^2), \quad (7)$$

analog für β_k . Hier ist $\widetilde{MV}_k$ der (zeitgestempelte, normierte) Kader-Marktwert als Stärke-Prior und ψ der zugehörige Gewichtungskoeffizient (das Symbol δ ist der Value-Marge in Abschnitt 7 vorbehalten): Teams mit wenigen Beobachtungen werden zum Konföderations-Mittel plus Marktwert-Signal geschrumpft statt zu Null. Interkonföderale Spiele (WM-Endrunden, Freundschaftsspiele, Confed-/Continental-Playoffs) identifizieren die μ_c^α -Ebene.

Inferenz. Hamiltonian Monte Carlo (NUTS) via PyMC oder NumPyro; Konvergenzdiagnostik über $\hat{R} < 1,01$ und effektive Stichproben; Posterior Predictive Checks gegen empirische Tor-Histogramme.

Nutzen des Posteriors. Die Parameterunsicherheit wird *durchgereicht*: Die Ergebnismatrix $\mathcal{P}_m$ entsteht als Posterior-Mittel über die prädiktive Verteilung, und für Modus A steht zusätzlich die Verteilung von p_{Modell} selbst zur Verfügung — ein Edge, der nur unter günstigen Parameterausprägungen existiert, rechtfertigt kleinere Einsätze (Abschnitt 7.3).

4.6 Regimewechsel und turnierspezifische Strukturbrüche

Die in Abschnitt 4.4 definierte Zustandsraum-Modellierung fängt graduellen Formdrift ab. Turnier-Settings weisen jedoch abrupte, diskrete Strukturbrüche auf, die das System wie folgt berücksichtigt:

- a) **Das WM-2026-Format als struktureller Bruch:** Die Erweiterung auf 48 Teams (12 Vierergruppen, Einzug der acht besten Gruppendritten, K.o.-Baum mit 32 Teams) verändert Anreizstruktur und Weiterkommens-Wahrscheinlichkeiten gegenüber allen Turnieren des Validierungszeitraums (2014–2024). Behandlung: Die Monte-Carlo-Turniersimulation (Abschnitt 5) implementiert das 2026er-Reglement exakt (Gruppen-Tiebreaker, Ranking der Gruppendritten, neuer K.o.-Baum); die Prognose einzelner Spiele ist davon unberührt, da formatunabhängig. Dass format-sensitive Größen (Weiterkommens- und Titelwahrscheinlichkeiten, Bonusfragen) auf historischen 32-Team-Turnieren nur eingeschränkt validierbar sind, wird als bekannte Limitation im Validierungsbericht ausgewiesen.
- b) **Dead Rubbers (zustandsabhängige Intensitäten):** Steht das Weiterkommen oder Ausscheiden eines Teams vor dem dritten Gruppenspiel bereits fest, verschiebt sich die Torverteilung (Kader-Rotation, Motivationseffekte). Das System erweitert hierfür die Intensitätsgleichung (2) um einen additiven Term $\zeta \cdot I_{\text{dead}}$, wobei die Indikatorvariable $I_{\text{dead}} \in \{0, 1\}$ ex ante aus dem Tabellenstand vor Anpfiff berechenbar ist (zeitkausal) und ζ auf historischen dritten Gruppenspielen geschätzt wird.
- c) **Exogene Strukturbrüche (COVID-Epoche):** Spiele der Geisterspiel-Epoche (ca. 2020–2021) zeigen einen dokumentierten Einbruch des Heimvorteils. Da bei Turnierspielen ohnehin $h = 0$ gilt, wäre eine Skalierung von h dort wirkungslos; korrigiert werden stattdessen (i) der Heimvorteil h in den betroffenen *Trainingsspielen* (Qualifikation, Nations League, Freundschaftsspiele) über eine zeitlich begrenzte Skalierung und (ii) der Host-Effekt η_{host} der EM 2021, die als Multi-Host-Turnier gesondert kodiert wird (England trug sechs von sieben Spielen in Wembley aus).

4.7 Elo-basiertes Referenzmodell

Als einfaches, robustes Zweitmodell (und Pflicht-Baseline) dient ein Elo-Ansatz [6]: Das World-Football-Elo-Rating [16] liefert R_i, R_j ; eine geordnete logistische Regression bzw. Poisson-Regression bildet die Differenz $d = R_i - R_j$ (plus Host-Indikator) auf Tendenzwahrscheinlichkeiten bzw. Torintensitäten ab:

$$\log \lambda = c_0 + c_1 d + c_2 \cdot \text{host}, \quad \log \mu = c_0 - c_1 d. \quad (8)$$

Dieses Modell hat ~ 3 Parameter, ist nahezu un-overfitbar und erstaunlich schwer zu schlagen — genau deshalb ist es die Messlatte für jede komplexere Komponente.

4.8 Feature-basiertes ML-Modell und Ensemble

Drittens ein Gradient-Boosting-Modell (LightGBM/XGBoost) auf zeitpunktkorrekten Features: Elo-Differenz, Marktwert-Verhältnis (log-Skala), Form (gewichtete Tordifferenz letzter n Spiele), Ruhetage, Reisedistanz, Wettbewerbstyp, Turnierphase — und optional die entvigten Marktquoten als Feature (nur für Modus B; in Modus A wäre der Markt sonst zugleich Input und Benchmark, was den Alpha-Nachweis zirkulär machte; vgl. Bemerkung 4.1).

Die Modelle werden per **Stacking** kombiniert: Eine multinomiale logistische Meta-Regression auf den Out-of-Fold-Prognosen der Basismodelle, geschätzt mit ausschließlich zeitkausalen Splits. Erfahrungsgemäß ist das Ensemble-Gewicht selbst ein Diagnose-Instrument: Kollabiert es auf ein Einzelmodell, ist die Zusatzkomplexität nicht gerechtfertigt.

Bemerkung 4.1 (Markt als Feature — Behandlung der Zirkularität). *Für Modus B (kein Markt-Gegner) ist die Marktquote ein legitimes, starkes Feature. Für Modus A berichten wir beide Varianten getrennt: (i) Modell ohne Marktinput — nur dies kann echtes, unabhängiges Alpha belegen; (ii) Modell mit Marktinput — relevant für die praktisch beste Prognose. Diese Trennung wird im Backtest-Bericht durchgehalten.*

4.9 K.o.-Phase: Verlängerung und Elfmeterschießen

Ein Elfmeterschießen findet ausschließlich in der K.o.-Phase statt, und auch dort nur, wenn nach 90 Minuten *und* Verlängerung (2×15 Minuten) kein Sieger feststeht. In der Gruppenphase endet ein Spiel ggf. als Remis. Für K.o.-Spiele wird die Endergebnis-Verteilung dreistufig aufgebaut:

1. Die 90-Minuten-Matrix $\mathcal{P}_m$ wird wie in der Gruppenphase geschätzt.
2. Bedingt auf Remis nach 90 Minuten wird die Verlängerung als Poisson-Prozess mit Intensitäten $\lambda^{ET} = \kappa \cdot \frac{1}{3}\lambda$, $\mu^{ET} = \kappa \cdot \frac{1}{3}\mu$ modelliert ($\frac{1}{3}$: Zeitanteil; κ : empirischer Intensitätsfaktor, erwartbar < 1 wegen vorsichtigerer Spielweise in der Verlängerung — wird auf historischen K.o.-Spiele geschätzt).
3. Bedingt auf Remis auch nach Verlängerung wird das Elfmeterschießen als annähernd faire Münze mit schwachem Stärke-Effekt modelliert: $\mathbb{P}(i \text{ gewinnt ES}) = \text{logit}^{-1}(c \cdot d_{ij})$ mit kleinem c (empirisch nahe 0; wenn nicht signifikant, exakt 0,5).

Bezeichnet D_{90} das Ereignis „Remis nach 90 Minuten“ und D_{120} das Ereignis „Remis auch nach Verlängerung“, so ergibt sich die Weiterkommens-Wahrscheinlichkeit als

$$\mathbb{P}(i \text{ kommt weiter}) = \pi_m^H + \pi_m^D \cdot [\mathbb{P}(i \text{ gewinnt ET} \mid D_{90}) + \mathbb{P}(D_{120} \mid D_{90}) \cdot \mathbb{P}(i \text{ gewinnt ES} \mid D_{120})]. \quad (9)$$

Endergebnis-Verteilung für den Tippmodus „nach Elfmeterschießen“. Die Zielrunde (Abschnitt 8.1) wertet K.o.-Spiele nach dem Endstand inklusive Verlängerung und Elfmeterschießen. Die dafür maßgebliche Verteilung $\mathcal{P}_m^{\text{final}}$ entsteht durch Faltung der drei Stufen:

$$\mathcal{P}_m^{\text{final}}(x, y) = \underbrace{\mathcal{P}_m(x, y) \mathbf{1}\{x \neq y\}}_{\text{Entscheidung in 90 Min.}} + \sum_{z \geq 0} \mathcal{P}_m(z, z) \cdot \mathbb{P}(\text{ET/ES führt von } (z, z) \text{ zu } (x, y)), \quad (10)$$

wobei der Übergangskern als Komposition der drei Stufen definiert ist: Verlängerungstore gemäß der Intensitäten (λ^{ET}, μ^{ET}) aus Stufe 2, bei erneutem Remis der ES-Sieger gemäß Stufe 3. Beim Elfmeterschießen gilt die Kicktipp-Konvention, dass dem Sieger des Elfmeterschießens ein Tor zum Stand nach Verlängerung hinzugezählt wird (Beispiel WM-Finale 2022: 3:3 n. V., Argentinien gewinnt das Elfmeterschießen $\Rightarrow$ gewertet als 4:3).¹ Unmittelbare Konsequenzen für den Optimierer: In K.o.-Spiele hat $\mathcal{P}_m^{\text{final}}$ keine Masse auf der Diagonalen — Remis-Tipps sind dort

¹Diese Konvention wird vor Implementierung gegen die Kicktipp-Hilfe und historische Rundendaten verifiziert (Testfall in der Daten-Pipeline).

strikt dominiert und das Gitter der Kandidaten-Tipps wird auf $i \neq j$ eingeschränkt; zugleich verschiebt die +1-Tor-Konvention Masse auf knappe Siege (1:0, 2:1), was deren $\mathbb{E}[R]$ systematisch erhöht.

5 Schicht 2: Pricing Engine — von Intensitäten zur Ergebnismatrix

5.1 Analytische Auswertung als Standardpfad

Da Schicht 1 parametrische Verteilungen liefert, ist die Ergebnismatrix *analytisch* berechenbar: $\mathcal{P}_m$ folgt direkt aus (λ, μ, ρ) durch Auswertung auf dem Gitter $\{0, \dots, X_{\max}\}^2$. Monte Carlo ist hierfür unnötig und würde nur Simulationsrauschen addieren.

5.2 Monte Carlo, wo es tatsächlich gebraucht wird

Simulation (typisch $N = 100.000$ Pfade) kommt an drei Stellen zum Einsatz, an denen analytische Lösungen unpraktikabel sind:

1. **Parameterunsicherheit:** Ziehung $\theta^{(s)} \sim \text{Posterior}$, Auswertung $\mathcal{P}_m^{(s)}$, Aggregation zur prädiktiven Matrix und zur Verteilung der Tendenzwahrscheinlichkeiten (für Kelly-Shrinkage, Abschnitt 7.3).
2. **Turniersimulation:** vollständige WM-Simulation (Gruppenausgänge inkl. Tiebreaker-Regeln, K.o.-Baum mit Abschnitt 4.9) für Weiterkommens-, Halbfinal- und Titelwahrscheinlichkeiten; nötig für Outright-Märkte und Kicktipp-Bonusfragen.
3. **Strategie-Backtests:** Verteilung von Bankroll-Pfaden in Modus A (Drawdown-Quantile statt nur Erwartungswerte).

Bemerkung 5.1. Die Trennung „analytisch wo möglich, Simulation wo nötig“ ist eine bewusste Designentscheidung: Sie hält den Prognosepfad deterministisch, testbar und schnell; Stochastik wird nur dort eingeführt, wo sie einen Informationsgewinn liefert.

6 Marktdaten: implizite Wahrscheinlichkeiten und Entvigung

Buchmacherquoten enthalten eine Marge (Vig). Aus Dezimalquoten $o = (o^H, o^D, o^A)$ folgt der Buchungsüberschuss $\Sigma = \sum_k 1/o^k > 1$. Wir implementieren zwei Entvigungsverfahren:

(a) **Proportionale Normierung (Baseline):** $q^k = \frac{1/o^k}{\Sigma}$.

(b) **Shin-Modell [8] (Standard):** modelliert die Marge als Schutz des Buchmachers vor Insider-Wetten; der Insider-Anteil z wird je Quotensatz aus

$$q_{\text{Shin}}^k = \frac{\sqrt{z^2 + 4(1-z) \frac{(1/o^k)^2}{\Sigma}} - z}{2(1-z)}, \quad \sum_k q_{\text{Shin}}^k = 1 \quad (11)$$

numerisch gelöst. Shin korrigiert das bekannte Favorite-Longshot-Bias-Muster besser als proportionale Normierung; die empirische Überlegenheit wird im Backtest verifiziert (Kalibrierung der q gegen realisierte Frequenzen).

Die entvigten q_m dienen (i) als Benchmark-Prognose, (ii) als Feature (Modus B), (iii) als Gegenseite der Value-Bedingung in Modus A.

7 Schicht 3, Modus A: Der Capital Allocator

7.1 Value-Identifikation

Eine Wette auf Ausgang k mit Quote o^k hat den erwarteten Bruttoertrag pro Einheit

$$\mathbb{E}[\text{Ertrag}] = p^k o^k - 1, \quad (12)$$

mit Modellwahrscheinlichkeit p^k . Die Wettbedingung lautet

$$p^k o^k > 1 + \delta, \quad (13)$$

mit Sicherheitsmarge $\delta > 0$ (kalibriert im Backtest, Größenordnung 2–5 %). Die Marge δ kompensiert Parameterunsicherheit und verbleibende Modellfehler; ohne Marge würde das System systematisch genau dann wetten, wenn das Modell irrt (Winner’s Curse der Modell-Markt-Differenz).

7.2 Kelly-Kriterium: Herleitung

Sei $f \in [0, 1]$ der Bankroll-Anteil auf eine Binärwette mit Nettoquote $b = o - 1 > 0$ und Gewinnwahrscheinlichkeit $p \in (0, 1)$, $q = 1 - p$. Das logarithmische Wachstum pro Wette ist

$$g(f) = p \log(1 + bf) + q \log(1 - f). \quad (14)$$

Da g auf $[0, 1]$ strikt konkav ist, liefert die Bedingung $g'(f) = 0$ das eindeutige innere Maximum, das Kelly-Optimum [10]

$$f^* = \frac{bp - q}{b} = \frac{po - 1}{o - 1}; \quad (15)$$

auf der zulässigen Menge $[0, f_{\max}]$ lautet die Lösung entsprechend $\min\{\max\{0, f^*\}, f_{\max}\}$. Es gilt $f^* > 0$ genau dann, wenn die Value-Bedingung (13) mit $\delta = 0$ erfüllt ist; die Nullaktion ist also natürlicher Bestandteil der Lösung. Kelly maximiert asymptotisch fast sicher die Wachstumsrate des Vermögens [11] und macht den Ruin (bei $f < 1$ und korrektem p) unmöglich — aber es ist berüchtigt volatil und vor allem *extrem empfindlich gegen Überschätzung von p* .

7.3 Fraktionales Kelly und Unsicherheits-Shrinkage

Wir setzen niemals volles Kelly, aus zwei formalisierten Gründen:

1. **Schätzfehler:** Bei überschätztem p ist Voll-Kelly überproportional schädlich (asymmetrische Verlustfunktion in f). Standard-Praxis: *fraktionales Kelly* $f = \phi f^*$ mit $\phi \in [0, 1, 0, 25]$.
2. **Bayesianisches Shrinkage:** Da das Modell die Posteriorverteilung von p liefert, setzen wir $f = \phi \cdot \min_{p' \in [\underline{p}, \bar{p}]} f^*(p')$ mit $[\underline{p}, \bar{p}]$ als z. B. 80 %-Kreditibilitätsintervall — d. h. der Einsatz wird auf das untere Ende des plausiblen Edge-Bereichs dimensioniert. Ist $f^*(\underline{p}) \leq 0$, wird nicht gewettet, selbst wenn der Punktschätzer Value anzeigt.

Zusätzlich gilt eine harte Obergrenze $f \leq f_{\max}$ (z. B. 2 % der Bankroll pro Spiel).

7.4 Grenzen der Asymptotik und Finite-Horizon-Effekte

Die asymptotische Optimalität des Kelly-Kriteriums — Maximierung der fast sicheren Wachstumsrate des Vermögens — beruht auf dem Starken Gesetz der großen Zahlen über die Folge der Wettausgänge [10, 11] und gilt für die Anzahl der Wetten $N_{\text{Wetten}} \rightarrow \infty$. Im Kontext einer FIFA-Weltmeisterschaft operiert der *Capital Allocator* dagegen in einem extremen Non-Asymptotic Regime: Bei 104 Turnierspielen und einer gemäß den Betriebsregeln erwarteten Wettfrequenz von ca. 15–30 % liegt die reale Stichprobengröße bei lediglich $N_{\text{Wetten}} \approx 15$ bis 35.

In diesem endlichen Horizont dominiert die Stichprobenvarianz der Bankroll-Pfade den asymptotischen Wachstumserwartungswert. Ein Ruin im strengen Sinne ist bei $f < 1$ und korrektem

p zwar ausgeschlossen (siehe die Diskussion nach (15)); im endlichen Regime drohen jedoch (i) Drawdowns, deren Aufholung den Resthorizont übersteigt, und (ii) echter Ruin unter Schätzfehlern, falls ein überschätztes p zu $f^* \geq 1$ führt. Das fraktionale Kelly aus Abschnitt 7.3 ($f = \phi f^*$) ist somit nicht nur ein Schutz vor Parameterschätzfehlern, sondern zugleich ein Varianz-Dämpfer, der die Strategie an das endliche Stichprobenregime anpasst.

7.5 Mehrere gleichzeitige Spiele: Portfolio-Sicht

In der Gruppenphase finden bis zu vier Spiele pro Tag statt. Gleichzeitige Wetten interagieren über die gemeinsame Bankroll. Da die zugrundeliegenden Modellwahrscheinlichkeiten p_m zudem über den gemeinsamen bayesianischen Posterior (insb. den Konföderations-Prior μ_c^α) stochastisch abhängig sind, wäre eine Optimierung über das Produkt der Randverteilungen fehlspezifiziert. Die simultane Kelly-Optimierung mittelt daher über die Posterior-Draws $\theta^{(1)}, \dots, \theta^{(S)}$ und bedingt auf jedes $\theta^{(s)}$ exakt über die Spielausgänge:

$$\max_{\substack{f_1, \dots, f_M \geq 0, \\ \sum_m \mathbf{1}^\top f_m \leq f_{\text{Tag}}}} \frac{1}{S} \sum_{s=1}^S \mathbb{E}_{Y \sim \pi(\theta^{(s)})} \left[\log \left(1 + \sum_{m=1}^M R_m(f_m, Y_m) \right) \right], \quad (16)$$

wobei $Y = (Y_1, \dots, Y_M)$ die Tendenz-Ausgänge der M Tagesspiele bezeichnet, die bedingt auf $\theta^{(s)}$ unabhängig mit den Tendenzwahrscheinlichkeiten $\pi_m(\theta^{(s)})$ verteilt sind, $R_m(f_m, Y_m)$ der Nettoertrag der Wette auf Spiel m bei Ausgang Y_m ist und f_{Tag} die maximale Tagesexposition begrenzt (z. B. 5% der Bankroll). Die innere Erwartung wird bei $M \leq 4$ exakt über die 3^M Ausgangskombinationen ausgewertet.

Risiko-Overlay (CVaR). Ergänzend zur Kelly-Zielfunktion wird eine Conditional-Value-at-Risk-Nebenbedingung auf den Tagesverlust L gelegt:

$$\text{CVaR}_\alpha(L) = \mathbb{E} [L \mid L \geq \text{VaR}_\alpha(L)] \leq c \cdot B_t, \quad (17)$$

z. B. $\alpha = 0,95$, $c = 5\%$: Der erwartete Verlust in den schlechtesten 5% der Tage darf 5% der Bankroll nicht übersteigen. Unter Hinzunahme dieser CVaR-Nebenbedingung bleibt das Gesamtproblem nach der Rockafellar-Uryasev-Formulierung [9] konvex und ist mit Standard-Solvern (`cvxpy`) lösbar.

Bemerkung 7.1 (Einordnung). *Für die praktisch relevanten Einsatzgrößen ($\phi f^* \leq 2\%$) bindet die CVaR-Nebenbedingung selten; sie ist primär ein Sicherheitsnetz gegen Tage mit ungewöhnlich vielen simultanen Value-Signalen — genau das Szenario, in dem korrelierte Modellfehler (ein systematisch falscher Konföderations-Prior!) am gefährlichsten sind.*

7.6 Betriebsregeln Modus A

- Quoten-Snapshot zu definiertem Zeitpunkt (z. B. 2 h vor Anpfiff); Entscheidung und Begründung (Modell- p , Markt- q , Edge, f) werden revisionssicher geloggt — vor Anpfiff.
- Es wird höchstens *ein* Ausgang pro Spiel bewettet (der mit maximalem f^* ; simultane Gegenwetten auf dasselbe Spiel sind durch (16) ohnehin nicht optimal).
- Erwartung an die Selektivität: Bei effizienten WM-Märkten ist in 70–85% der Spiele kein Edge zu erwarten; eine deutlich höhere Wettfrequenz ist ein *Warnsignal* (Modell zu selbstsicher), kein Erfolg.
- Paper-Trading ist der Default-Betriebsmodus; Echtgeld ist eine rein persönliche Entscheidung außerhalb des Systems.

8 Schicht 3, Modus B: Der Kicktipp-Optimierer

8.1 Punktefunktion der Zielrunde

Die Zielrunde ist die Kicktipp-Runde „Yanuwantaka“ mit folgenden, den offiziellen Spielregeln entnommenen Parametern:

	Tendenz	Tordifferenz	Ergebnis
Sieg	2	3	4
Unentschieden	2	—	4

Da die Runde Turnierspiele auf neutralem Platz wertet, sind Heim- und Auswärtssieg punktgleich. Formal, für Tipp (i, j) und gewertetes Ergebnis (x, y) :

$$S(i, j \mid x, y) = \begin{cases} 4 & (i, j) = (x, y) \\ 3 & i - j = x - y \wedge (i, j) \neq (x, y) \wedge i \neq j \\ 2 & \text{sgn}(i - j) = \text{sgn}(x - y) \wedge (i - j \neq x - y \vee i = j) \wedge (i, j) \neq (x, y) \\ 0 & \text{sonst.} \end{cases} \quad (18)$$

Bemerkung 8.1 (Remis-Abwertung in dieser Runde). *In vielen Tipprunden erhält ein in der Tendenz richtiger Remis-Tipp die Tordifferenz-Punktzahl (hier wären das 3 Punkte), da bei Remis Tordifferenz und Tendenz zusammenfallen. Die Zielrunde vergibt dafür jedoch nur die Tendenz-Punktzahl 2 (Beispiel: Tipp 1:1, Ergebnis 2:2 $\Rightarrow$ 2 Punkte). Remis-Tipps sind hier also strukturell schwächer als im verbreiteten 4/3/2-Schema: Ein Sieg-Tipp kann drei Punkteklassen treffen (4/3/2), ein Remis-Tipp nur zwei (4/2). Der Optimierer berücksichtigt das automatisch über (19); erwartbare Konsequenz ist eine gegenüber dem Standardschema reduzierte Häufigkeit optimaler Remis-Tipps.*

Weitere Regelparameter der Zielrunde.

- **Tippmodus:** genaues Ergebnis, gewertet „nach Elfmeterschießen“ — relevant nur für die K.o.-Phase (Abschnitt 4.9); Gruppenspiele werden nach 90 Minuten gewertet, Remis ist dort ein regulärer Ausgang.
- **Bonusfragen:** 4 Punkte pro richtiger Antwort, Reihenfolge ohne Bedeutung. Antworten werden aus der Monte-Carlo-Turniersimulation (Abschnitt 5) abgeleitet: Maximierung der Trefferwahrscheinlichkeit je Frage.
- **Tipgabgabe bis Anpfiff** (0 Minuten Vorlaufzeit): operativ wertvoll, da Tipps mit dem spätesten verfügbaren Quoten- und Aufstellungsstand abgegeben werden können.
- **Punktegleichstand:** Platzierung per Anzahl der Spieltagsiege — relevant für die Rang-Optimierung (Abschnitt 8.4): Spieltagsiege erhöhen den Wert varianzreicher Tipps an Spieltagen, an denen man ohnehin nicht führt.

Konfigurierbarkeit. Das Punkteschema bleibt ein injizierter Parameter (Konstruktor-Argument) — die obigen Werte sind die Default-Konfiguration der Zielrunde, Backtests gegen andere Schemata (z. B. Standard 4/3/2 mit Remis-Tordifferenz) bleiben möglich.

8.2 Optimaler Tipp als Erwartungsnutzen-Maximierung

Der Optimierer berechnet für jeden Kandidaten-Tipp (i, j) auf dem Gitter $\{0, \dots, 5\}^2$ (höhere Tipps sind nie optimal bei realistischen λ, μ ; das Gitter ist konfigurierbar):

$$\mathbb{E}[R_{i,j}] = \sum_{x=0}^{X_{\max}} \sum_{y=0}^{X_{\max}} \mathbb{P}(X = x, Y = y) \cdot S(i, j \mid x, y), \quad (i^*, j^*) = \arg \max_{(i,j)} \mathbb{E}[R_{i,j}]. \quad (19)$$

Das ist eine exakte, geschlossene Berechnung (36×121 Auswertungen pro Spiel) — kein Schätzproblem, sobald $\mathcal{P}$ vorliegt.

Proposition 8.1 (Tipp $\neq$ Modus der Verteilung). *Es existieren Intensitäten (λ, μ) , für die der punktoptimale Tipp (i^*, j^*) aus (19) nicht mit dem wahrscheinlichsten Ergebnis (dem Modus von $\mathcal{P}$) übereinstimmt.*

Beweis. Direkte Auswertung von (19) für unabhängige Poisson-Margen mit $\lambda = 1,8$ und $\mu = 1,2$ (moderater Favorit): Der Modus der Ergebnismatrix ist das Remis 1:1 mit $\mathbb{P}(1:1) = 0,108$, aber $\mathbb{E}[R_{1,1}] = 0,678$. Der optimale Tipp ist 2:1 mit $\mathbb{E}[R_{2,1}] = 1,354$ (knapp vor 1:0 mit $\mathbb{E}[R_{1,0}] = 1,347$) — fast der doppelte erwartete Punktertrag des Modus-Tipps, da der Remis-Tipp die Tordifferenz-Punktekategorie verliert (Bemerkung 8.1) und nur zwei statt drei Punktekategorien abdeckt. $\square$

Diese Rechnung dient zugleich als handverifizierter Testfall für Meilenstein M4; der Optimierer macht die Abwägung zwischen Trefferwahrscheinlichkeit und Nachbarschafts-Abdeckung exakt statt intuitiv.

8.3 Sensitivität und Diagnostik

Pro Spiel werden ausgegeben: die Top-5-Tipps nach $\mathbb{E}[R]$, deren Erwartungswerte und die Differenz zum naiven Modus-Tipp. Da $\mathbb{E}[R_{i,j}]$ -Landschaften oft flach sind (Differenzen $< 0,05$ Punkte), dokumentieren wir die Robustheit des optimalen Tipps gegen Posterior-Unsicherheit in $\mathcal{P}$ (Anteil der Posterior-Draws, in denen (i^*, j^*) optimal bleibt).

8.4 Erweiterung: Rang- statt Punktemaximierung

Punktemaximierung ist optimal für die *erwartete* Punktzahl, aber das eigentliche Ziel in einer Tipprunde ist der *Rang*. Rang ist eine nichtlineare Funktion der Punktdifferenzen zu den Mitspielern:

- Wer führt, minimiert Varianz (mit der Masse tippen, Favoriten absichern).
- Wer zurückliegt, maximiert Varianz (konträre Tipps: Außenseiter, ungewöhnliche Ergebnisse) — analog zu Tournament-Theory-Resultaten im Fondsmanagement [12].

Formal: Maximiere $\mathbb{P}(\text{Endpunktzahl} > \text{Punktzahl der Führenden})$ statt $\mathbb{E}[\text{Punkte}]$, gegeben ein Verhaltensmodell der Mitspieler (empirisch: Mehrheit tippt Modus-nahe Favoritenergebnisse). Dies ist als Phase-2-Erweiterung spezifiziert: Monte-Carlo-Simulation der Restrunde inkl. Mitspieler-Tippverhalten, Politik-Auswahl per simulierter Rangverteilung.

9 Validierung und Backtesting

9.1 Designprinzipien und Leakage-Kontrolle

1. **Walk-Forward, keine zufälligen Splits:** Training ausschließlich auf $\mathcal{F}_{t_m}$. Für Turnier-Backtests: Parameterschätzung mit Datenstand *vor Turnierbeginn*, optional tägliche Re-Schätzung während des Turniers (nur mit bereits gespielten Turnierspielen).
2. **Feature-Zeitkausalität technisch erzwungen:** Jede Feature-Berechnung erhält den Prognose-Zeitpunkt als Pflicht-Parameter; Tests stellen sicher, dass kein Feature auf Daten mit späterem Zeitstempel zugreift (Look-Ahead-Bias als Testfall, nicht als Konvention).
3. **Hyperparameter-Disziplin:** ξ , Wettbewerbsgewichte, δ , ϕ werden auf einem zeitlich *früheren* Validierungsfenster gewählt und auf späteren Turnieren unverändert getestet. Es gibt genau *ein* finales, vorregistriertes Test-Set: die jüngsten Turniere werden bis zum Schluss nicht angefasst.

4. **Vorregistrierung:** Vor der WM 2026 wird die finale Konfiguration (Modelle, Hyperparameter, δ , ϕ , Punkteschema) in einem getaggten Commit eingefroren; alle WM-Prognosen sind dadurch nachweislich ex-ante.

9.2 Evaluationsdatensätze

Fenster	Turniere	Rolle
Training (rollierend)	alle Länderspiele bis t	Parameterschätzung
Validierung	WM 2014, EM 2016, WM 2018	Hyperparameter, Modellwahl
Test (eingefroren)	EM 2021, WM 2022, EM 2024, Copa 2024	finale Bewertung
Live	WM 2026	vorregistrierter Ernstfall

Das ergibt ~ 190 Validierungs- und ~ 190 Testspiele — genug für probabilistische Metriken, knapp für ökonomische (daher Bootstrap, Abschnitt 9.7).

9.3 Probabilistische Güte: Proper Scoring Rules

Accuracy ist für probabilistische Prognosen ungeeignet. Wir verwenden ausschließlich *proper* Scoring Rules (Anreizverträglichkeit: ehrliche Wahrscheinlichkeiten minimieren den erwarteten Score):

Ranked Probability Score (primär). Für die geordneten Ausgänge (Heimsieg $\succ$ Remis $\succ$ Auswärtssieg) mit Prognose $p = (p_1, p_2, p_3)$ und Ergebnisindikator $e \in \{0, 1\}^3$ (One-Hot-Kodierung des realisierten Ausgangs):

$$\text{RPS} = \frac{1}{2} \sum_{k=1}^2 \left(\sum_{l=1}^k (p_l - e_l) \right)^2. \quad (20)$$

RPS respektiert die Ordnung der Ausgänge („knapp daneben“ ist besser als „völlig daneben“) und ist Standard der Fußballprognose-Literatur [7]. Erwartete Größenordnung guter Modelle auf Turnierdaten: $\text{RPS} \approx 0,19\text{--}0,21$.

Log-Loss / Ignorance Score. $-\log p_{\text{Ergebnis}}$; bestraft Überkonfidenz drastisch. Zusätzlich auf der *Ergebnismatrix* ausgewertet ($-\log \mathbb{P}(x, y)$), was die volle Verteilung statt nur der Tendenz testet — relevant für Modus B.

Brier Score. Quadratischer Multikategorie-Score als Robustheits-Check.

Kalibrierung. Reliability-Diagramme und Kalibrierungs-Regression (prognostizierte vs. realisierte Frequenz in Wahrscheinlichkeits-Bins) für Tendenzen und für ausgewählte Ergebnis-Wahrscheinlichkeiten. Ein unkalibriertes Modell ist für Modus A disqualifiziert, selbst bei gutem RPS.

Stratifizierung nach Quotenbändern. Die Kalibrierungsanalyse wird ergänzend explizit nach Quotenbändern (starke Favoriten vs. extreme Außenseiter) geschnitten. Dies dient als spezifisches Prüfkriterium, um nachzuweisen, ob das eigene Modell gegen das marktweit dokumentierte *Favorite-Longshot-Bias* [15] kalibriert ist oder dieses systematisch repliziert.

9.4 Baselines (Mindesthürden)

- B1. **Klimatologie:** historische Basisraten (z. B. Heim/Remis/Auswärts $\approx 45/27/28\%$ in Turnieren, neutral korrigiert).
- B2. **Nur-Elo** (Abschnitt 4.7).
- B3. **Entvigter Markt** (q_m): die harte Benchmark. Modelle ohne Marktinput, die B3 im RPS schlagen, belegen echtes Alpha; Gleichstand ist bereits ein starkes Resultat.
- B4. **Kicktipp-Heuristiken** (nur Modus B): „immer 2:1 für den Favoriten“, „immer 1:0 für den Quoten-Favoriten“, „Modus der Markt-impliziten Ergebnisverteilung“.

9.5 Ökonomische Validierung Modus A

Auf historischen Quoten (Abdeckung dokumentiert) wird die volle Strategie simuliert (Value-Filter, Shrinkage-Kelly, CVaR-Overlay, Transaktionsannahmen):

- **Equity Curve** und Endkapital-Verteilung (über Bootstrap-Resamples der Spielmenge);
- **ROI** pro Wette und p. a.; **Profit Factor**;
- **Maximum Drawdown** und Drawdown-Dauer;
- **Sharpe Ratio** der Wettrendite-Reihe (mit der gebotenen Vorsicht: nicht-normale, schiefe Erträge — ergänzt um Sortino);
- **Closing Line Value (CLV)**: mittlere relative Bewegung der Quote zwischen Wettzeitpunkt und Schlussquote auf den bewetteten Ausgängen. CLV ist der stärkste verfügbare Indikator für echten Edge, da er nicht vom Ergebnisrauschen abhängt: systematisch positiver CLV bei $\sim 100+$ Wetten ist aussagekräftiger als jeder ROI auf derselben Stichprobe;
- **Wettfrequenz** und Edge-Verteilung (Plausibilitäts-Check gegen Überkonfidenz).

Data-Snooping und Backtest-Overfitting. Da bei der iterativen Modell- und Hyperparameterwahl auf dem Validierungsfenster implizit eine Vielzahl an Konfigurationen (ξ, w_c, δ) verglichen wird, unterliegt der resultierende Backtest einem Selektionsbias (Data-Snooping). Um die Gefahr von Scheinerfolgen statistisch zu bereinigen, unterziehen wir die Sharpe-Ratio der Equity Curve einem Korrekturverfahren analog zu *White's Reality Check* [13] bzw. berechnen die *Deflated Sharpe Ratio* (DSR) nach Bailey und López de Prado [14].

9.6 Validierung Modus B

Pro Test-Turnier: erzielte Kicktipp-Punkte des Optimierers vs. alle B4-Heuristiken und vs. dem Optimierer auf Basis der entvigten Markt-Ergebnismatrix (Markt-implizite $\mathcal{P}$ via Poisson-Kalibrierung auf q_m). Zusätzlich: erwartete vs. realisierte Punkte (Kalibrierung der Punkteprognose) und Verteilung der Punktzahl über simulierte Turnierverläufe (wo hätte der Optimierer in einer typischen Tipprunde gelegen?).

9.7 Statistische Signifikanz

Bei ~ 190 Testspielen sind Konfidenzintervalle breit; wir berichten sie immer mit:

- **Bootstrap-Konfidenzintervalle** (Spiel-Level-Resampling) für RPS-Differenzen, ROI und Punktdifferenzen;
- **Paarweise Tests** für Scoring-Rule-Differenzen (Diebold-Mariano-artig auf Spiel-Level-Scoredifferenzen);
- **Ehrlichkeitsklausel:** Ergebnisse, deren Konfidenzintervall die Null überdeckt, werden als „nicht unterscheidbar“ berichtet — insbesondere ist ein positiver Backtest-ROI auf ~ 50 – 80 Wetten *kein* Beleg für profitables Wetten, und das Dokument sagt das auch so.

10 Software-Architektur

10.1 Schichtenmodell

Schicht	Paket	Verantwortung (SRP)
Ingestion	src/data/	Quellen laden, validieren, kanonisches Schema bauen
Features	src/features/	zeitpunktkorrekte Feature-Berechnung
Modelle	src/models/	$\mathcal{F}_t \rightarrow \mathcal{P}_m$ (Schicht 1+2)
Markt	src/market/	Quoten laden, entvigen (Shin)
Entscheidung	src/decision/	$\mathcal{P}_m \rightarrow$ Aktion (Modus A/B)
Backtest	src/backtest/	Walk-Forward-Engine, Metriken, Berichte
Helpers	src/helpers/	constants.py, dtos.py, enums.py
Einstieg	main.py	CLI: predict / tip / bet / backtest

10.2 Zentrale Abstraktionen

- **ScorelineDistribution** (DTO): die Ergebnismatrix samt Ableitungen (Tendenz, Tordifferenz-Verteilung) — die *einzig*e Schnittstelle zwischen Modellen und Entscheidungen.
- **MatchPredictionModel** (ABC): `fit(matches, as_of)` und `predict(fixture) → ScorelineDistribution`. Subklassen: `EloPoissonModel`, `DixonColesModel`, `BayesianHierarchicalModel`, `EnsembleModel` (Open/Closed: neue Modelle als neue Subklassen).
- **DecisionStrategy** (ABC): `decide(distribution, context) → Aktion`. Subklassen: `KellyBettingStrategy` (Kontext: Quoten, Bankroll), `KicktippStrategy` (Kontext: Punkteschema). Liskov: beide sind drop-in-austauschbar gegen die ABC.
- **ScoringScheme** (Wertobjekt, injiziert): kapselt $S(i, j | x, y)$ inklusive Sonderregeln.
- **WalkForwardEngine**: orchestriert Re-Fitting und Vorhersage entlang der Zeitachse; Modelle und Strategien werden per Dependency Injection übergeben (testbar mit Stub-Modellen).

Alle übrigen Konventionen (PEP 8, Black, Type Hints, uv, Funktionslängen, Konstanten-Klassen, Branch-/PR-Workflow) folgen den projektweiten Coding-Standards und werden hier nicht dupliziert.

11 Roadmap mit Verifikationskriterien

- M1. **Daten-Pipeline**: kanonischer Datensatz (Kaggle + Elo gemerzt, Namens-Mapping, K.o.-Rekonstruktion).
Verifiziert durch: Validierungs-Suite grün (Zeilenzahlen, Null-Quoten, Stichproben gegen Originalquellen).
- M2. **Baseline-Modelle**: Elo-Poisson und Dixon-Coles mit Zeitgewichtung.
Verifiziert durch: RPS auf Validierungsturnieren im Literaturbereich (0,19–0,21); Kalibrierungsplots ohne systematische Verzerrung.
- M3. **Backtest-Engine + Metriken**: Walk-Forward, alle Scores, Baselines B1–B3.
Verifiziert durch: Leakage-Tests grün; Baseline-Resultate reproduzierbar (Seed-fixiert).
- M4. **Modus B**: `KicktippStrategy` + Punkteschema.
Verifiziert durch: Unit-Tests gegen handgerechnete $\mathbb{E}[R]$ -Beispiele; Backtest-Punkte $\geq$ beste B4-Heuristik auf Validierungsturnieren.
- M5. **Markt + Modus A**: Quoten-Pipeline, Shin-Entvigung, Shrinkage-Kelly, CVaR-Overlay.
Verifiziert durch: Unit-Tests Kelly/Shin gegen Handrechnung; Backtest-Bericht mit CLV, ROI inkl. Bootstrap-Intervallen.

- M6. **Bayesianisches Modell + Ensemble:**
Verifiziert durch: $\hat{R}$ -Diagnostik; RPS-Verbesserung (oder dokumentierte Nicht-Verbesserung) gegenüber M2 out-of-sample.
- M7. **Finalisierung Test-Set + Vorregistrierung:** eingefrorene Konfiguration, Bericht auf EM 2021–Copa 2024, getaggtter Commit.
Verifiziert durch: vollständiger, reproduzierbarer Ergebnisbericht (README mit Charts).
- M8. **WM-2026-Betrieb:** CLI-Workflow pro Spieltag (Quoten ziehen, Tipps/Wetten ausgeben, Logs).
Verifiziert durch: Trockenlauf auf den WM-Eröffnungsspieltagen mit vollständigem Log.

12 Future Work

In Reihenfolge des erwarteten Nutzen-Aufwand-Verhältnisses:

1. **Rang-Optimierung in Tipprunden** (Abschnitt 8.4) — spieltheoretisch reizvoll, benötigt nur vorhandene Bausteine plus Mitspieler-Verhaltensmodell.
2. **Spielerbasierte Features** (Belastung, Verfügbarkeit von Schlüsselspielern, xG-Aggregate wo verfügbar).
3. **Partikelfilter** für kontinuierliche Stärke-Dynamik (Abschnitt 4.4, Stufe 3).
4. **Quotenbewegungs-Features** (Open-zu-Close-Drift als Smart-Money-Proxy), sofern historische Open/Close-Paare in ausreichender Abdeckung beschaffbar sind.
5. **GNN auf Interaktionsdaten** — nur falls Event-Daten-Abdeckung für Länderspiele substanziell besser wird; aktuell nicht reproduzierbar umsetzbar (Abschnitt 1.4).

Literatur

- [1] M. J. Maher, *Modelling association football scores*, Statistica Neerlandica 36 (1982), 109–118.
- [2] M. J. Dixon, S. G. Coles, *Modelling association football scores and inefficiencies in the football betting market*, Journal of the Royal Statistical Society C 46 (1997), 265–280.
- [3] D. Karlis, I. Ntzoufras, *Analysis of sports data by using bivariate Poisson models*, Journal of the Royal Statistical Society D 52 (2003), 381–393.
- [4] H. Rue, Ø. Salvesen, *Prediction and retrospective analysis of soccer matches in a league*, Journal of the Royal Statistical Society D 49 (2000), 399–418.
- [5] S. J. Koopman, R. Lit, *A dynamic bivariate Poisson model for analysing and forecasting match results in the English Premier League*, Journal of the Royal Statistical Society A 178 (2015), 167–186.
- [6] L. M. Hvattum, H. Arntzen, *Using ELO ratings for match result prediction in association football*, International Journal of Forecasting 26 (2010), 460–470.
- [7] A. C. Constantinou, N. E. Fenton, *Solving the problem of inadequate scoring rules for assessing probabilistic football forecast models*, Journal of Quantitative Analysis in Sports 8 (2012).
- [8] H. S. Shin, *Measuring the incidence of insider trading in a market for state-contingent claims*, The Economic Journal 103 (1993), 1141–1153.
- [9] R. T. Rockafellar, S. Uryasev, *Optimization of conditional value-at-risk*, Journal of Risk 2 (2000), 21–41.

- [10] J. L. Kelly, Jr., *A new interpretation of information rate*, Bell System Technical Journal 35 (1956), 917–926.
- [11] L. Breiman, *Optimal gambling systems for favorable games*, Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability 1 (1961), 65–78.
- [12] K. C. Brown, W. V. Harlow, L. T. Starks, *Of tournaments and temptations: An analysis of managerial incentives in the mutual fund industry*, The Journal of Finance 51 (1996), 85–110.
- [13] H. White, *A reality check for data snooping*, Econometrica 68 (2000), 1097–1126.
- [14] D. H. Bailey, M. López de Prado, *The deflated Sharpe ratio: Correcting for selection bias, backtest overfitting, and non-normality*, The Journal of Portfolio Management 40 (2014), 94–107.
- [15] M. Cain, D. Law, D. Peel, *The favourite-longshot bias and market efficiency in UK football betting*, Scottish Journal of Political Economy 47 (2000), 25–36.
- [16] World Football Elo Ratings, <https://eloratings.net>.